

## 基于 HMM 的车辆行驶状态实时判别方法研究

王相海<sup>1,2</sup> 丛志环<sup>1</sup> 方玲玲<sup>1,2</sup> 秦钺鳌<sup>1</sup>

**摘要** 对交通视频车辆轨迹时序特征下的车辆行驶状态进行研究, 提出了一种基于隐马尔科夫模型 (Hidden Markov model, HMM) 的车辆行驶状态实时判别方法. 首先对轨迹序列进行了基于轨迹长度的去不完整轨迹序列、对车辆轨迹点序列的线性平滑滤波和最小二乘线性拟合的预处理操作, 保证了所获得轨迹序列的有效性; 其次, 提出一种基于车辆运行轨迹点序列方向角的车辆轨迹特征值表示方法和基于方向角区间划分的 HMM 观察值序列生成方法, 该方法以方向角的区间变化来区分不同轨迹模式的特征; 最后, 采用多观察值序列下的 Baum-Welch 算法训练得到相关交通场景轨迹模式类的最优 HMM 参数, 并通过实时获取车辆行驶轨迹段与相应模型的匹配, 实现对车辆行驶状态的实时判别. 仿真实验验证了本文方法的有效性和稳定性.

**关键词** 视频车辆轨迹, 隐马尔科夫模型, 方向角, 行驶状态, 实时判别

**引用格式** 王相海, 丛志环, 方玲玲, 秦钺鳌. 基于 HMM 的车辆行驶状态实时判别方法研究. 自动化学报, 2013, 39(12): 2131–2142

**DOI** 10.3724/SP.J.1004.2013.02131

## Determination of Real-time Vehicle Driving Status Using HMM

WANG Xiang-Hai<sup>1,2</sup> CONG Zhi-Huan<sup>1</sup> FANG Ling-Ling<sup>1,2</sup> QIN Ju-Ao<sup>1</sup>

**Abstract** In this paper, we propose a method for determination of vehicle driving status from its time-ordered trajectory data using the hidden Markov model (HMM). Firstly, we take some preprocessing including linear smooth filtering and least square fitting to abandon the trajectory sequences whose lengths are not enough, so as to guarantee the usability of acquired trajectory sequences. Secondly, we extract trajectory direction angle features from the trajectory sequences, and on this basis we propose a direction angle region partition algorithm to generate the observation sequences, which will determine the different trajectory patterns acquired by vehicle real-time various driving status. Finally, we get the optimal HMM model parameters of each trajectory pattern in specific traffic scene by multiple observations based Baum-Welch algorithm, then through matching with the above trained HMM models, we can determine the real-time vehicle driving status. Experiment results demonstrate the effectiveness and stability of this method.

**Key words** Video vehicle trajectories, hidden Markov models (HMM), direction angles, driving status, realtime determination

**Citation** Wang Xiang-Hai, Cong Zhi-Huan, Fang Ling-Ling, Qin Ju-Ao. Determination of real-time vehicle driving status using HMM. *Acta Automatica Sinica*, 2013, 39(12): 2131–2142

收稿日期 2011-06-22 录用日期 2013-06-21

Manuscript received June 22, 2011; accepted June 21, 2013

国家自然科学基金 (41271422), 高等学校博士学科点专项科研基金 (20132136110002), 辽宁省自然科学基金 (20102123), 计算机软件新技术国家重点实验室开放基金 (KFKT2011B09, KFKT2011B11), 南京邮电大学图像处理与图像通信江苏省重点实验室开放基金 (LBK2010003), 智能计算与信息处理教育部重点实验室 (湘潭大学) 开放课题 (2011ICIP06) 资助

Supported by National Natural Science Foundation of China (41271422), Specialized Research Fund for the Doctoral Program of Higher Education (20132136110002), Natural Science Foundation of Liaoning Province (20102123), Open Foundation of Novel Software Technology of State Key Laboratory (Nanjing University) (KFKT2011B09, KFKT2011B11), Open Foundation of Image Processing and Image Communication Laboratory (Nanjing University of Posts and Telecommunications) of Jiangsu Province (LBK2010003), and Intelligent Computing and Information Processing, Open Topics of Education Ministry (Xiangtan University) (2011ICIP06)

本文责任编辑 周东华

Recommended by Associate Editor ZHOU Dong-Hua

交通运输业的快速发展和现代化管理的需求使智能交通系统 (Intelligent transportation system, ITS) 成为解决交通发展中所出现瓶颈问题的重要途径. 其中视频车辆行驶状态实时判别作为实现交通视频场景理解的有力工具, 已成为继视频车辆检测和跟踪后 ITS 又一新兴的研究热点. 所谓车辆行驶状态, 可理解为车辆运动轨迹的不同模式, 即通过对车辆运动轨迹的处理实现对车辆行驶状态的判别. 视频车辆的检测和跟踪<sup>[1-3]</sup>, 主要用于实现自动统计交通路段上行驶的车辆数目, 计算行驶车辆的速

1. 辽宁师范大学计算机与信息技术学院 大连 116029 2. 苏州大学江苏省计算机信息处理技术重点实验室 苏州 215006

1. College of Computer and Information Technology, Liaoning Normal University, Dalian 116029 2. Computer Information Processing Technology Key Laboratory in Jiangsu Province, Soochow University, Suzhou 215006

度以及划分行驶车辆类别等,达到远程智能提取道路交通数据信息的目的;而对视频车辆行驶状态的实时判别,则可以进一步对行驶车辆的状态进行分析,预测和判断车辆违章行为,这对实现车辆智能导航和减少城市交通事故具有积极的意义<sup>[4]</sup>.另外,还可以将提取到的各种交通数据信息在监控终端存储起来,以便随时为交通管理者提供数据分析依据<sup>[5]</sup>.

因此,对智能监控中车辆行驶状态判别的研究具有重要的现实意义.近年来,对该领域的研究受到国内外学者的关注,并出现了许多有关车辆行为的判别方法<sup>[6]</sup>,这些方法通常以传统的车辆运动轨迹模式聚类算法为基础,首先从车辆行驶轨迹中提取表征车辆行驶状态的特征,进而利用机器学习或者模式分类方法进行行为判别.文献[7-8]利用神经网络模型较强的数据处理能力对数据进行分类和手势状态识别,取得了很好的分类识别效果,但神经网络模型对具有时序数据的车辆轨迹的建模能力较弱,而且需要大量的样本数据进行训练才能达到准确收敛;为了克服神经网络模型的建模局限性,文献[9]构建了动态贝叶斯网络模型进行交通场景车辆轨迹的识别分析,该模型能够很好地适应车辆轨迹数据随时间变化的特点,但在车辆轨迹预处理操作中只限定了车辆轨迹的统一长度,忽略了对轨迹的去噪处理,对车辆轨迹的跟踪鲁棒性较差,从而降低了识别率;文献[10]在轨迹预处理部分对轨迹进行了有效性判断,并利用隐马尔科夫模型(Hidden Markov model, HMM)良好的数据建模能力对轨迹模式进行建模,提高了车辆轨迹的识别率,然而文献[10]是保存了车辆行驶后形成的完整轨迹并对整段轨迹进行模式判别的静态轨迹识别,是对车辆行驶出视频帧前最终行驶状态的判别,不能满足诸如对即将违规的车辆进行实时预警等交通视频实时监控理解的需求.总体而言,目前关于车辆行为智能理解方面的研究还刚刚起步,特别是车辆运行状态的实时识别有很多问题还有待进一步研究.本文根据交通视频监控对视频场景的实时理解需求以及车辆轨迹的时序性特征提出一种基于HMM的车辆轨迹实时判别方法,该方法总体上包含两个过程:1)对车辆运行轨迹的分段预处理;2)在此基础上的车辆行为识别.在车辆运行轨迹的预处理过程中,首先提出一种基于轨迹长度的去不完整轨迹序列方法,同时对车辆轨迹点序列进行线性平滑滤波处理,在此基础上进行了基于最小二乘拟合的车辆轨迹拟合;在车辆行为的识别过程中,首先提出一种基于车辆运行轨迹点序列方向角的车辆轨迹特征值表示方法,在此基础上提出一种基于方向角区间划分法的HMM观察

值序列的生成方法,该方法以方向角的区间变化来区分不同轨迹模式的特征,进而实现对运行车辆行为的识别.大量的仿真试验验证了所提出方法的有效性.

## 1 车辆运行轨迹点序列的预处理

与轨迹的静态识别不同,车辆运行轨迹的实时识别是在车辆的行驶过程中来判断车辆的行驶状态,即当前时刻车辆的行驶判别状态不一定代表针对该车辆完整轨迹的最终行驶判别状态.车辆的运动轨迹可以用车辆在多个视频帧的质心坐标点 $(x, y)$ 来表示.对于目标车辆,设第 $i$ 帧时其质心位置的坐标为 $(x_i, y_i)$ , $l$ 帧后就可以得到一个由 $l$ 个坐标点组成的初始序列(见式(1)),用以表示目标车辆走过 $l$ 帧的轨迹.并定义该轨迹的长度为 $l$ .

$$L_{\text{initial}} = \{(x_1, y_1), (x_2, y_2), \dots, (x_l, y_l)\} \quad (1)$$

在实际应用中通常进行等帧间隔采样来获取车辆的质心坐标点.由于视频帧频率固定,也可认为质心坐标点是通过等时间间隔 $\Delta t$ 采样获得,那么轨迹序列 $L$ 就转化为一个具有时间先后关系的点序列, $(x_i, y_i)$ 称为车辆在 $i$ 时刻的轨迹点.

车辆质心坐标点位置需要通过车辆跟踪而确定,而在车辆跟踪过程中通常会出现跟踪失败、跟踪错误等情况,因此所获取的轨迹序列可能是跟踪不完整的或者带有很多噪声的轨迹点序列,这样的轨迹点序列会对进一步的轨迹特征提取、训练和分类识别等造成很大影响,因此有必要在轨迹特征提取之前对轨迹进行相关的预处理操作,以保证所获得轨迹序列的有效性.本文的轨迹预处理过程包括以下三方面的工作:

### 1) 去不完整轨迹序列

在车辆轨迹点的跟踪过程中,统计所获取的轨迹序列 $L$ 上轨迹点的个数 $l'$ ,如果 $l'$ 小于设定的阈值(该阈值可根据后面轨迹特征训练模型所需要的最低特征点数通过统计获得),则将该序列看作是不完整的轨迹序列,放弃对其进行随后的处理.通过去除这些不完整的轨迹序列,降低了后续处理的计算量,同时也将提高对有效轨迹序列训练和识别的精准性.

### 2) 轨迹序列的平滑去噪处理

尽管通过等帧间隔采样可以在一定程度上避免得到过多的冗余轨迹点,但帧间的不稳定特性仍然会使所获得的采样点中存在着不能正确反映车辆运行趋势的噪声轨迹点,为此本文采用线性均值滤波的方法对轨迹序列进行如下的平滑去噪处理:

对于形如式 (1) 的车辆轨迹点序列, 按照式 (2) 对点  $(x_i, y_i)$  进行滤波处理:

$$\begin{cases} x_i = \sum_{j=i-adj}^{i+adj} \frac{x_j}{2 \times adj + 1} \\ y_i = \sum_{j=i-adj}^{i+adj} \frac{y_j}{2 \times adj + 1} \end{cases}, \quad adj \leq i \leq 1 - adj \quad (2)$$

其中,  $adj$  为滤波邻域, 本文实验中选其值为 3.

### 3) 轨迹点序列的拟合

对于平滑去噪处理的轨迹点, 进行如下基于最小二乘法分段拟合, 拟合函数  $y = f(x)$  采用三次多项式函数, 拟合后的对应轨迹点序列参见式 (3).

$$L_{fit} = \{(x_1, f(x_1)), (x_2, f(x_2)), \dots, (x_l, f(x_l))\} \quad (3)$$

对轨迹点的拟合不仅可以进一步去除线性平滑后仍然可能存在的噪声点, 更准确地描述车辆的行驶趋势, 同时也为进一步有效地提取轨迹特征参数奠定了基础.

## 2 车辆轨迹的特征参数提取

视频中不同车辆行驶所产生的方向信息可以很好地描述车辆轨迹的几何形状信息, 可以作为区分车辆间运行模式的一个重要特征. 本文通过利用车辆运行轨迹序列中相邻的轨迹点所形成的方向角来描述车辆行驶的特征参数.

设在获取的轨迹点序列  $L'$  中相邻两轨迹点坐标为  $(x_i, y_i)$  和  $(x_{i+1}, y_{i+1})$  ( $i \in [1, l-1]$ ), 则由  $(x_i, y_i)$  与  $(x_{i+1}, y_{i+1})$  所形成的运动方向角通过式 (4) 获得, 其中,  $y_i = f(x_i)$ ,  $y_{i+1} = f(x_{i+1})$ ,  $\theta$  ( $\theta \in [0, 2\pi]$ ) 是所形成的方向角度. 图 1 给出了方向角度映射在视频屏幕坐标系中的几何含义.




图 1 方向角度映射在视频屏幕坐标系中的情况

Fig.1 The direction angle mapping coordinate system in the video screen

$$\theta_i = \begin{cases} \arctan\left(\frac{y_{i+1} - y_i}{x_{i+1} - x_i}\right), & y_{i+1} - y_i > 0 \\ \frac{\pi}{2}, & y_{i+1} - y_i > 0 \text{ 且 } x_{i+1} - x_i = 0 \\ \arctan\left(\frac{y_{i+1} - y_i}{x_{i+1} - x_i}\right) + 2\pi, & y_{i+1} - y_i \leq 0 \\ \frac{3\pi}{2}, & y_{i+1} - y_i \leq 0 \text{ 且 } x_{i+1} - x_i = 0 \end{cases} \quad (4)$$

进一步, 利用所获的方向角  $\theta_1$ , 形成如式 (5) 所示的车辆运行轨迹的特征值序列  $L_\theta$ :

$$L_\theta = \{\theta_1, \theta_2, \dots, \theta_{l-1}\} \quad (5)$$

## 3 基于 HMM 的车辆行驶状态判别

HMM 是一种基于参数表示的描述随机过程统计特性的概率模型<sup>[11-13]</sup>, 通常由马尔科夫链和一般随机过程两部分构成, 前者用于描述状态的转移, 后者则用以描述状态与观察值序列间的关系.

在实际特定交通场景的交通视频中, 不同时刻的车辆具有不同的行驶状态, 从而产生不同的轨迹模式. 本文将在时域范围内对车辆的轨迹状态进行建模, 并通过其观察值序列来判定车辆的行驶状态.

考虑到车辆的当前行驶状态通常只与其前一时刻的状态有关, 这样将采用马尔可夫链来描述车辆行驶状态的变化, 车辆行驶过程中每个状态可能产生的轨迹模式观察值序列, 可以认为是 HMM 的一般随机过程.

### 3.1 HMM 的形式化定义

HMM 可以定义为一个五元组  $\lambda(X, O, \pi, A, B)$ , 其中五个参数的含义如下:

1)  $X = \{S_1, S_2, \dots, S_N\}$  代表一组马尔科夫状态的集合, 其中  $N$  为状态个数, 状态之间可以相互转换, 可把  $t$  时刻马尔科夫链处于状态  $S_i$  表示成  $q_t$  的形式:  $q_t = S_i$  ( $1 \leq i \leq N$ ).

2)  $V = \{V_1, V_2, \dots, V_T\}$  是  $T$  个相互独立的观察值符号组成的序列, 其中  $T$  表示序列中观察值的个数, 也代表序列的长度. 在时域范围内  $V$  可等价于按照时间先后次序排列的观察值集合.

3)  $A = \{a_{ij}\}_{N \times N}$  ( $1 \leq i, j \leq N$ ) 表示从  $t$  时刻的状态  $S_i$  转向  $t+1$  时刻的状态  $S_j$  的状态转移概率分布矩阵, 即:  $a_{ij} = P\{q_{t+1} = S_j | q_t = S_i\}$ , 且满足:

$$\sum_{j=1}^N a_{ij} = 1, \quad a_{ij} \geq 0$$

HMM 模型中利用参数  $A$  来描述马尔科夫链中状态的转移.

4)  $B = \{b_{S_i}(V_k)\}_{N \times M}$  是  $t$  时刻在状态  $S_i$  下取得相应观察值  $V_k$  的概率所构成的离散型概率分布矩阵, 即:  $b_{S_i}(V_k) = P\{V_k|q_t = S_i\}$ , 且满足:  $\sum_{m=1}^M b_{S_i}(V_k)_m = 1$ . 其中,  $b_{S_i}(V_k) \geq 0$ ,  $1 \leq k \leq T$ ,  $V_k \in V$ ,  $1 \leq V_k \leq M$ ,  $M$  是矩阵  $B$  的列数, 也是观察值序列  $V$  中所允许的最大观察值.

HMM 模型中利用参数  $B$  来描述一般随机过程中状态与观察值序列间的关系.

5)  $\pi = (\pi_1, \pi_2, \dots, \pi_N)$  表示初始状态概率分布向量, 其中  $\pi_i = P\{q_1 = S_i\}$  ( $1 \leq i \leq N$ ) 表示初始时刻时马尔科夫链处于状态  $S_i$  的概率, 满足:

$$\sum_{i=1}^N \pi_i = 1, \pi_i \geq a_0$$

### 3.2 HMM 观察值序列的生成

观察值序列是 HMM 进行正确训练和识别的前提. 本文采用方向角区间划分编码方法将车辆轨迹的特征方向角序列  $L^\theta$  映射成适合 HMM 处理的观察值数据形式.

#### 1) 方向象限的划分

根据前面第 2 节方向角的计算方法及其几何含义, 我们以视频帧左下角为总基准点, 以当前车辆的质心为中心点从水平位置开始, 按逆时针方向每隔  $\pi/2$  确定一个方向, 这样可以将方向角的范围  $[0, 2\pi]$  在屏幕坐标系中划分为  $D_1$ 、 $D_2$ 、 $D_3$  和  $D_4$  四个区域 (参见图 2). 如果将这四个方向区域分别对应于直角坐标系中的四个象限, 则  $D_1$ 、 $D_2$ 、 $D_3$  和  $D_4$  可看成是四个方向象限, 即若车辆轨迹的方向角落入到某一象限区域, 则该车辆在视频中可认为是沿着该象限方向进行行驶.

进一步, 将车辆行驶过程中隐状态解释为当前




图 2 方向象限的划分

Fig. 2 The division of directional quadrant

时刻车辆的位置是落在相对其前一时刻位置的哪个方向象限中. 这样, 将直行模式的状态数  $N$  确定为 1 就意味着车辆当前时刻的位置与其前一时刻的位置处于同一个方向象限中; 而转向的状态数  $N$  为 4 就意味着车辆当前时刻的位置可以落在相对其前一时刻位置的任意四个方向象限中.

#### 2) 方向象限的细分

按照上述方向象限的划分, 可通过方向角所属象限区间的变化来判断车辆的转向. 图 3 给出了车辆首先沿  $D_1$  方向, 继而沿  $D_2$  方向行驶的示例.




图 3 车辆轨迹的方向象限转化示例

Fig. 3 The transformation of the directional quadrant about the vehicle trajectory

然而, 上述方向划分存在的一个问题是不能始终说明沿着一个方向行驶的车辆就是属于直行模式. 如图 4 所示, 虽然车辆始终沿着  $D_1$  方向行驶, 但根据视频场景中路口的弯曲程度, 车辆很可能已经发生了转向行为.




图 4 车辆单方向轨迹的转向行为示例

Fig. 4 The behavior sample of the vehicle trajectory in single direction

为了保证对车辆轨迹行为识别的准确性, 需要对前面的方向象限进行细分, 一般而言, 分的越细, 识别的精度会越高. 考虑到实时性需求, 本文对每个  $D_i$  ( $i = 1, \dots, 4$ ) 进一步细划分成两个小方向区域  $D_{i,1}$  和  $D_{i,2}$ , 即每隔  $\pi/4$  确定一个方向区域, 将整个屏幕坐标系划分为八个方向 (参见图 5). 细分后的方向区域保证了始终沿着一个方向行驶的车辆属于直行模式.




图 5 方向象限的细分

Fig. 5 The subdivision of directional quadrant

### 3) 方向区域编码

在确定好方向划分后, 沿逆时针方向依次对每一个方向区间进行编码, 即每一个方向区域均有唯一一个码字与之相对应 (参见式 (6)).

$$\begin{cases} D_{1,1} \sim 1, & D_{1,2} \sim 2 \\ D_{2,1} \sim 3, & D_{2,2} \sim 4 \\ D_{3,1} \sim 5, & D_{3,2} \sim 6 \\ D_{4,1} \sim 7, & D_{4,2} \sim 8 \end{cases} \quad (6)$$

这样对于由式 (5) 所形成的运行轨迹的特征值序列  $L_\theta$ , 可通过式 (6) 将每一个方向角  $\theta_i$  ( $i = 1, \dots, l-1$ ) 唯一编码为相应的码字, 从而形成如式 (7) 所示的 HMM 观察值序列, 其中  $V_i$  是与  $\theta_i$  相对应的码字,  $V_i \in \{1, 2, \dots, 8\}$  ( $i = 1, \dots, l-1$ ).

$$V = \{V_1, V_2, \dots, V_{l-1}\} \quad (7)$$

## 3.3 HMM 拓扑结构及初始模型

### 1) 拓扑结构选择

特定的交通视频场景有其特定的道路交通状况, 但在每种路况下, 车辆从当前时刻到下一时刻的行驶状态间的转移都是随机的, 据此本文选择如图 6 所示的各态经历 (全遍历) 的 HMM 拓扑结构作为车辆轨迹的模型. 假设车辆行驶存在 4 个隐状态, 则

规定车辆行驶状态的转移可以由当前时刻的状态转向下一时刻的任何一个状态, 或若干时刻连续停留在同一个状态上.




图 6 车辆轨迹的各态经历的 HMM 拓扑结构示意图

Fig. 6 HMM topology diagram of the state of vehicle trajectory

### 2) 初始 HMM 模型

HMM 的初始化就是确定 HMM 模型五元组参数的初始值. 本文根据车辆轨迹的复杂程度及第 3.2 节中车辆轨迹特征方向角的区间细分情况, 将视频中直行的轨迹模式规定其隐状态数  $N$  为 1, 有转向的轨迹模式规定其隐状态数  $N$  为 4; 观察值的个数  $M$  均确定为 8; 对于观察值序列长度  $T$  的选取, 应考虑能够充分描述出视频内车辆的轨迹特征, 实验中选取  $T$  的值为 25.

假设所有车辆均从初始状态出发, 并按所选择的 HMM 拓扑结构逐步转移, 最终停留在末状态. 这样当状态数为  $N$  时, 初始状态概率分布向量  $\pi$  可选取为:  $\pi = (1, 0, \dots, 0)_{N \times 1}^T$ ; 对于  $N \times N$  的状态转移概率矩阵  $A$ , 本文所选取的各状态经历的 HMM 拓扑结构决定了初始隐马尔科夫状态矩阵由当前时刻的隐状态等概率地转向下一时刻任何一个隐状态. 直行的轨迹模式的隐状态数  $N$  为 1, 则其  $A$  矩阵的初始概率分布初始化为如下形式:

$$A = [1.0]_{1 \times 1}$$

转向的轨迹模式的隐状态数  $N$  为 4, 相应地初始化其  $A$  矩阵的概率分布为如下形式:

$$A = \begin{bmatrix} \frac{1}{4} & \frac{1}{4} & \frac{1}{4} & \frac{1}{4} \\ \frac{1}{4} & \frac{1}{4} & \frac{1}{4} & \frac{1}{4} \\ \frac{1}{4} & \frac{1}{4} & \frac{1}{4} & \frac{1}{4} \\ \frac{1}{4} & \frac{1}{4} & \frac{1}{4} & \frac{1}{4} \end{bmatrix}_{4 \times 4}$$

对于  $N \times M$  的输出概率矩阵  $B$ , 本文根据不同轨迹模式的先验特性来确定其初始概率分布. 对于视频中沿着一定方向直行的轨迹模式 (如图 5 沿着  $D_1$  方向直行的车辆), 根据直行隐状态数  $N$  和观察值个数  $M$  的选取, 其  $B$  矩阵的规模是  $1 \times 8$ , 由于它只可能输出编码为 1 或 2 的两个观察值, 因此可把沿  $D_i$  方向行驶的轨迹模式的  $B$  矩阵的初始概率分布设定为如下形式:

$$B = \begin{bmatrix} 1 & 2 & 3 & 4 & 5 & 6 & 7 & 8 \\ 0.5 & 0.5 & 0.0 & 0.0 & 0.0 & 0.0 & 0.0 & 0.0 \end{bmatrix}_{1 \times 8}$$

即在当前状态下, 以等概率得到编码为 1 或 2 的两个观察值. 沿着其他方向直行的轨迹模式  $B$  矩阵的初始概率分布的设定可依此类推; 对于视频中有转向的轨迹模式 (如图 5 中先沿着  $D_3$  方向继而沿着  $D_2$  方向行驶的车辆), 根据转向隐状态数  $N$  和观察值个数  $M$  的选取, 其  $B$  矩阵的规模是  $4 \times 8$ , 但其只可能输出编码为 3, 4, 5, 6 的四个观察值, 因此可将此轨迹模式的  $B$  矩阵设定为

$$B = \begin{bmatrix} 1 & 2 & 3 & 4 & 5 & 6 & 7 & 8 \\ 0.0 & 0.0 & \frac{1}{4} & \frac{1}{4} & \frac{1}{4} & \frac{1}{4} & 0.0 & 0.0 \\ 0.0 & 0.0 & \frac{1}{4} & \frac{1}{4} & \frac{1}{4} & \frac{1}{4} & 0.0 & 0.0 \\ 0.0 & 0.0 & \frac{1}{4} & \frac{1}{4} & \frac{1}{4} & \frac{1}{4} & 0.0 & 0.0 \\ 0.0 & 0.0 & \frac{1}{4} & \frac{1}{4} & \frac{1}{4} & \frac{1}{4} & 0.0 & 0.0 \end{bmatrix}_{4 \times 8}$$

即在当前状态下, 以等概率得到编码为 3, 4, 5, 6 的四个观察值. 沿着其他方向转向的轨迹模式  $B$  矩阵的初始概率分布的设定可依此类推.

规定了上述 HMM 模型参数的初始值后, 就得到了系统的一个初始 HMM 模型  $\lambda$ .

本文的目的正是要利用轨迹模式的观察值序列去判定车辆的行驶状态, 所以利用状态不可见的隐马尔科夫模型可以合理地对轨迹模式进行建模, 并达到识别的目的. 本节首先对 HMM 参数的基本定义进行描述, 其次分析了系统对 HMM 拓扑结构的选择及初始化方式, 最后重点提出了本文利用轨迹训练和判别的 HMM 模型观察值序列的生成方式.

### 3.4 HMM 样本轨迹的训练

在交通规则约束下每个交通路段所允许的车辆行驶状态模式数是确定的, 本文根据当前视频场景中交通规则所允许的车辆行驶状态进行轨迹模式类划分, 并为每一个轨迹模式类训练相应的 HMM 模型. 根据视频场景中车辆行驶轨迹间的独立特性,

采用多观察值序列下的 Baum-Welch 算法<sup>[14-17]</sup> 进行轨迹模式训练.

#### 1) Baum-Welch 算法的训练过程

基于 Baum-Welch 算法的训练过程就是对 HMM 模型参数不断迭代重估, 最终得到一个最优模型的过程, 其参数  $\pi$ 、 $A$  和  $B$  的迭代重估公式如式 (8) 所示:

$$\left\{ \begin{aligned} \hat{\pi}_i &= \frac{\sum_{l=1}^L \gamma_l(S_i)}{\sum_{l=1}^L \sum_{t=1}^{T-1} \delta_t(S_i, S_j)}, & 1 \leq i \leq N, \hat{\pi}_i \in \pi \\ \hat{a}_{ij} &= \frac{\sum_{l=1}^L \sum_{t=1}^{T-1} \delta_t(S_i, S_j)}{\sum_{l=1}^L \sum_{t=1}^T \gamma_t(S_i)}, & 1 \leq i, j \leq N, \hat{a}_{ij} \in A \\ \hat{b}_{S_i}(V_k) &= \frac{\sum_{l=1}^L \sum_{t=1, V_k}^T \gamma_t(S_i)}{\sum_{l=1}^L \sum_{t=1}^T \gamma_t(S_i)}, & 1 \leq i \leq N, \hat{b}_{S_i}(V_k) \in B \end{aligned} \right. \quad (8)$$

其中,  $\gamma_t(S_i)$  表示  $t$  时刻处于状态  $S_i$  下的概率.

$$\gamma_t(S_i) = \frac{\gamma_t(S_i)}{\sum_{j=1}^N \partial_t(S_j) \beta_t(S_j)}, \quad 1 \leq t \leq T, 1 \leq i \leq N \quad (9)$$

$\delta_t(S_i, S_j)$  表示  $t$  时刻处于状态  $S_i$ ,  $t+1$  时刻处于状态  $S_j$  的概率.

$$\delta_t(S_i, S_j) = \frac{\partial_t(S_i) \hat{a}_{ij} b_{S_j}(V_{t+1}) \beta_{t+1}(S_j)}{\sum_{i=1}^N \sum_{j=1}^N \partial_t(S_i) \hat{a}_{ij} b_{S_j}(V_{t+1}) \beta_{t+1}(S_j)}, \quad 1 \leq t \leq T \quad (10)$$

式中,  $\partial_t(S_i)$  由 Baum-Welch 前向算法迭代计算得到:

$$\left\{ \begin{aligned} \partial_1(S_i) &= \hat{\pi}_i b_{S_i}(V_1) \\ \partial_{t+1}(S_j) &= \sum_{i=1}^N \partial_t(S_i) \hat{a}_{ij} b_{S_j}(V_{t+1}) \\ 1 \leq i, j \leq N, & \quad 1 \leq t \leq T-1 \end{aligned} \right. \quad (11)$$

$\beta_t(S_i)$  由 Baum-Welch 后向算法迭代计算得到:

$$\begin{cases} \beta_T(S_i) = 1 \\ \beta_t(S_i) = \sum_{j=1}^N \hat{a}_{ij} b_{S_j}(V_{T+1}) \beta_{t+1}(S_j) \\ 1 \leq t \leq T-1, 1 \leq i \leq N \end{cases} \quad (12)$$

以上式 (11) 和式 (12) 通过循环迭代计算  $\partial_t(S_i)$  和  $\beta_t(S_i)$ , 由于  $\partial_t(S_i)$  和  $\beta_t(S_i)$  均是数值小于 1 的变量, 因此,  $\partial_t(S_i)$  随着  $t$  的增加和  $\beta_t(S_i)$  随着  $t$  的减小都将迅速趋于零值, 那么在 HMM 训练的过程中就面临着数据下溢的问题. 为了解决该问题, 需要采取如式 (13) 对  $\partial_t(S_i)$  和  $\beta_t(S_i)$  的计算增加比例因子  $\omega_t$  的方法.

$$\begin{cases} \partial_1(S_i) = \frac{\hat{\pi}_i b_{S_i}(V_1)}{\sum_{i=1}^N \hat{\pi}_i b_{S_i}(V_1)} \\ \omega_{t+1} = \sum_{j=1}^N \left( \sum_{i=1}^N \partial_t(S_j) \hat{a}_{ij} \right) b_{S_j}(V_{t+1}) \\ \partial_{t+1}(S_j) = \frac{\sum_{i=1}^N (S_j) \hat{a}_{ij} b_{S_j}(V_{t+1})}{\omega_{t+1}} \\ \beta_T(S_i) = \frac{1}{\omega_T} \\ \beta_t(S_i) = \frac{\sum_{j=1}^N \hat{a}_{ij} b_{S_j}(V_{t+1}) \beta_{t+1}(S_j)}{\omega_t} \\ 1 \leq i, j \leq N, 1 \leq t \leq T-1 \end{cases} \quad (13)$$

## 2) 轨迹模式类训练算法的实现

训练的总体过程是对于某一轨迹模式类, 收集若干轨迹段样本形成样本集, 再根据该轨迹模式类的特征为其初始一个 HMM 模型, 最后利用样本集进行训练. 具体的轨迹模式类训练过程如下:

**步骤 1.** 已知轨迹模式类  $c_1$  的训练样本集, 其中包含  $L$  条轨迹段, 即  $L$  个观察值序列,  $n$  表示迭代次数, 初始  $n = 1$ .

**步骤 2.** 开始对第  $l$  个观察值序列  $V^l = \{V_1^l, V_2^l, \dots, V_T^l\}$  的训练, 初始  $l = 1, 1 \leq l \leq L$ .

**步骤 3.** 在给定观察值序列  $V^l$  及模型  $\lambda$  参数后 (第 1 次迭代为初始化的  $\lambda$  模型参数), 利用式 (13) 计算前向变量  $\partial_t^l(S_i)$  和后向变量  $\beta_t^l(S_i)$ .

**步骤 4.** 利用式 (9) 和式 (10) 计算  $\gamma_t^l(S_i)$  和  $\delta_t^l(S_i, S_j)$ .

**步骤 5.** 遍历  $t$ , 累加  $\gamma_t^l(S_i)$  和  $\delta_t^l(S_i, S_j)$ , 暂存计算结果, 并返回步骤 2, 取下一个观察值序列进行

计算, 直到  $l = L$ .

**步骤 6.** 利用重估式 (8) 对模型参数进行重新估计, 得到新模型  $\lambda_{\text{new}}$ .

**步骤 7.** 判断模型参数迭代收敛条件, 利用前向概率进行模型评价, 前向概率的计算公式如下:

$$P(V|\lambda) = \log \sum_{i=1}^N \partial_t(S_i) \quad (14)$$

比较前后两次迭代计算得到前向概率  $P_{n-1}(V|\lambda)$  和  $P_n(V|\lambda_{\text{new}})$ .

**步骤 8.** 如果  $P_n(V|\lambda_{\text{new}}) - P_{n-1}(V|\lambda) < \text{threshold}$ , 则模型收敛, 得到轨迹模式类  $c_1$  的最优 HMM 模型, 开始下一个轨迹模式  $c_2$  的训练; 否则, 用新模型  $\lambda_{\text{new}}$  替换原模型  $\lambda$ , 迭代次数  $n++$ , 转至步骤 2, 开始下一次迭代.

训练结束后, 将得到视频场景中  $c_n$  个轨迹模式类的 HMM 模型  $\lambda(\lambda_{c_1}, \lambda_{c_2}, \dots, \lambda_{c_n})$ .

## 3.5 HMM 实时轨迹模式识别

识别的实时性体现在对轨迹的分段匹配, 即对进入视频的车辆, 每行驶一段就获取该段的轨迹点序列, 并进行实时预处理和方向区域编码形成观察值序列, 最后与轨迹点模式类进行匹配识别. 具体识别过程如下:

**步骤 1.** 初始化: 用  $G_s$  来记录当前车辆的所有采样点数,  $T_s$  记录当前待识别轨迹段的采样点数, 初始化  $T_s = G_s = 0$ .

**步骤 2.** 采集轨迹点: 累计当前视频中特定车辆的轨迹采样点数  $T_s$  和  $G_s$ , 如果  $T_s$  满足观察值序列的个数  $T$  ( $T$  可事先确定), 则对当前  $G_s$  个点做最小二乘拟合处理, 否则继续采集轨迹点.

**步骤 3.** 生成观察值序列: 以第  $G_s - T_s + 1$  采样点作为起始点, 提取拟合轨迹方程上的  $T_s$  个点  $\{(x_{G_s-T_s+1}, f(x_{G_s-T_s+1})), (x_{G_s-T_s+2}, f(x_{G_s-T_s+2})), \dots, (x_{G_s}, f(x_{G_s}))\}$ , 对这  $T_s$  个点计算方向角并编码, 形成该待识别轨迹段的观察值序列  $V = \{V_1, V_2, \dots, V_T\}$ .

**步骤 4.** 按照式 (14) 计算该观察值序列  $V = \{V_1, V_2, \dots, V_T\}$  对于训练好的所有模式类 HMM 模型  $\lambda(\lambda_{c_1}, \lambda_{c_2}, \dots, \lambda_{c_n})$  的前向概率  $P(V|\lambda_i)$ ,  $1 \leq i \leq c_n$ .

**步骤 5.** 寻找最大前向概率  $P(V|\lambda_i)$  的下标索引  $i$  对应的模型  $\lambda_i$  作为该段轨迹所属的模式类别, 至此完成对该车辆当前行驶状态的一次判别.

**步骤 6.** 若  $T_s$  未满足  $T$  时, 当前车辆已行驶出视频区域, 则结束对该车辆的判别工作; 否则轨迹段累计点数  $T_s$  清零, 返回步骤 2, 继续该车辆的下一

次行驶状态判别.

## 4 实验与分析

### 4.1 $X$ - $Y$ 坐标系定义及特征方向角获取

实验以摄像设备获取的一段交通视频为素材, 利用个人 PC 模拟视频监控端完成对车辆行驶状态的自动判别. 实验平台为 VC6.0, 并在其中配置 OpenCV 1.0, 以读取视频, 并获取视频帧图像.

在获取视频帧图像的基础上, 以屏幕的横向作为  $X$  轴, 纵向作为  $Y$  轴, 左下角为坐标  $(0,0)$  点, 以此形成  $X$ - $Y$  平面坐标系.

对于特征方向角的获取, 实验在  $X$ - $Y$  坐标系的基础上, 首先利用文献 [18] 基于 Mean shift 的卡尔曼粒子滤波车辆跟踪算法来确定车辆在不同视频帧的质心坐标点, 然后每隔 30 帧进行采样, 获得相应车辆的质心坐标点, 最后按照第 2 节式 (4) 计算车辆连续两次采样坐标点之间的方向角.

### 4.2 实验结果

为了验证所提出方法的有效性, 我们对大连市多个路口的交通视频车辆行驶状态进行了仿真实验. 实验视频参数如下: 尺寸为  $320 \times 240$ , 帧率为 15 fps, 编码 XVID. 观察值序列的长度  $T$  取为 25, 即每采样 26 个坐标点的轨迹段后, 进行一次识别操作, 每隔 780 帧, 显示一次跟踪车辆的行驶状态. 实验以车辆实际行驶生成的轨迹点序列作为相应轨迹模式类的训练样本数据. 由于实验所用视频素材中按照每一个轨迹模式行驶的实际车辆数目比较少, 甚至有一些轨迹模式类没有车辆行驶, 所以实验在训练轨迹模式类时, 每一轨迹模式类所采用的训练样本数量参照视频中按照这一轨迹模式行驶的车辆数目比例自行定义.

#### 1) 初始方向为多路口情况

图 7 给出了初始方向为多路口的视频场景, 其中场景道路上的 4 个箭头方向表示此路口按照交通规则允许的  $P1 \sim P4$  四种轨迹模式. 这四种模式类在实验中分别由 20 条车辆的实际运行轨迹训练得到. 图 8~11 分别显示了按照轨迹模式  $P1 \sim P4$  路线行驶的车辆每隔 780 帧的连续两次判别结果.

#### 2) 初始方向为单路口情况

图 12 给出了初始方向为单路口的视频场景, 其中  $C1 \sim C4$  是该种情况下交通规则允许的四种轨迹模式, 其中  $C1$  与  $C2$  归结为车辆直行情况, 训练时将二者归为同一个轨迹模式类  $C2$ . 由于实验视频中



图 7 初始方向为多路口的四种轨迹模式场景  
Fig. 7 Four kinds of trajectory models of initial direction for crossing situation



(a) 第 19 050 至 19 830 帧的判别结果  
(a) The results from 19 050 to 19 830 frames



(b) 第 74 610 至 75 390 帧的判别结果  
(b) The results from 74 610 to 75 390 frames

图 8 由西向北走向车辆行驶自动判别  
Fig. 8 The vehicle automatic identification from the west to the north

按照每种模式行驶的实际车辆数量多少不一, 并且无车辆以  $C4$  模式行驶, 这样模式类  $C2$  和模式类  $C3$  分别采用了 20 条样本轨迹点序列和 10 条样本轨迹点序列训练得到. 最终训练得到了该场景关于  $C2$  和  $C3$  的两个 HMM 轨迹模式类. 图 13 和图 14 展示了该视频中部分车辆行驶状态的判别结果.

#### 3) 夜间丁字路口情况

图 15 给出了夜间丁字路口的视频场景, 其中场景道路上的 6 个箭头方向表示此路口按照交通规则允许的  $S1 \sim S6$  六种轨迹模式, 其中  $S1$  与  $S2$  归结为车辆的直行情况, 训练时将二者归为同一个轨迹模式类  $S2$ . 由于实验视频段中无车辆以  $S4 \sim S6$



模式行驶, 故最终训练得到该场景的  $S_2$  和  $S_3$  两个 HMM 轨迹模式类, 其中  $S_2$  模式类和  $S_3$  模式类分别采用 20 条样本轨迹点序列和 10 条样本轨迹点序列训练得到。图 16 分别给出了该视频中部分车辆行驶状态的判别结果。



(a) 第 28 380 至 29 160 帧的判别结果  
(a) The results from 28 380 to 29 160 frames



(b) 第 89 460 至 90 240 帧的判别结果  
(b) The results from 89 460 to 90 240 frames

图 9 由西向北走向车辆行驶自动判别

Fig. 9 The vehicle automatic identification from the west to the north



(a) 第 32 580 至 33 360 帧的判别结果  
(a) The results from 32 580 to 33 360 frames



(b) 第 49 800 至 50 580 帧的判别结果  
(b) The results from 49 800 to 50 580 frames

图 10 由北向西走向车辆行驶自动判别

Fig. 10 The vehicle automatic identification from the north to the west



(a) 第 49 110 至 49 890 帧的判别结果  
(a) The results from 49 110 to 49 890 frames



(b) 第 52 020 至 52 800 帧的判别结果  
(b) The results from 52 020 to 52 800 frames

图 11 由北至南走向车辆行驶自动判别

Fig. 11 The vehicle automatic identification from the north to the south



图 12 初始方向为单路口的四种轨迹模式场景

Fig. 12 Four kinds of trajectory models of initial direction for single intersection



(a) 第 46 260 至 47 040 帧的判别结果  
(a) The results from 46 260 to 47 040 frames



(b) 第 69 780 至 70 560 帧的判别结果  
(b) The results from 69 780 to 70 560 frames

图 13 直行车辆行驶自动判别

Fig. 13 Vehicle automatic identification in straight vehicles



(a) 第 124 920 至 125 700 帧的判别结果  
(a) The results from 124 920 to 125 700 frames



(b) 第 229 740 至 230 520 帧的判别结果  
(b) The results from 229 740 to 230 520 frames

图 14 右转车辆行驶自动判别

Fig. 14 Vehicle automatic identification in right turn vehicles



图 15 夜间丁字口的六种轨迹模式场景

Fig. 15 Six kinds of trajectory models of initial direction for night intersection

### 4.3 实验分析

#### 1) 判别结果分析

以图 7 轨迹模式类  $P1$  为例, 本文通过第 3.4 节式 (2) 中步骤 1~8 的过程对  $P1$  由其对应的初始

HMM 模型开始训练, 最终得到的 HMM 模型  $\lambda_{P1}$  的各个参数变化如下: 即  $\lambda_{P1}(A, B, \pi)$  是对轨迹模式类  $P1$  训练后得到的最终 HMM 模型. 同理可得到  $P2 \sim P4$  轨迹模式类的最终 HMM 模型.



(a) 第 33 720 至 34 500 帧的判别结果  
(a) The results sfom 33 720 to 34 500 frames



(b) 第 36 330 至 37 110 帧的判别结果  
(b) The results from 36 330 to 37 110 frames

图 16 不同时段车辆行驶的自动判别

Fig. 16 Vehicle automatic identification in different time

以图 8(a) 和 8(b) 为例, 表 1 列出了图 8(a) 中 050 号车辆和图 8(b) 中 262 号车辆在行驶过程中产生的轨迹观察值序列与图 7 中  $P1 \sim P4$  四种轨迹模式的最终 HMM 模型按照式 (14) 计算得到的前向概率值.

表 1 行驶车辆与图 7 轨迹模式间的前向概率统计结果

Table 1 The probability statistics results between the vehicle trajectory and Fig. 7

车辆 ID	交通场景轨迹模式			
	$P1$	$P2$	$P3$	$P4$
050	-10.862	-12.507	-14.476	-11.740
050	-10.483	-12.326	-14.832	-11.627
262	-10.314	-12.273	-14.476	-11.549
262	-9.274	-12.893	-15.636	-10.224

从表 1 对前向概率值的统计结果可以得到, 050 号车辆和 262 号车辆与  $P1$  轨迹模式计算产生的前向概率值最大, 同时图 8(a) 和图 8(b) 将两车辆的当前行驶状态判别显示为  $P1$  模式. 将此判别结果与实际交通视频中两车辆的实时行驶状态进行对比, 表明对当前两车辆行驶状态的实时判别结果是正确的, 这说明了本文利用 Baum-Welch 的前向概率来

衡量车辆行驶状态判别结果的有效性. 同理, 按照式 (14) 统计计算图 9~16 中行驶的车辆与相应场景轨迹模式间的前向概率值均能得到以上的分析结论, 在此不再赘述.

## 2) 判别评价分析

我们采用正确率和查全率两种数值方法对车辆的实时行驶状态判别结果进行评价分析. 对于一个特定的轨迹模式类 SX, 行驶状态判别的正确率是指被准确识别为 SX 的轨迹点序列数与所有被识别为 SX 的轨迹点序列数的比值; 查全率是被准确识别为 SX 的轨迹点序列数与所有属于 SX 的轨迹点序列数的比值. 正确率  $\mu$  与查全率  $\eta$  的计算式为

$$\begin{cases} \mu = \frac{T_a}{T_a + T_b} \\ \eta = \frac{T_a}{T_a + T_c} \end{cases}$$

其中,  $T_a$  是所有被识别为 SX 并且实际也确实属于 SX 的轨迹点序列数,  $T_b$  是被识别为 SX 但实际并不属于 SX 的轨迹点序列数,  $T_c$  是未被识别为 SX 但实际却属于 SX 的轨迹点序列数.

由于实验结果可以得到对于车辆至少连续两次的行驶状态显示, 则在实验统计中把每次车辆的状态显示都作为一次独立的识别. 3 种实验情况的正确率和查全率的统计结果见表 2~4.

表 2 初始方向为多路口的统计结果

Table 2 The statistical results of initial direction for crossing situation

模式类	P1	P2	P3	P4
$T_a$	251	486	41	183
$T_a + T_b$	260	501	54	183
$T_a + T_c$	260	488	48	202
$\mu$ (%)	96.5	99.6	85.4	100
$\eta$ (%)	96.5	99.6	85.4	90.6

表 3 初始方向为单路口的统计结果

Table 3 The statistical results of initial direction for single intersection

模式类	C2 (C1)	C3	C4
$T_a$	132	13	—
$T_a + T_b$	135	17	—
$T_a + T_c$	136	16	—
$\mu$ (%)	97.8	76.4	—
$\eta$ (%)	97	81.3	—

综合图 7~16 的实验结果及表 2~4 对识别准确率和查全率的统计分析可以看出, 在有效地对行驶车辆进行检测和跟踪的基础上, 采用本文基于 HMM 的车辆行驶行为判别算法可以有效地实现对车辆行驶状态的判别.

表 4 初始方向为单路口的统计结果

Table 4 The statistical results of initial direction for single intersection

模式类	S2 (C1)	S3	S4	S5	S6
$T_a$	106	10	—	—	—
$T_a + T_b$	106	10	—	—	—
$T_a + T_c$	106	10	—	—	—
$\mu$ (%)	100	100	—	—	—
$\eta$ (%)	100	100	—	—	—

## 5 结论

本文提出一种基于 HMM 的交通视频车辆行驶状态实时判别的新算法. 算法首先对车辆运行轨迹进行了分段预处理, 对车辆运行轨迹进行了去不完整轨迹序列、对车辆轨迹点序列进行线性平滑滤波以及基于最小二乘拟合的车辆轨迹拟合等操作; 进一步, 提出一种基于车辆运行轨迹点序列方向角的车辆轨迹特征值表示方法, 通过对方向角区间细分获得车辆运行轨迹方向角的 HMM 观察值序列, 在此基础上通过对 HMM 样本轨迹的训练和模式识别实现对运行车辆行为的判定. 实验结果表明, 根据本文提出的算法可以实现对车辆行驶状态的各种模式进行有效的判别, 并可达到较高的正确率和查全率.

本文是根据轨迹模式类的特征在理想的交通路况下拟定的 HMM 模型初值, 并通过 Baum-Welch 算法训练, 但 Baum-Welch 算法对初值敏感以及其爬山式的迭代搜索方式使训练得到的最终 HMM 模型应对复杂特殊交通状况下车辆行驶状态的实时判别仍可能存在一定的误差, 因此有必要在 HMM 模型的初值选取以及 HMM 模型的训练算法上做进一步的改善和优化.

## 致谢

感谢大连市西岗区交通大队在实验视频图像方面所给予的帮助.

## References


- 1 Cuntoor N P, Yegnanarayana B, Chellappa R. Activity modeling using event probability sequences. *IEEE Transactions*

- on *Image Processing*, 2008, **17**(4): 594–607
- 2 Feng B L, Gao J, Lin S X, Zhang Y D, Tao K. Motion region-based trajectory analysis and re-ranking for video retrieval. In: *Proceedings of the 2009 IEEE International Conference on Multimedia and Expo*. New York, NY: IEEE, 2009. 378–381
  - 3 Wang Xiang-Hai, Fang Ling-Ling, Cong Zhi-Huan. Research on real-time multi-target tracking algorithm based on MSPF. *Acta Automatica Sinica*, 2012, **38**(1): 139–144 (王相海, 方玲玲, 丛志环. 基于 MSPF 的实时监控多目标跟踪算法研究. *自动化学报*, 2012, **38**(1): 139–144)
  - 4 Wang Kun-Feng, Li Zhen-Jiang, Tang Shu-Ming. Visual traffic data collection approach based on multi-features fusion. *Acta Automatica Sinica*, 2011, **37**(3): 322–330 (王坤峰, 李镇江, 汤淑明. 基于多特征融合的视频交通数据采集方法. *自动化学报*, 2011, **37**(3): 322–330)
  - 5 Wu Cong, Li Bo, Dong Rong, Chen Qi-Mei. Detecting traffic parameters based on vehicle clustering from video. *Acta Automatica Sinica*, 2011, **37**(5): 569–576 (吴聪, 李勃, 董蓉, 陈启美. 基于车型聚类的交通流参数视频检测. *自动化学报*, 2011, **37**(5): 569–576)
  - 6 Morris B T, Trovati M M. A survey of vision-based trajectory learning and analysis for surveillance. *IEEE Transactions on Circuits and Systems for Video Technology*, 2008, **18**(8): 1114–1127
  - 7 Buccolieri F, Distanti C, Leone A. Human posture recognition using active contours and radial basis function neural network. In: *Proceedings of the 2005 IEEE Conference on Advanced Video and Signal Based Surveillance, AVSS*. Como: IEEE, 2005. 213–218
  - 8 Dilruba R A, Chowdhury N, Liza F F, Karmakar C K. Data pattern recognition using neural network with back-propagation training. In: *Proceedings of the 2006 IEEE International Conference on Electrical and Computer Engineering, ICECE*. Dhaka: IEEE, 2006. 451–455
  - 9 Meyer D D, Sturm J, Burgard W. Regression-based online situation recognition for vehicular traffic scenarios. In: *Proceedings of the 2009 IEEE/RSJ International Conference on Intelligent Robots and Systems, IROS*. Piscataway, NJ, USA: IEEE Press, 2009. 1711–1716
  - 10 Jiu Y H, Sheng H, Chao L, Zhang X. Vehicle behavior understanding based on movement string. In: *Proceedings of the 12th International IEEE Conference on Intelligent Transportation Systems, ITSC*. St. Louis, MO: IEEE, 2009: 1–6
  - 11 Rabiner L R. A tutorial on hidden Markov models and selected applications in speech recognition. *Proceedings of the IEEE*, 1989, **77**(2): 257–286
  - 12 Mitchell T M [Author], Zeng Hua-Jun, Zhang Yin-Kui et al. [Translator]. *Machine Learning*. Beijing: Mechanical Industry Press, 2008 (米歇尔 [著], 曾华军, 张银奎等 [译]. *机器学习*. 北京: 机械工业出版社, 2008)
  - 13 Duda R O et al. [Author], Li Hong-Dong et al. [Translator]. *Pattern Classification* (2nd edition). Beijing: Mechanical Industry Press, 2003 (迪达等 [著], 李宏东等 [译]. *模式分类* (第 2 版). 北京: 机械工业出版社, 2003)
  - 14 Li X L, Parizeau M, Plamondon R. Training hidden Markov models with multiple observations — a combinatorial method. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2000, **22**(4): 371–377
  - 15 Jia Bin, Zhu Xiao-Yan, Luo Yu-Pin, Hu Dong-Cheng. Accurate Baum-Welch algorithm free from overflow. *Journal of Software*, 2000, **11**(5): 707–710 (贾宾, 朱小燕, 罗予频, 胡东成. 消除溢出问题的精确 Baum-Welch 算法. *软件学报*, 2000, **11**(5): 707–710)
  - 16 Chenshomi S, Rahati Q S, Akbarzadeh T. HMM training by a hybrid of chaos optimization and Baum-Welch algorithms for discrete speech recognition. In: *Proceedings of the 6th International Conference on Digital Content, Multimedia Technology and Its Applications, IDC*. Seoul: IEEE, 2010. 337–341
  - 17 Chen M, Madden M G, Liu Y. Refined learning of hidden Markov models with a modified Baum-Welch algorithm and informative components. In: *Proceedings of the 2010 IEEE International Conference on Progress in Informatics and Computing, PIC*. Shanghai, China: IEEE, 2010: 165–169
  - 18 Wang Xiang-Hai, Fang Ling-Ling, Cong Zhi-Huan. Research on video vehicle tracking algorithm based on Kalman and particle filter. *Journal of Image and Graphics*, 2010, **15**(11): 1616–1622 (王相海, 方玲玲, 丛志环. 卡尔曼粒子滤波的视频车辆跟踪算法研究. *中国图象图形学报*, 2010, **15**(11): 1616–1622)



of this paper.)

王相海 博士, 教授. 主要研究方向为多媒体信息处理和计算机图形学. 本文通信作者. E-mail: xhwang@lnnu.edu.cn (WANG Xiang-Hai Ph. D., professor. His research interest covers multimedia information processing and computer graphics. Corresponding author



丛志环 硕士研究生. 主要研究方向为智能图像处理. E-mail: czhwork@163.com (CONG Zhi-Huan Master student. Her main research interest is intelligent image processing.)



equations.)

方玲玲 博士, 讲师. 主要研究方向为智能交通信息处理及偏微分方程图像处理. E-mail: fanglingling1985@163.com (FANG Ling-Ling Ph. D., lecturer. Her research interest covers intelligent traffic image processing and image processing based on partial differential



秦钜鳌 硕士研究生. 主要研究方向为智能交通图像处理. E-mail: qjawork@126.com (QIN Ju-Ao Master student. His main research interest is intelligent traffic image processing.)