

本文引用格式: 刘林凡. 深度学习在故障诊断中的研究综述 [J]. 新型工业化, 2017, 17 (4): 45-48, 61.

DOI: 10.19335/j.cnki.2095-6649.2017.04.008

深度学习在故障诊断中的研究综述

刘林凡

(湖南工业大学, 湖南 株洲, 412007)

摘要: 深度学习在特征提取与模型拟合方面显示了其潜力和优势。对于特征提取精度要求高的故障诊断领域, 引入深度学习具有重要的意义。特征提取的精度决定着故障状态辨识的结果。许多学者将深度学习应用在故障诊断领域, 并取得不少的成果。本文介绍了深度学习在故障诊断中的研究现状, 总结了深度学习在故障诊断中的应用的研究现状和技术难点, 最后对深度学习在故障诊断中的研究进行了展望。

关键词: 深度学习; 故障诊断; 特征提取; 状态辨识; 综述

Review of Deep Learning In Fault Diagnosis

LIU Lin-fan

(Hunan University of Technology, Zhuzhou Hunan, 412007)

Abstract: Deep learning shows its potential and advantages in feature extraction and model quasi mediation. For high precision of feature extraction, it is of great importance to introduce depth learning in the field of fault diagnosis. The accuracy of feature extraction determines the results of fault state identification. Many scholars have applied deep learning to the field of fault diagnosis, and have achieved many results. This paper introduces the research status quo in fault diagnosis of deep learning, summarizes the research status of deep learning and technical difficulties in the application of fault diagnosis, finally the prospects of the study on deep learning in fault diagnosis.

Key words: Deep learning; Fault diagnosis; Feature extraction; State identification; Overview

Citation: LIU Lin-fan. Review of Deep Learning In Fault Diagnosis [J]. The Journal of New Industrialization, 2017, 17 (4): 45-48, 61.

0 引言

2006 年, Geoffrey Hinton 教授在《科学》上发表关于深度学习的文章, 开启了深度学习在学术界和工业界的浪潮^[1]。深度学习是机器学习的一个分支, 是神经网络的发展。深度学习采用分层结构, 系统由包括输入层、隐含层、输出层组成的多层网络, 只有相邻层节点之间有连接, 同一层以及跨层节点之间相互无连接, 每一层可以看作是逻辑回归模型^[2]。这种分层结构, 是比较接近人类大脑的结构。深度学习的概念源于人工神经网络的研究。多隐层的人工神经网络具有优异的特征学习能力, 学习得到的特征对数据有更本质的刻画, 从而有利于可视化或分类深度学习通过组合低层特征形成更加抽象的高层, 来表示属性类别或特征, 以发现数据的分布式特征表示。最为常用的主要有深度信念网络 (Deep Belief Nets, DBNs)、卷积神经网络 (Convolutional Neural Networks, CNN) 和堆叠自动编码器 (Stacked Auto-Encoders)^[3-5]。

设备的及时维修是建立在精准的故障诊断的基础上, 根据故障诊断的结果能够判断设备运行状态, 以便于工业生产中及时对故障设备进行维修。随着硬件技术的高速发展, 使得实时提取设备状态数据成

基金项目: 湖南工业大学研究生创新基金资助项目 (CX1707)

作者简介: 刘林凡 (1989-), 男, 硕士研究生, 主要研究方向: 研究方向为电力传动技术及其故障诊断;

为了可能。研究基于实时数据监控的故障诊断方法,对保障工业设备有效高速运行具有重要意义。近年来,深度学习在故障诊断方面得到了大量的学者关注,取得了不少的研究成果。本节将概述以上几种模型在故障诊断中的具体应用。

1 深度信念网络在故障诊断中的应用

DBN 由多个限制玻尔兹曼机 (Restricted Boltzmann Machines) 层组成,典型的神经网络类型如图 1 所示。这些网络被“限制”为一个可视层和一个隐层,层间存在连接,但层内的单元间不存在连接。隐层单元被训练去捕捉在可视层表现出来的高阶数据的相关性。

深度信念网络不需要人工特征提取与选择过程,通过网络特性刻画故障信

息的内部特征^[6]。避免了传统特征提取方法带来的问题。使得该方法的操作性强,提高了机器学习的智能水平。以深度信念网络为例,在故障诊断领域中,传统方法和深度信念网络方法比较模型如图 2 所示。




图 1 DBN 结构图

Fig. 1 DBN structure diagram

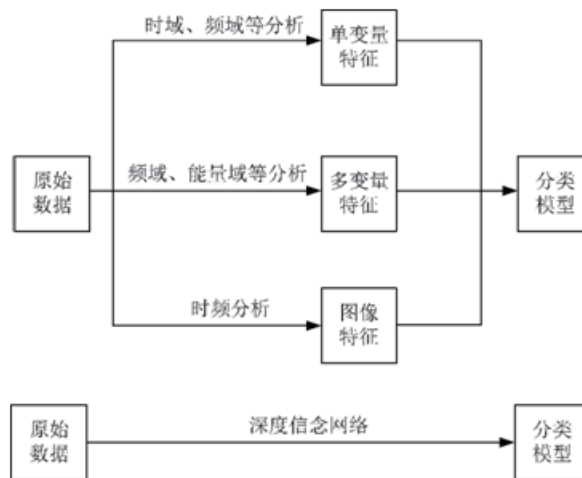


图 2 分析过程比较

Fig. 2 Comparison of analysis process

将获取的故障数据处理后获得原始数据,然后通过深度信念网络提取数据特征,再进行分类。谢吉鹏等^[7]将深度信念网络应用在高速列车行走部的故障诊断方面,通过获取振动数据,并进行基于深度信念网络的特征提取和故障诊断,取得了良好的效果。石鑫等^[8]获取电力变压器油中溶解气体的相关数据,提出采用深度信念网络构建分类模型,对变压器故障进行分类辨识,并验证了该方法在提取特征方面的优越性。

2 栈式自动编码网络在故障诊断中的应用

栈式自动编码网络是由多个自编码模块单元堆叠成的多层感知器神经网络^[9-10]。自编码模块是由编码层和解码层组成的两层神经网络,通过编码和解码的过程最大限度还原原始输入,自编码模块变换过程如图 3 所示。

张绍辉^[11]提出采用改进的栈式自编码模型对机械的轴承进行动态监测,并通过仿真实验证明该方法能够准确定位故障的位置。随着技术的发展,也有学者将堆叠降噪自动编码网络应用在故障诊断领域。堆叠降噪自动编码网络把降噪作为网络学习准则,训练时可在输入信号中加入不同类型、不同强度




图 3 自编码模块变换过程

Fig. 3 self coding module transformation process

的噪声,从被施加噪声的训练数据中学习,重构原始数据。因此其编码过程具有良好的稳定性和鲁棒性,在特征提取领域表现出优越性。朱煜奇等^[12]提出将堆叠降噪自动编码网络应用于设备故障诊断,证明了该方法泛化能力强,具有很好的鲁棒性。

3 卷积神经网络在故障诊断中的应用

卷积网络是为识别二维形状而特殊设计的一个多层感知器,这种网络结构对平移、比例缩放、倾斜或者其他形式的变形具有高度不变性。这些良好的性能是网络在有监督方式下学会的,网络的结构主要有稀疏连接和权值共享两个特点,包括如下形式的约束:(1)特征提取;(2)特征映射;(3)特征抽样。卷积神经网络的结构如图4所示。

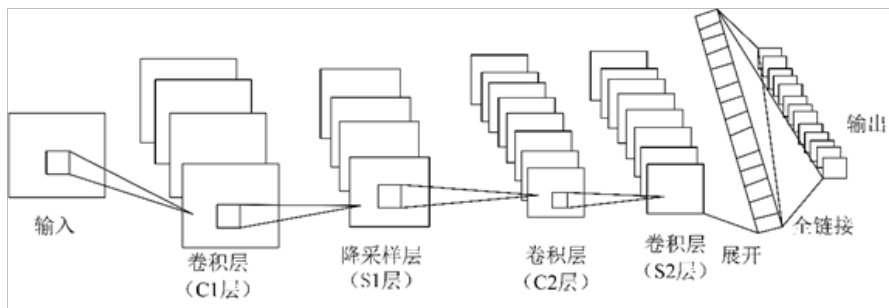


图4 CNN网络结构图

Fig. 4 CNN network structure diagram

卷积神经网络的分类包括训练和测试两个过程。用训练样本集对网络进行训练,再将测试样本集输入到训练好的网络中,测试网络的分类效果。曾雪琼等^[13]将卷积神经网络应用于振动信号时频图像的处理,实现了汽车变速器的故障分类识别。魏东等^[14]提出了采用逻辑回归分类器的卷积神经网络结构,解决了输电线路区内外故障判断和故障选相两类非独立分类问题,实现了两种非独立分类问题的权值共享。林颖^[15]提出了基于卷积递归网络的电流互感器红外故障图像诊断方法。

4 存在问题及技术展望

4.1 存在的问题

利用深度学习对故障进行诊断时,局限于已知故障类型数据的分类识别。对于新出现的故障深度学习模型则没有识别能力。逻辑回归分类器对于新出现的故障都会依据最大概率,将新出现的故障分类到已经获知的故障类型中。从而,影响故障诊断的精度^[16-17]。

深度学习在故障诊断领域的使用的难点在于参数的调整,参数选择影响着故障体征提取的精度,目前没有很系统的理论体系指导深度学习参数的调整^[18-20]。相关参数的调整,往往还需要根据实际经验选取。

深度学习训练耗时,模型正确性相对于机器学习而言,验证过程比较复杂,找出来的特征不够直观。故障诊断要求模型能够及时、快速地辨别故障的类型,这是深度学习方法在该方面的应用要克服的难点。

4.2 技术展望

在现阶段的研究中,有标签的数据特征学习占有重要位置,然而在故障诊断的实际应用中,故障数据的出现往往没有标签,并且数量巨大,掌握这些数据的标签是十分困难的事情。在不远的将来,随着数据集和存储技术的发展,无数据标签的数据特征学习,将会越来越被重视。如何智能自动的为数据添加标签将是研究的热点。

深度学习和其他方法组合使用,能够为深度学习在故障诊断领域的应用带来更高的精确度,深度强化学习,深度支持向量机和深度极限学习机等融合方法,具有一定意义。

在实际应用中的深度学习模型,远远低于当前最大的深度模型所包含的参数大约在100亿的数量级。深度学习模拟类似于人脑的结构,在巨大数据样本的情况下,更容易捕捉数据的特征,从而获得更高的分类准确率。因此,研究高精度的硬件设备,配合深度学习海量数据学习,将能够使深度学习性能更好的发挥出来。

5 总结

为打破深度学习在故障诊断领域的研究局限,本文对深度信念网络、堆栈式自编码和卷积神经网络在故障诊断领域的应用进行介绍。深度学习在语音识别、游戏和机器视觉领域的成功应用,带来了故障诊断前所未有的启发。故障诊断领域由深度强化学习带来质的飞跃。在未来的时间里,深度学习的思想和方法将会越来越多地被人们应用在故障诊断领域。故障诊断中的深度学习还有许多需要解决的问题,比如如何应对新出现的故障识别问题,参数调整的问题和如何快速验证模型的正确性。我们希望看到深度学习将广泛应用在与人们生活紧密相关的行业,比如智能出行和智慧医疗,服务人类。

参考文献

- [1] Lecun Y, Bengio Y, Hinton G. Deep learning[J]. Nature, 2015, 521 (7553): 436-444.
- [2] Schmidhuber J. Deep learning in neural networks: An overview[J]. Neural Networks the Official Journal of the International Neural Network Society, 2014, 61: 85-117.
- [3] Sun Y, Wang X, Tang X. Hybrid Deep Learning for Face Verification[J]. IEEE Transactions on Pattern Analysis & Machine Intelligence, 2016, 38 (10): 1997-2009.
- [4] Oberweger M, Wohlhart P, Lepetit V. Hands Deep in Deep Learning for Hand Pose Estimation[J]. Computer Science, 2016.
- [5] 段艳杰, 吕宜生, 张杰, 等. 深度学习在控制领域的研究现状与展望 [J]. 自动化学报, 2016, 42 (5): 643-654.
DUAN Yan-jie, LV Yi-sheng, ZHANG Jie, et al. Deep Learning for Control: The State of the Art and Prospects[J]. Acta Automatica Sinica, 2016, 42 (5): 643-654.
- [6] 耿志强, 张怡康. 一种基于胶质细胞链的改进深度信念网络模型 [J]. 自动化学报, 2016, 42 (6): 943-952.
GENG Zhi-qiang, ZHANG Yi-kang. An Improved Deep Belief Network Inspired by Glia Chains[J]. Acta Automatica Sinica, 2016, 42 (5): 643-654.
- [7] 谢吉朋. 云平台下基于深度学习的高速列车走行部故障诊断技术研究 [D]. 西南交通大学, 2015.
XIE Ji-peng. Research on Fault Diagnosis Technology of high-speed train running part based on deep learning under cloud platform[D]. Southwest Jiao Tong University, 2015.
- [8] 石鑫, 朱永利. 深度学习神经网络在电力变压器故障诊断中的应用 [J]. 电力建设, 2015, 36 (12): 116-122.
SHI Xin, ZHU Yongli. Application of Deep Learning Neural Network in Fault Diagnosis of Power Transformer[J]. Electric power construction, 2015, 36 (12): 116-122.
- [9] Xu J, Xiang L, Liu Q, et al. Stacked Sparse Autoencoder (SSAE) for Nuclei Detection on Breast Cancer Histopathology images[J]. IEEE Transactions on Medical Imaging, 2016, 35 (1): 119.
- [10] Tao C, Pan H, Li Y, et al. Unsupervised Spectral - Spatial Feature Learning With Stacked Sparse Autoencoder for Hyperspectral Imagery Classification[J]. IEEE Geoscience & Remote Sensing Letters, 2015, 12 (12): 2438-2442.
- [11] 张绍辉. 基于多路稀疏自编码的轴承状态动态监测 [J]. 振动与冲击, 2016, 35 (19): 125-131.
ZHANG Shao-hui. Bearing condition dynamic monitoring based on Multi-way sparse autocoder[J]. Journal of Vibration and Shock, 2016, 35 (19): 125-131.
- [12] 朱煜奇, 黄双喜, 杨天祺, 等. 基于栈式降噪自编码的故障诊断 [J]. 制造业自动化, 2017, 39 (3).
ZHU Yu-qi, HUANG Shuang-xi, YANG Tian-qi, et al. Fault diagnosis based on stacked denoising autoencoder[J]. Manufacturing Automation, 2017, 39 (3).
- [13] 曾雪琼. 基于卷积神经网络的变速器故障分类识别研究 [D]. 华南理工大学, 2016.
ZENG gang. Research on classification and identification of transmission faults based on convolutional neural network [D]. South China University of Technology, 2016.
- [14] 魏东, 龚庆武, 来文青, 等. 基于卷积神经网络的输电线路区内外故障判断及故障选相方法研究 [J]. 中国电机工程学报, 2016, 36 (S1):

(下转第61页)

- [17] 冯楠, 郭李娟, 符金伟, 等. 电力系统稳定器研究综述 [J]. 陕西电力, 2013, 41 (11): 45-50. FENG Nan, GUO Lijuan, FU Jinwei, et al. Research summary of power system stabilizer [J]. Shaanxi Electric Power, 2013, 41 (11): 45-50.
- [18] POULBEK P, GIBBARD M J. Simultaneous coordination of power system stabilizers and FACTS device stabilizers in a multimachine power system for enhancing dynamic performance[J] IEEE Trans on Power Systems, 1998, 13 (2): 473-479.
- [19] 杜文娟, 王海风, 曹军. PSS 就地相位补偿法的模型和理论 [J]. 中国电机工程学报, 2012, 32 (19): 36-41. DU Wenjuan, WANG Haifeng, CAO Jun. Model and theory of PSS localized phase compensation method[J]. Proceedings of the CSEE, 2012, 32(19): 36-41.
- [20] 刘志雄, 黎雄, 孙元章, 等. 广域 PSS 闭环控制工程中可变时滞及其处理 [J]. 电力系统自动化, 2013, 37 (10): 54-59. LIU Zhixiong, LI Xiong, SUN Yuanzhang, et al. Variable delay and its treatment in wide-area PSS closed-loop control engineering[J]. Automation of Electric Power Systems, 2013, 37 (10): 54-59.

(上接第 48 页)

21-28.

WEI Dong, GONG Qing-wu, et al. Study on fault diagnosis and fault phase selection in transmission line area based on convolutional neural network [J]. Proceedings of the CSEE, 2016, 36 (S1): 21-28.

- [15] 林颖, 郭志红, 陈玉峰. 基于卷积递归网络的电流互感器红外故障图像诊断 [J]. 电力系统保护与控制, 2015 (16): 87-94. LIN Ying, GUO Zhi-hong, CHEN Yu-feng. Convolutional-recursive network based current transformer infrared fault image diagnosis[J]. Power System Protection and Control, 2015, V43 (16): 87-94.
- [16] 叶森, 邓亮. 基于果蝇优化的压电执行器迟滞非线性神经网络建模 [J]. 新型工业化, 2017, 7 (1). YE Sen, DENG Liang. Modeling of Piezoelectric Actuator Hysteresis Nonlinear Neural Network Based on Fruit Fly Algorithm[J]. New Industrialization Strategy, 2017, 7 (1).
- [17] 吕锋, 李华, 李延忠, 等. 基于支持向量机的故障诊断方法研究 [J]. 新型工业化, 2015 (4): 34-39. LV Feng, LI Hua, LI Yan-zhong, et al. A Study of Fault Diagnosis Method Based on SVM[J]. New Industrialization Strategy, 2015 (4): 34-39.
- [18] Wang X, Gao L, Mao S. CSI Phase Fingerprinting for Indoor Localization With a Deep Learning Approach[J]. IEEE Internet of Things Journal, 2017, 3 (6): 1113-1123.
- [19] Qiu X, Ren Y, Suganthan P N, et al. Empirical Mode Decomposition based ensemble deep learning for load demand time series forecasting[J]. Applied Soft Computing, 2017, 54: 246-255.
- [20] Oh S W, Kim S J. Approaching the computational color constancy as a classification problem through deep learning[J]. Pattern Recognition, 2017, 61: 405-416.