

• 机电与自动化 •

金属露天矿旋回式破碎机在线故障 诊断模型构建与实时分析

顾清华¹ 田晶晶¹ 卢才武¹ 连民杰²

(1. 西安建筑科技大学管理学院, 陕西 西安 710055; 2. 中钢集团矿业开发有限公司, 北京 100000)

摘 要 矿石破碎是露天矿采矿生产工艺的重要环节, 旋回式破碎机作为露天矿进行破碎的大型设备, 其故障的诊断通常较为复杂, 难以利用主观经验进行精确及快速诊断。针对旋回式破碎设备的故障诊断问题, 利用传感器实时采集数据, 基于改进后 BP 神经网络构建故障诊断模型, 以偏心套故障、轴承磨损、平行轴缺油、平行轴油温异常作为故障类型, 以回流油温、润滑油油压、轴承振动频率、轴承转速作为故障特征参数, 利用已知故障类型和故障样本数据对 BP 神经网络故障诊断模型进行了训练和优化, 最后通过测试数据对优化后的旋回式破碎机故障诊断模型进行了验证。结果表明: 基于 BP 神经网络的故障诊断模型能够对旋回式破碎机故障状态实时地做出有效判断, 实现以预防为主的故障诊断方式, 满足了露天矿大型旋回式破碎机的故障诊断的需求。

关键词 露天矿 旋回式破碎机 故障诊断 BP 神经网络

中图分类号 TD451, TP183 文献标志码 A 文章编号 1001-1250(2017)-11-167-05

On-line Fault Diagnosis Model Construction and Real-time Analysis of Rotary Crusher in Metal Open-pit Mine

Gu Qinghua¹ Tian Jingjing¹ Lu Caiwu² Lian Minjie²

(1. College of Management, Xi'an University of Architecture and Technology, Xi'an 710055, China;

2. Sinosteel Mining Co., Ltd., Beijing 100080, China)

Abstract Ore crushing is an important link in mining production process of open-pit mines. As the large-scale device for the crushing of open-pit mines, in general, gyratory crusher's failure diagnosis is relatively complicated and it's hard to make accurate and rapid diagnosis based on subjective experience. Aiming at the failure diagnosis problem of gyratory crusher, real-time data collection is carried out through sensor and the failure diagnosis model is built up based on the improved BP neural network. Taking eccentric bushing failure, bearing wear, oil storage of parallel axis and abnormal oil temperature of parallel axis as the failure types and taking reflux oil temperature, lubricating oil pressure, bearing vibration frequency and revolving speed of bearing as the failure feature parameters, the training and optimization for the failure diagnosis model based on BP neural network are made by utilizing the known failure types and failure sample data. Finally, the optimized failure diagnosis model of gyratory crusher was verified according to the test data. The result indicated that the failure diagnosis model based on BP neural network could effectively judge the real-time failure state of gyratory crusher and the prevention-oriented failure diagnosis model could be realized, which satisfied the failure diagnosis demand of the large-scale gyratory crusher for open-pit mines.

Keywords Open pit mine, Rotary crusher, Fault diagnosis, BP neural network

在露天矿采矿生产中, 破碎是采矿生产工艺的重要环节, 一旦破碎设备出现故障会影响矿山的正常生产, 并给企业带来不小的损失及安全问题。目前大多数露天矿山多采用旋回式破碎机, 由于破碎机故障出现前难以用经验直接进行判断, 更无法实现对破碎设

备可能出现的故障类型提前预知, 破碎设备的重要部件往往采用定期更换的方式, 这样往往造成设备维修成本的增加以及停工损失。目前对于大型破碎机故障诊断研究相对较少, 所采用诊断方法大多以主观诊断为主, 主要依靠人员的经验来进行诊断, 如从破碎

收稿日期 2017-08-05

基金项目 国家自然科学基金项目(编号: 51774228, 51404182), 陕西省自然科学基金项目(编号: 2017JM5043), 陕西省教育厅专项科研计划项目(编号: 17JK0425)。

作者简介 顾清华(1981—), 男, 副教授, 博士, 硕士研究生导师。

机故障发生原因的角度出发,对破碎机的故障类型进行分析并得出发生故障的原因,在破碎过程中,集中对所发生原因加以观察和控制,来降低故障发生的可能性^[1-3]。但由于机械故障的复杂性及人类认知的有限性,使得主观诊断技术在故障诊断过程中的精度并不准确,为了弥补这一缺陷,特引入物联网和人工智能诊断技术,通过多传感器获取大型破碎设备的状态参数,利用人工智能构建设备故障诊断模型,学习破碎机故障的规律来提前对故障进行诊断预警。人工智能诊断技术主要有神经网络、专家系统、小波分析等^[4],其中利用神经网络非线性映射及自学习能力能够有效实现故障诊断,也越来越多地应用于故障诊断中。如禹建丽等^[5]提出了一种基于 BP 神经网络的变压器故障诊断方法,发现 BP 神经网络用于变压器诊断,具有结构简单、便于实际应用等优点;孙璐等^[6]提出了一种基于神经网络的信息融合故障诊断方法,并进行了实际检验,方法应用后可有效减少破碎机故障发生次数;孙永厚等^[7]利用模糊集对数据样本处理以减少冗余信息,简化神经网络结构,提高误差收敛速度,建立模糊集-BP 神经网络模型来解决垃圾破碎机的故障诊断。

总体来说,大型露天矿旋回式破碎机故障诊断的研究还是相对较少,利用 BP 神经网络进行旋回式破碎机故障诊断的研究更为少见。本研究针对旋回式破碎机故障原因复杂及难以诊断的情况,以旋回式破碎机为诊断对象,通过物联网传感器进行设备状态数据实时采集,确定旋回破碎机故障类型及相应的故障特征参数,利用改进后 BP 神经网络构建故障诊断模型,实现了旋回式破碎机故障的提前预知和实时精确诊断,大大节约了旋回式破碎设备的维修时间和维修成本,提高了露天矿采矿生产的实际生产率。

1 旋回式破碎机故障诊断模型

1.1 故障诊断模型原理

旋回式破碎机故障诊断模型基于 BP 神经网络实现的,BP 神经网络采用误差反向传播算法调整各层神经元之间的连接权值,通过调整连接权值,实现对非线性的学习,并且可以任意精度逼近任何非线性函数,故障诊断问题看作 BP 神经网络的模式识别问题,构建故障诊断模型主要是 4 部分:①数据采集及选取,②建立 BP 神经网络,③BP 神经网络训练,④旋回式破碎机故障诊断。

1.2 数据采集及选取

故障诊断模型是基于 BP 神经网络建立的模型,数据的有效性以及分布均匀性极大地影响了神经网络训练的结果,建立有效故障诊断模型的首要任务是

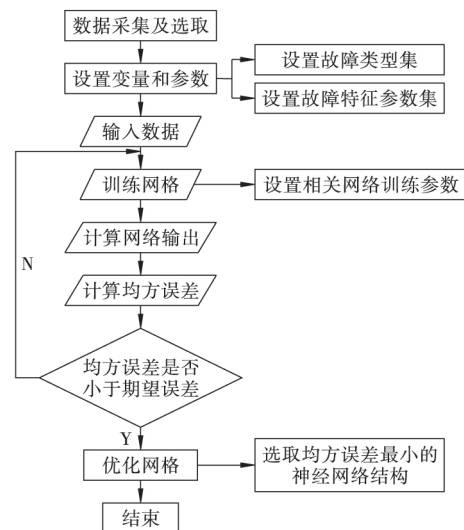


图 1 故障诊断模型建立流程

Fig.1 Establishing a fault diagnosis model flow

采集及选取有效数据,破碎机故障诊断中,故障类型 T 主要是偏心套故障 T_1 、轴承磨损 T_2 、平行轴缺油 T_3 、平行轴油温异常 T_4 ,故障类型集为

$$T = [T_1 \quad T_2 \quad T_3 \quad T_4],$$

故障特征参数 P 为回流油温 P_1 、润滑油油压 P_2 、轴承振动频率 P_3 、轴承转速 P_4 ,相对应的故障特征参数集为

$$P = [P_1 \quad P_2 \quad P_3 \quad P_4],$$

在采集数据过程中,采集数据手段为通过传感器进行实时采集,并在所采集原始数据中仅仅记录下故障数据;为了保证故障类型数据的均匀性,避免出现对于某类故障训练过多现象,要从采集的数据样本中进行选取,使得每个故障类型下具有相同数量的故障特征参数数据。

不同矿山开采强度和时间会影响到故障特征参数的大小,在每类故障下所对应的故障特征参数,其选取总体规则为满足开采强度和时间多样性,故障特征数据尽量分布于不同开采强度与时间,使得所选取的数据更具有覆盖性,模型更具有良好的合理性以及环境适应性^[8],能够更有效地学习并反映出故障规律。

1.3 BP 神经网络训练及优化

BP 神经网络训练流程主要是通过数据处理、建立 BP 神经网络、设置训练 BP 神经网络参数及训练网络、计算均方误差完成网络训练。

1.3.1 归一化处理

4 种故障特征参数数据具有不同量纲和物理意义,需要对数据进行归一化处理,使得样本数据在训练时处于同等地位,在同类数据中进行归一化,更能

保证数据精准性,在训练网络前对故障特征参数进行归一化,其中样本数据归一化处理主要通过调用 MATLAB 中 mapminmax 函数来实现的,输出层中故障类型是采用二进制编码加以处理如表 1 所示。

表 1 故障类型矩阵

Table 1 Fault type matrix

序号	故障类型矩阵	故障类型
1	[1 0 0 0]	偏心套故障
2	[0 1 0 0]	轴承磨损
3	[0 0 1 0]	平行轴缺油
4	[0 0 0 1]	平行轴油温异常

1.3.2 故障诊断网络的拓扑结构

旋回式破碎机故障诊断模型所应用的 BP 神经网络拓扑结构为 3 层神经网络,如图 2,选用具有一个隐含层的前向型神经网络;在故障诊断模型中,破碎机故障特征参数、故障类型分别作为神经网络的输入、输出,因此对应输入层神经元个数 $n=4$,输出层神经元个数 $l=4$ 。隐含层个数采用试凑法进行网络训练实验来确定隐含层个数及拓扑结构。




图 2 旋回式破碎机故障网络结构

Fig.2 Structure of the rotary crusher fault network

1.3.3 故障诊断网络训练

以归一化后的矩阵 P 作为输入数据,再写入目标输出数据 T ,根据网络拓扑结构,建立 BP 神经网络,调用 newff 函数建立网络,如: $\text{net} = \text{newff}(P, T, m, \{\text{'logsig'}, \text{'purelin'}\}, \text{'trainlm'})$, P 是输入数据, T 是目标输出, m 为训练中的隐含层神经元个数, logsig 函数是输入层至隐含层的传递函数,隐含层至输出层的传递函数为 purelin 函数,训练函数运用 L-M 法,利用 L-M 法可以实现误差快速收敛;在训练时对训练数据的划分进行重新定义,利用 dividerand 划分函数,设定每类数据的百分比,确定所需训练数据个数。

数据确定后通过设置训练网络参数来实现所需神经网络性能,主要对 net. epochs(训练迭代次数)、net. goal(训练目标精度值)、net. lr(学习速率)根据自身网络需要进行设置,选取 net. epochs = 500、net. lr = 0.01、net. goal = 0.01,其他的参数直接运用网络缺省值即可,所有参数设定完成后,对模型进行训练。

1.3.4 网络仿真模拟

网络训练完成后,要对训练效果进行仿真验证,通过调用仿真函数 sim 进行网络仿真得出实际输出,并利用函数 perform 计算实际输出与目标输出之间的均方误差(perf),以此来检查网络性能训练的好坏,判断网络训练好坏的关键是均方误差是否小于目标误差,旋回式破碎机故障诊断模型是应用于实际中破碎机的故障诊断,应该最大限度提高诊断模型的诊断精度,对诊断模型进一步地优化,可以通过改变隐含层个数来确定一个相对最优的网络模型。

1.3.5 网络结构优化

模型优化可以通过隐含层神经元个数的确定来达到优化模型的目的,隐含层神经元个数属于一个经验值,没有确定的理论值,采用试凑法来确定隐含层神经元个数,并在改变隐含层神经元个数过程中观察均方误差的大小,设隐含层神经元个数为 m ,在网络训练参数不变的前提下,参照经验公式计算隐含层神经元个数大致范围,经验公式主要是:

$$m = \log_2 n, \quad (1)$$

$$m > n - 1, \quad (2)$$

$$m < \sqrt{(l+n)} + a, \quad (3)$$

式中 n 、 l 分别是输入层及输出层神经元个数, a 是 0 ~ 10 之间的常数。

在隐含层神经元个数范围内,以 m_{\min} 为训练初始值,神经元个数每改变一次随之训练网络一次,训练后计算 perf,并对比所有隐含层神经元个数情况下的 perf 大小,确定 perf_{\min} 所对应的神经元个数为隐含层神经元个数。

2 实例分析

以洛阳某矿山的旋回式破碎机为例,通过传感器获取到 30 组故障数据,参照数据分布均匀性及有效性,选取 20 组数据作为训练样本,20 组训练样本是 4×20 维矩阵,体现了故障类型与故障特征参数相互映射关系,每个故障类型对应 5 组故障特征参数如表 2 所示。

以 MATLAB 为平台,对所选取的数据进行归一化处理如表 3,然后根据设置好的训练参数进行训练并计算均方误差,为有效地应用于实际中,对模型进行优化。

模型优化过程中根据 3 个经验公式,已知 $n=4$ 、 $l=4$,得知 $3 < m < 13$,即从 $m=4$ 开始进行训练,训练结束后,分别计算 $m=4, 5, 6, 7, 8, 9, 10, 11, 12$ 训练后的均方误差。训练后发现,任何隐含层神经元个数情况下,均方误差均小于期望误差,只要从中选取误差最

表 2 故障样本数据
Table 2 Fault sample data

故障类型	故障特征参数			
	轴承振动 频率(P_1)	轴承转速 (P_2)	回油油温 (P_3)	润滑油油 压(P_4)
偏心套故障(T_1)	8 391	590	43	0.360
偏心套故障(T_1)	8 424	587	45	0.340
偏心套故障(T_1)	8 733	591	40	0.370
偏心套故障(T_1)	8 036	590	44	0.353
偏心套故障(T_1)	8 220	580	47	0.320
轴承磨损(T_2)	6 932	593	40	0.370
轴承磨损(T_2)	7 000	590	41	0.364
轴承磨损(T_2)	7 600	597	40	0.360
轴承磨损(T_2)	7 500	600	43	0.350
轴承磨损(T_2)	6 800	590	45	0.347
平行轴缺油(T_3)	5 302	572	35	0.420
平行轴缺油(T_3)	5 230	560	32	0.430
平行轴缺油(T_3)	6 042	559	33	0.442
平行轴缺油(T_3)	5 400	570	37.2	0.410
平行轴缺油(T_3)	5 700	567	36	0.401
平行轴油温过高(T_4)	5 200	620	59	0.160
平行轴油温过高(T_4)	5 000	613	60	0.130
平行轴油温过高(T_4)	5 000	610	61	0.120
平行轴油温过高(T_4)	4 500	617	58.3	0.150
平行轴油温过高(T_4)	4 700	615	59.6	0.130

表 3 网络训练数据
Table 3 Network training data

序号	网络训练数据				
	故障特征参数矩阵 P				故障类型矩阵 T
1	[0.919 3	0.508 2	0.379 3	0.745 3]	[1 0 0 0]
2	[0.927 1	0.459 0	0.448 3	0.683 2]	[1 0 0 0]
3	[1.000 0	0.524 6	0.275 9	0.776 4]	[1 0 0 0]
4	[0.835 4	0.508 2	0.413 8	0.723 6]	[1 0 0 0]
5	[0.878 9	0.344 3	0.517 2	0.621 1]	[1 0 0 0]
6	[0.574 6	0.557 4	0.275 9	0.776 4]	[0 1 0 0]
7	[0.590 7	0.508 2	0.310 3	0.757 8]	[0 1 0 0]
8	[0.732 4	0.623 0	0.275 9	0.745 3]	[0 1 0 0]
9	[0.708 8	0.672 1	0.379 3	0.714 3]	[0 1 0 0]
10	[0.543 4	0.508 2	0.448 3	0.705 0]	[0 1 0 0]
11	[0.189 5	0.213 1	0.103 4	0.931 7]	[0 0 1 0]
12	[0.172 5	0.016 4	0.000 0	0.962 7]	[0 0 1 0]
13	[0.364 3	0.000 0	0.034 5	1.000 0]	[0 0 1 0]
14	[0.212 6	0.180 3	0.179 3	0.900 6]	[0 0 1 0]
15	[0.283 5	0.131 1	0.137 9	0.872 7]	[0 0 1 0]
16	[0.165 4	1.000 0	0.931 0	0.124 2]	[0 0 0 1]
17	[0.118 1	0.885 2	0.965 5	0.031 1]	[0 0 0 1]
18	[0.118 1	0.836 1	1.000 0	0.000 0]	[0 0 0 1]
19	[0.000 0	0.950 8	0.906 9	0.093 2]	[0 0 0 1]
20	[0.047 3	0.918 0	0.951 7	0.031 1]	[0 0 0 1]

小的隐含层神经元个数作为最优的隐含层神经元个数即可,从图 3 中可以发现 $m=8$ 时,神经网络的仿真误差为 $0.000\ 81 < 0.01$ (期望误差),并且在误差集合中是最小的,即确定隐含层神经元为 8 个。




图 3 误差变化幅度

Fig.3 Error variation range

在经过故障诊断模型调整后,确定模型网络结构为 4-8-4,通过仿真及计算均方误差 $\text{perf}=0.000\ 81$,网络模型的均方误差远远小于期望误差,并且误差下降及收敛速度很快,仅迭代 4 次完成误差的下降,网络性能达标如图 4。




图 4 网络训练梯度

Fig.4 Network training gradient

网络训练仿真结果是表明训练结果是优秀,通过测试数据,来对网络进行测试,判断网络模型的故障诊断能力,为避免出现网络训练仿真结果表明成功,但泛化能力不足的现象,利用测试数据对网络进行检验,从原始数据初次选取后所余下 10 数据中选取获得测试数据,用 u 表示,

$$u = \begin{bmatrix} 800\ 0\ 585\ 44\ 0.354; 693\ 1\ 596\ 40\ 0.37; \\ 530\ 0\ 570\ 35\ 0.42; 516\ 4\ 616\ 59\ 0.16 \end{bmatrix},$$

测试目标输出

$$t_{\text{test}} = \begin{bmatrix} 1\ 0\ 0\ 0; 0\ 1\ 0\ 0; 0\ 0\ 1\ 0; 0\ 0\ 0\ 1 \end{bmatrix};$$

经过归一化处理后,调用仿真函数来得出实际测试结果。

对比实际测试结果与期望测试结果如表 4,发现 2 个结果从直观上对比结果非常接近,计算出测试均方误差 $\text{perf}_{\text{test}}=0.000\ 11$,远远小于期望误差,说明网

络模型训练成功,此时,神经网络系统获得的故障诊断知识就表达为神经元连接权值矩阵和阈值矩阵^[9]。在此基础上保存训练好的网络,选用训练好的 BP 神经网络模型 BPnn 作为旋回式破碎机故障诊断模型,来解决矿山企业旋回式破碎机故障诊断问题。

表 4 测试结果对比

Table 4 Comparison of test results

理想测试输出				实际测试输出				故障类型	
1	0	0	0	0.976 2	-0.008 4	0.014 0	-0.012 9	T_1	
0	1	0	0	0.007 4	1.011 8	-0.009 8	0.012 8	T_2	
0	0	1	0	0.007 8	0.004 4	0.989 9	-0.000 8	T_3	
0	0	0	1	0.005 0	-0.003 4	0.005 3	0.989 7	T_4	

3 结 论

(1) 根据旋回式破碎机的故障问题,以回流油温、润滑油油压、轴承振动频率、轴承转速作为 BP 神经网络输入,偏心套故障、轴承磨损、平行轴缺油、平行轴油温异常为网络输出,以物联网技术作为数据采集及传输的技术支撑,利用改进后 BP 神经网络,通过数据采集及选取、网络训练、优化及测试等步骤完成了旋回式故障诊断模型建立。

(2) 旋回式破碎机故障诊断模型具有结构简单,诊断迅速等优点,在对矿山旋回式破碎机故障诊断中,可以达到实时诊断,便于在工程实际应用。

(3) 旋回式破碎机故障诊断模型诊断准确率很高,诊断准确率 95% 以上,并且具有良好的扩展性和容错性,为矿山企业旋回式破碎机故障诊断提供了一种有效方式。

参 考 文 献

[1] 黎云峰. 弹簧式圆锥破碎机的常见故障、原因分析及处理方法[J]. 矿山机械, 2009(20) : 63-64.
Li Yunfeng. Common faults of spring-type cone crusher cause analysis and treatment[J]. Mining Machinery, 2009(20) : 63-64.
[2] 陈以壮. 锤式破碎机传动装置的常见故障分析[J]. 煤矿机械,

2013(1) : 278-280.
Chen Yizhuang. Common failure analysis of hammer crusher transmission[J]. Coal Mine Machinery, 2013(1) : 278-280.
[3] 熊旭平, 孙慧峰. PLCM1000 破碎机主轴断裂故障分析及结构改进[J]. 煤矿机械, 2014(4) : 163-164.
Xiong Xuping, Sun Huifeng. Failure analysis and structural improvement of machine spindle PLCM1000[J]. Coal Mine Machinery, 2014(4) : 163-164.
[4] 普亚松, 郭德伟, 张文斌. 故障诊断技术在煤矿机械设备中的应用[J]. 工矿自动化, 2015(4) : 36-39.
Pu Yasong, Guo Dewei, Zhang Wenbin. Application of fault diagnosis technology in coal mine machinery[J]. Industry and Mine Automation, 2015(4) : 36-39.
[5] 禹建丽, 卞 帅. 基于 BP 神经网络的变压器故障诊断模型[J]. 系统仿真学报, 2014(6) : 1343-1349.
Yu Jianli, Bian Shuai. Fault diagnosis model of transformer based on BP neural network[J]. Journal of System Simulation, 2014(6) : 1343-1349.
[6] 孙 璐, 唐广群, 张德政. 神经网络技术在破碎机故障诊断中的应用[J]. 矿冶, 2007(3) : 85-90.
Sun Lu, Tang Guangqun, Zhang Dezheng. Application of neural network in Crusher Fault Diagnosis of system[J]. Mining and Metallurgy, 2007(3) : 85-90.
[7] 孙永厚, 李 聪. 基于粗糙集-BP 神经网络的垃圾破碎机故障诊断[J]. 机械设计与制造, 2012(1) : 218-220.
Sun Yonghou, Li Cong. The fault diagnosis of garbage crusher based on rough Set-BP neural network[J]. Machinery Design & Manufacture, 2012(1) : 218-220.
[8] 王元章, 李智华, 吴春华, 等. 基于 BP 神经网络的光伏组件在线故障诊断[J]. 电网技术, 2013(8) : 2094-2100.
Wang Yuanzhang, Li Zhihua, Wu Chunhua, et al. A survey of online fault diagnosis for PV module based on BP neural network[J]. Power System Technology, 2013(8) : 2094-2100.
[9] 李文江, 屈海峰, 马云龙. 基于 BP 神经网络的矿井提升机故障诊断研究[J]. 工矿自动化, 2010(4) : 44-47.
Li Wenjiang, Qu Haifeng, Ma Yunlong. Study on fault diagnosis of mine hoister based on BP neural network[J]. Industry and Mine Automation, 2010(4) : 44-47.

(责任编辑 徐志宏)