

一种无刷发电机旋转整流器自适应故障特征提取方法

崔江, 唐军祥, 龚春英, 张卓然

(南京航空航天大学自动化学院, 江苏省 南京市 211106)

An Adaptive Fault Feature Extraction Method of Brushless Generator Rotating Rectifier

CUI Jiang, TANG Jun-xiang, GONG Chun-ying, ZHANG Zhuo-ran

(Nanjing University of Aeronautics and Astronautics, College of Automation Engineering, Nanjing 210016, Jiangsu Province, China)

ABSTRACT: This paper presented a fault feature extraction method based on the stacked auto-encoder (SAE), which is optimized by the grey relational analysis (GRA). This method can extract fault features from raw data adaptively, and this method can be applied to fault diagnosis of rotating rectifier diodes in aircraft generator. First, filed current of aviation generator excitation is collected. Second, the deep learning theory is adopted to train the auto-encoder, combined with the grey relational analysis, to achieve a good network structure of stack auto-encoders, which can extract the fault features adaptively from the generator current data information. Finally, fault diagnosis can be implemented with the support vector machine classifier. The performances of the presented method were compared with Fast Fourier Transform (FFT) method through simulations and physical experiments. The experiment results showed that the presented fault extractor is automatic and adaptive, and the achieved features with this method can be evaluated ideally with the support vector machine classifier.

KEY WORDS: aircraft generator; rotating rectifier; adaptive feature extraction; auto-encoder; grey relational analysis; deep learning;

摘要: 研究了一种基于灰色关联度分析优化堆栈自动编码器的故障特征自适应提取方法,并用于航空发电机中的旋转整流器二极管故障诊断。首先,采集发电机中交流励磁机励磁电流信号;然后,结合灰色关联度分析并利用深度学习理论对堆栈编码器网络进行训练学习以确立其较优的网络结构,通过该网络可以自适应地从励磁电流信号中提取故障特征;训练完毕,借助于支持向量机分类器实施故障诊断。对

本文方法与典型的 FFT 方法进行了仿真和物理实验,并将分类性能进行比较。结果表明,本文方法自动化程度高,自适应性能好,所提取的特征用 SVM 可以取得很好的分类效果。

关键词: 航空发电机; 旋转整流器; 自适应特征提取; 自编码器; 灰色关联度分析; 深度学习

0 引言

随着多电/全电飞机概念的提出和逐步实现,飞机供电系统在现代飞机上的地位越来越重要,它为所有的机载电子和电气设备提供电能来源^[1]。而航空发电机是飞机供电系统的主电源,属于飞机的关键设备,发电机的任何一个环节出现故障,都有可能威胁飞机的飞行安全和飞行任务的完成,甚至造成不可估量的经济损失和人员伤亡的严重后果^[2]。

目前,航空用的发电机主要是采用无刷交流发电机,这类发电机使用旋转二极管取代了传统有励磁的滑环和电刷等转动接触部分,从根本上解决了由此带来的接触不良以及发热的问题^[3],在民用飞机领域得到了广泛应用。其中,旋转整流器是飞机无刷交流发电机的关键部件之一,美国宾夕法尼亚州立大学的 Batzel 等人对航空无刷发电机的故障模式、影响和危害性分析(Failure Mode, Effects and Criticality Analysis, FMECA)进行了研究,并指出旋转整流器是航空发电机中易损坏的部件之一,其故障的严酷度等级很高^[4]。旋转整流器故障主要是指二极管短路故障和开路故障,由于短路故障可转化为开路故障^[5],因此本文主要针对旋转整流器二极管的开路故障诊断进行研究。

目前,传统的航空发电机旋转整流器故障诊断大多采用基于信号处理或模式识别的方法^[6-11],即

基金项目: 国家自然科学基金项目(51377079); 中央高校基本科研业务费专项资金资助(NS2017019)。

Project Supported by National Natural Science Foundation of China (51377079); Fundamental Research Funds for the Central Universities (NS2017019).

首先采集各种故障模式所对应的数据信息,然后再采用信号处理方法提取故障特征,最后用神经网络或支持向量机等进行故障分类。其中,故障特征提取是目前故障诊断技术的难点所在^[12],也是属于故障诊断和健康监测领域的关键技术。现有的发电机旋转整流器故障特征提取方法可分为三类:

(1) 基于时域的分析方法。该方法在时域中对故障信号进行分析,提取出故障信号的时域特征,通过对时域特征设定阈值实施故障检测。文献[6]中提到,当旋转整流器发生故障时,旋转整流器的输出电压将会下降,会造成负载电流下降,并且在调压器的作用下交流励磁机励磁电流将会上升,通过对负载电流和励磁电流设定阈值,可以判定旋转整流器是否发生故障。阈值方法可判断有故障发生,而不能对具体故障二极管实施定位。

(2) 基于频域的分析方法^{[7]-[9]}。该方法的理论基础是谐波电枢反应原理^[13],由于二极管的单向导通性,整流电路将会在交流励磁机的电枢绕组上产生相应的谐波分量,谐波分量的存在将会在空间中产生相应的谐波磁势,同时由于谐波磁势的存在将会在交流励磁机的励磁绕组中产生相应的谐波分量。通过对励磁电流进行快速傅里叶变换(即FFT)得到交流励磁机励磁电流的频谱,借助人分析,提取出谐波成分进行故障诊断。基于FFT的故障分析是目前该领域内采用最多的一种诊断方法。

(3) 基于时-频域的联合分析方法。小波变换继承和发展了短时傅里叶变换局部化的思想,同时又克服了窗口大小不随频率变化等缺点,是进行信号时-频分析和处理的常用工具^[14],文献[10]对航空交流励磁机建立仿真模型,通过仿真获取励磁电流并进行小波分解,提取了频带能量组成特征向量,取得了较好的分类效果。经验模态分解(Empirical Mode Decomposition, EMD)方法是依据数据自身的时间尺度特征来进行信号分解,是一种新型自适应信号时-频处理方法,已经在旋转机械故障诊断领域得到了研究^[15],文献[11]对交流励磁机励磁电流信号进行经验模态分解,构造能量特征向量,并采用支持向量机进行分类。

故障特征提取是基于数据驱动的故障诊断方法中的关键步骤^[16],上述故障特征提取方法均需要依靠合适的信号处理技术,需要考虑较多参数的选择和尝试,或者依据本领域专家的丰富经验去选择

故障特征,导致特征提取和选择过程有时较为复杂。2006年,Hinton等人在《Science》上发表相关文章^[17],提出了深度学习的基本理论和实现框架。深度学习理论通过模拟人类大脑的学习过程,构建深层次模型来学习大量数据中所隐含的特征,可以刻画出数据中蕴藏的特征信息,从而能够提高分类正确率。受此启发,本文提出一种基于堆栈自动编码器(Stacked Auto-Encoder,简称SAE)的航空发电机旋转整流器故障特征提取方法。其中,SAE的网络结构通过灰色系统理论中的关联度方法进行优化分析,这种方法可称为GRA-SAE(Stacked Auto-Encoder optimized by Grey Relational Analysis)。实验结果表明,该方法的实验效果好,并且自动化程度高,具有较好的自适应性。

1 GRA-SAE 理论

深度学习理论可以认为是开启了神经网络发展的一个里程碑^[18]。传统的单隐层神经网络具有一定的自适应性,鲁棒性效果也好,因而在故障诊断领域应用广泛。但单隐层神经网络属于一种浅层结构,这就使其在深度挖掘数据内在特征能力方面受到了一定限制^[19]。为了解决此类问题,可以采用深度学习神经网络加以实现。深度学习网络是由很多层的基本单元构成,这些基本单元前后一般通过权值相衔接。深度神经网络的学习问题可以采用Hinton等人提出的贪婪逐层训练算法加以实现^[17]。目前,深度神经网络的隐含层节点数大都依靠经验选取^[20],尚无合适的方法指导选择过程,而隐含层节点的选择对网络的性能具有十分重要的影响。

目前,深度学习神经网络有几种典型模型^[21],本文采用自动编码器(Auto-encoder, AE)作为深度神经网络构成的基本单元,利用灰色关联度分析指导SAE网络结构的确立过程,将其用于航空发电机的旋转整流器故障特征提取中,可以自适应地提取故障特征。

1.1 自动编码器

AE是一个三层的神经网络模型,它是由编码器和解码器两部分组成^[22],其结构如图1所示。AE的输入层节点数与输出层节点数相同,通过编码器部分将输入映射为低维的特征输出;然后,通过解码器部分将特征层输出向量重构原来的输入向量,当输出向量与输入向量之间的误差足够小时,得到

的特征层输出向量即为输入向量的一种低维空间表示^[23]，通过这种方式可以提取输入数据的特征。

给定一个无标签的航空发电机旋转整流器故障样本集 $X=\{x^i|1\leq i\leq S\}$ ，其中， S 为总样本个数， x^i 为样本集中第 i 个样本，每个样本的长度为 m 。自动编码器的编码部分将输入向量通过非线性映射函数映射为隐含层输出向量，设 $H=\{h^i|1\leq i\leq S\}$ 表示隐含层输出向量集合，其中， h^i 表示第 i 个故障样本对应的特征向量，每个特征向量的长度为 n ，则

$$H = f_{(W,b)}(X) = s_f(WX + b) \quad (1)$$

式中， W 表示连接在输入层与隐含层之间的权值矩阵， b 为输入层与隐含层之间的偏置矩阵， s_f 为编码器部分的神经元激活函数。




图 1 自动编码器结构图

Fig.1 Structure of Auto-encoder

解码器是编码器的逆运算，它是利用编码器得到的隐含层输出向量重构出原始输入向量。设 $\hat{X}=\{\hat{x}^i|1\leq i\leq S\}$ 表示输出向量集合，其中， \hat{x}^i 表示第 i 个故障样本对应的输出向量，输出向量的长度与故障样本长度相同。解码器的数学表示如下：

$$\hat{X} = g_{(W',b')}(H) = s_g(W'H + b') \quad (2)$$

式中， W' 表示连接在隐含层与输出层之间的权值矩阵， b' 为特征层与输出层之间的偏置矩阵， s_g 表示解码器部分的神经元激活函数。

本文选用的神经元激活函数为 ‘sigmoid’ 函数，这个函数较为常用，实验效果好。其形式如下：

$$\text{sigmoid}(z) = \frac{1}{1 + e^{-z}} \quad (3)$$

其中， e 为自然常数， z 表示每个神经元对应的输入向量。

AE 通过最小化输出向量与输入向量之间的重构误差 $L(x^i, \hat{x}^i)$ 来达到特征提取的目的，重构误差公式如下：

$$L(x^i, \hat{x}^i) = \frac{1}{S} \sum_{i=1}^S \|x^i - \hat{x}^i\|^2 \quad (4)$$

利用梯度下降算法不断地调整权值和偏置，使得重构误差最小，最终完成整个网络的训练，公式如下：

$$\begin{aligned} W &\leftarrow W - l \times \frac{\partial L(x, \hat{x})}{\partial W} \\ b &\leftarrow b - l \times \frac{\partial L(x, \hat{x})}{\partial b} \end{aligned} \quad (5)$$

式中， l 为学习率， $\frac{\partial L(x, \hat{x})}{\partial W}$ 表示 $L(x, \hat{x})$ 对 W 求偏

导， $\frac{\partial L(x, \hat{x})}{\partial b}$ 表示 $L(x, \hat{x})$ 对 b 求偏导。

1.2 堆栈自动编码器

SAE 是一种典型的深度学习网络模型。该模型是一个包含多个隐含层的神经网络，由多个 AE 叠加而成^[24]，模型结构如图 2 所示。深度自动编码器的训练过程是采用贪婪逐层预训练方法，解决了传统神经网络训练算法容易陷入局部极值的问题，通过逐层训练每个自动编码器模型，可以最终完成对整个网络的训练^[25]。




图 2 SAE 的结构图

Fig.2 Structure of Stack Auto-encoder

首先使用航空发电机旋转整流器故障样本集训练第一个 AE，随机初始化 AE 的初始权值和偏置 $\{W_1, b_1, W'_1, b'_1\}$ ，通过 AE 的编码器部分将故障样本集映射为隐含层输出向量，即：

$$h(1)^i = f_{(W_1, b_1)}(x^i) = s_f(W_1 x^i + b_1) \quad (5)$$

式中， W_1 和 b_1 分别为第一个 AE 的编码器部分的

权值和偏置, $\mathbf{h}(1)^i$ 为第一个 AE 的隐含层输出向量。通过解码器部分重构输入向量, 即:

$$\hat{\mathbf{x}}^i = g_{(w,b)}(\mathbf{h}(1)^i) = s_g(\mathbf{W}_1' \mathbf{h}(1)^i + \mathbf{b}_1') \quad (6)$$

计算输出向量与输入向量之间的重构误差, 利用误差反向传播算法不断的调整权值和偏置 $\{\mathbf{W}_1, \mathbf{b}_1, \mathbf{W}_1', \mathbf{b}_1'\}$, 使得重构误差最小, 完成第一级 AE 的训练。然后, 只保留本级的编码器部分, 将特征层输出向量作为下一级 AE 的输入向量按照同样的方法训练第二级 AE。重复这个训练过程, 直到完成最后一级 AE 的训练。当完成前面所有 AE 训练时, 最后一个 AE 的隐含层输出即为最终的特征向量。

1.3 灰色关联度分析

关联度是事物或因素之间关联性大小的度量。它定量地描述了事物或因素之间相互变化的情况, 即变化的大小、方向与速度等的相对性。GRA 具有原理简单、易于理解和掌握等优点, 因此在各个领域得到了应用^[26]。

设 \mathbf{Y}_i 为有序数列, 序列长度为 p , 则称 $\mathbf{Y}_i = [y_i(1), y_i(2), \dots, y_i(p)]$ 为第 i 个个体的特征行为序列。设系统中 q 个个体的特征行为序列为:

$$\begin{aligned} \mathbf{Y}_0 &= [y_0(1), y_0(2), \dots, y_0(p)] \\ \mathbf{Y}_1 &= [y_1(1), y_1(2), \dots, y_1(p)] \\ &\dots \\ \mathbf{Y}_q &= [y_q(1), y_q(2), \dots, y_q(p)] \end{aligned} \quad (7)$$

以特征行为序列 \mathbf{Y}_0 为参考序列, 特征行为序列 $\mathbf{Y}_1, \mathbf{Y}_2, \dots, \mathbf{Y}_q$ 为比较序列。参考序列 \mathbf{Y}_0 与比较序列 $\mathbf{Y}_i (i=1, 2, \dots, q)$ 的灰色关联度 $r(\mathbf{Y}_0, \mathbf{Y}_i)$ 为:

$$r(\mathbf{Y}_0, \mathbf{Y}_i) = \frac{1}{p} \sum_{j=1}^p r(y_0(j), y_i(j)) \quad (8)$$

式(8)中:

$$r(y_0(j), y_i(j)) = \frac{\min \min |y_0(j) - y_i(j)| + \xi \max \max |y_0(j) - y_i(j)|}{|y_0(j) - y_i(j)| + \xi \max \max |y_0(j) - y_i(j)|} \quad (9)$$

式(9)中, ξ 为灰色关联度的分辨系数, 人为引入这个系数是为了提高关联系数之间的差异显著性, ξ 越小, 分辨能力越大, 一般取 $\xi \in (0, 1)$; $|y_0(j) - y_i(j)|$ 是参考序列 \mathbf{Y}_0 、比较序列 \mathbf{Y}_i 在第 j 点处的绝对差值; $\min \min |y_0(j) - y_i(j)|$ 为两级最小差, 其中, $\min |y_0(j) - y_i(j)|$ 是第一级最小差, 即在比较序列 \mathbf{Y}_i 各点中找出与 \mathbf{Y}_0 的最小绝对差; $\min \min |y_0(j) - y_i(j)|$ 表示在个比较序列找出最小

绝对差的基础上, 再按 $i=1, 2, \dots, q$ 找出所有比较序列 \mathbf{Y}_i 的最小值; $\max \max |y_0(j) - y_i(j)|$ 为两级最大差, 其计算方法与两级最小差类似。

1.4 GRA-SAE

AE 的输入层节点与输出层节点数相等, 而隐含层节点一般小于输入(出)层节点数, 通过这样的结构可以在隐含层得到输入向量的低维空间表示, 隐含层输出向量视为输入向量的一种低维特征。隐含层节点数也就代表特征的维数。但是, 将一个高维输入向量映射至低维空间, 选取的低维空间维数难以把握, 通常的方法是根据经验来选取较优的网络结构。本文尝试采用 GRA 对 SAE 的网络结构进行优化, 可以自适应地确立 SAE 的网络结构。

AE 的隐含层节点与输出层节点通过权值和阈值直接连接, 而每一个隐含层节点的输出向量对输出层向量的贡献大小也不相同。基于此, 通过计算隐含层节点与输出层向量之间的灰色关联度来剔除贡献较小的隐含层节点来选取网络结构, 具体选取过程如下:

(1) 初始化隐含层节点个数, 使得隐含层节点数等于输入(出)节点数。

(2) 通过公式(9)计算每一个隐含层节点的输出向量(可以视为 GRA 中的比较序列)与 AE 输出层输出向量(可以视为 GRA 中的参考序列)之间的灰色关联度系数, 然后通过公式(8)计算出每一个隐含层节点与输出向量之间的灰色关联度大小, 得到灰色关联度序列。

(3) 设定阈值 ε , 剔除步骤(2)中得到的灰色关联度序列中值较小的节点(也即此隐含层节点对最终的输出向量的贡献很小), 这里的阈值 ε 采用自适应的方法计算, 具体计算公式如下:

$$\varepsilon = (r_{\max} - r_{\min}) / 2 + r_{\min} \quad (10)$$

式中, r_{\max} 表示灰色关联度序列中的最大值, r_{\min} 表示灰色关联度序列中的最小值。

(4) 判断所剔除的节点个数是否小于某一个值 N (N 一般可设为 5~50, 认为此时网络结构趋于稳定, 在本文中设定 $N=40$)。如果小于 N , 则停止本次训练, 将本级 AE 得到的隐含层节点作为下一级 AE 的输入节点, 返回步骤(1), 以相同方式训练下一级 AE。否则, 更新本级 AE 的隐含层节点数, 返回步骤(2), 继续训练。

综上, 基于 GRA-SAE 的航空发电机旋转整流

器故障特征提取和诊断流程可以分为如下步骤，如图 3 所示。

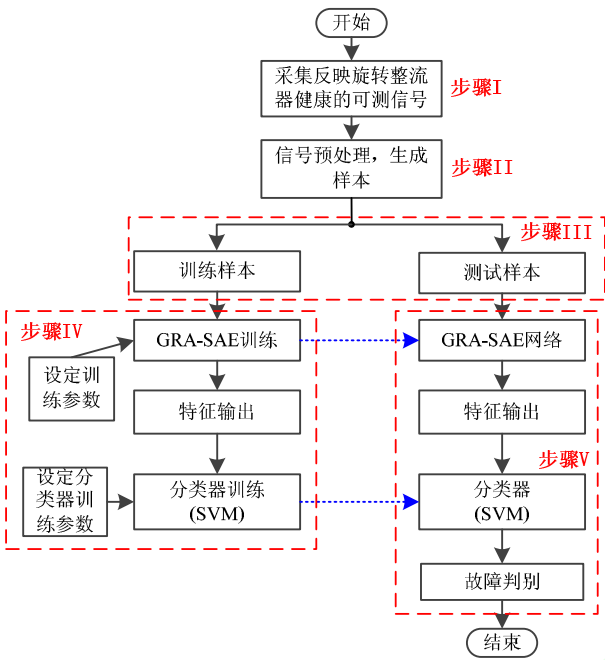


图 3 基于 GRA-SAE 的故障诊断流程图
Fig.3 Algorithm of fault diagnosis based on GRA-SAE

(I) 从可测节点采集能够反映旋转整流器故障的数据信号。

(II) 对信号进行预处理，比如，数据归一化和数字滤波等，以降低噪声或者负载波动对后续处理的影响。

(III) 把采集的数据样本分为训练样本和测试样本，训练样本的作用是用于训练分类器；测试样本的主要作用是为了测试提取的特征的有效性，并可在一定的测试样本数目下计算诊断正确率。

(IV) 训练阶段。把训练样本输入至 GRA-SAE 进行训练，此时的一些基本参数（例如 SAE 的层数和激活函数、灰色关联度分辨系数 ξ 等）需要预先加以确定；经过训练之后的 GRA-SAE 有两种信息需要利用：一种是特征信息，另外一种训练之后的 GRA-SAE 网络（此时，SAE 的网络参数都已经固定）。GRA-SAE 的输出特征尚不具备分类功能，此时，对获取的 GRA-SAE 输出特征加分类器（在本研究中，使用 SVM 作为模式分类器^[27]）再次进行训练，保存训练完成之后的网络结构，用于后续的测试。

(V) 测试阶段。把测试样本输入至已经训练好的 GRA-SAE 并抽取特征，提取完成的特征输入至分类器得到故障模式分类，并根据诊断结果完成诊

断正确率的计算。

2 仿真实验

航空发电机是一个非线性、强耦合的复杂系统，本文选择的是航空三级式发电机作为研究对象。该类型的发电机具有外特性优良，起激可靠等优点，目前在 A380 和 B787 等客机上得到了广泛应用。在 Matlab/Simulink 软件中搭建了三级式航空发电机的模型（输出三相交流电压 115V/400Hz，额定转速：8000 rpm），研究旋转整流器二极管开路故障。

2.1 发电机建模及故障模式分析

航空三级式发电机结构图如图 4 所示，主要由永磁副励磁机、交流励磁机和主发电机三级组成^[28]，每级均含定子和转子部分。




图 4 航空三级式发电机结构图

Fig.4 Structure of Aircraft Generator

自动调压器模块包含一个整流器和一个比例积分(Proportional-Integral, PI)调节器，它通过整流器将永磁励磁机三相交流电整流成直流给交流励磁机提供励磁，然后检测主发电机输出两相线电压，求出其均方根值，然后与参考电压进行比较，产生的误差经 PI 串联校正环节后，调节交流励磁机的励磁电流，进而可以实现对主发电机电压的控制，达到稳压的目的。旋转整流器位于交流励磁机与主发电机之间，它的作用是将交流励磁机三相交流电整流成直流电给主发电机提供励磁。此处，研究航空发电机旋转整流器的开路故障模式，包括：健康模式（即无故障模式，可认为是一种特殊的故障模式），单管故障（共 6 种）和双管故障三类（共 15 种），如表 1 所示。

表 1 故障模式分类表

Tab.1 List of failure modes

故障模式	故障二极管
------	-------

健康模式	--
单管故障模式	$D1、D2、D3、D4、D5、D6$
双管故障模式	$D1D4、D2D5、D3D6$
	$D1D3、D1D5、D3D5、D2D6、D2D4、D4D6$
	$D1D2、D2D3、D3D4、D4D5、D5D6、D6D1$

2.2 数据采集

发电机在实际运行过程中, 旋转整流器跟随转子一起转动, 但转子上信号不易测量。由于谐波电枢反应的存在, 交流励磁机励磁电流 I_{ef} 可反映故障信息, 实际应用中也属于可测信号。因此, I_{ef} 可作为信息源。




图5 空载条件下5种典型故障模式励磁电流波形图

Fig.5 Excitation generator field current wave of 5 typical fault modes in no-load situation

空载条件下5种典型故障模式的交流励磁机励磁电流波形图如图5所示。在发电机运行中由于温升等原因, 电机内部的电感、电阻等参数存在一定的波动性。为了模拟该特性, 在仿真中采用了蒙特卡罗 (Monte Carlo, MC) 分析, 对每一级发电机的内部电感、电阻参数均设置了5%的容差, 对每种故障模式进行100次MC分析。考虑到发电机负载的影响, 本文分别在空载、1.5kW阻性负载和3kW阻性负载条件下进行了仿真。每种负载条件下每种故障模式均得到100个样本, 设置采样时钟率为10KHz。此处, 为了模拟负载变动对所提方法的影响, 将空载、1.5kW和3kW的故障类样本混合在一起进行操作组成随机负载条件下的故障样本。在随机负载条件下, 每类故障模式的样本仍为100个(从三种负载状况下的样本中随机选取)。

2.3 特征提取及诊断

在旋转整流器故障诊断领域, 典型的故障特征提取方法是FFT分析。文献[6]、[8]等指出当旋转整流器二极管发生故障时, 交流励磁机励磁电流的1次、2次、6次谐波分量(用 A_1, A_2, A_6 依次表示各分量的幅值, $\varphi_1, \varphi_2, \varphi_6$ 依次表示各分量的相位)会发生较为显著的变化, 可以用来作为故障特征, 这种特征提取方法(方法I)可作为一种专家领域知识, 与本文方法进行对比。

其次, 为了验证深度多层神经网络较传统浅层神经网络在深度数据挖掘中的优势, 随机选择两个单隐层神经网络结构进行故障特征提取(方法II), 作为本文的第二种对比方法。

再次, SAE隐含层节点的选择大都依靠经验或随机选择。本文选择两个4层的SAE网络结构进行实验, 作为本文的第三种对比方法(方法III)。

最后, 基于GRA-SAE的特征提取方法(方法IV), 为了和方法III比较, 也采用4层AE结构。神经元激活函数设为“sigmoid”函数, 每一个自动编码器的迭代次数设为20次, GRA的分辨系数 ξ 设为0.05。由于SAE的输入层节点与样本长度相同, 输入层节点与所需的特征维数相同, 因此, 输入层与输出层节点通过人工设置, GRA只对SAE的隐含层节点进行寻优。本文利用随机负载条件下的故障样本对GRA-SAE进行训练, 得到一组通用网络结构, 其余几种负载条件(空载、1.5KW负载)同样是利用该网络结构进行特征提取。

这里需要说明的是, 在方法II、方法III和方法IV中, 输入至神经网络中进行故障特征提取的原始样本均需进行均值为0、方差为1的归一化进行预处理。特征提取完成后, 需要添加一个故障分类器。目前, 航空发电机旋转整流器故障诊断领域较为常用的分类方法有神经网络方法、支持向量机 (Support vector machine, SVM) 等^{[29][30]}。由于SVM的分类性能比较稳定, 因此本文选择SVM作为故障分类器。将上述几种方法提取的故障特征(分别考虑提取3、4和5维特征等三种情况进行验证)分别输入至SVM进行分类, 具体分类器参数设置如下: 采用标准的C-SVM分类器, 分类方法为一对一算法。核函数选用径向基核函数, 惩罚因子C和核函数参数 γ 分别为100和0.1(可以取得较好的分类效果)。

仿真所用计算机操作系统为Win7, 内存为

2GB, 主频为 2.79GHz, 采用软件的是 Matlab2009a。分别在空载和负载变动条件下进行处理。实验结果如表 2、表 3 和表 4 所示。其中, 方法 I 可以认为是借鉴专家领域知识进行选择的故障特征; 方法 II 可认为是利用浅层网络结构所提取的故障特征; 方法 III 认为是随机选取 SAE 所提取的故障特征; 方法 IV 为本文改进的 GRA-SAE 方法。此处, 方法 IV 含两种网络结构, 分别对应空载条件下和负载变动条件下 GRA 寻优得到的 SAE 网络结构(两种条件下的数据信息相异, 因而优化 GRA 得到的网络结构也不同)。

表 2 在 3 维特征下的诊断正确率

Tab.2 Classification accuracy with 3-dimensional features

方法	网络结构 (特征)	空载	1.5KW 负载	随机负载
I	$A_1A_2A_6$	99.64%	99.09%	99.45%
II	1000-500-3	52.36%	62.45%	75.55%
II	1000-200-3	86.27%	86.27%	86.18%
III	1000-600-400-200-3	95.27%	93.64%	95.00%
III	1000-750-500-250-3	96.45%	96.27%	96.64%
IV	1000-516-227-49-3	99.91%	99.64%	99.64%

表 3 在 4 维特征下的诊断正确率

Tab.3 Classification accuracy with 4-dimensional features

方法	网络结构 (特征)	空载	1.5KW 负载	随机负载
I	$A_1A_2A_6\phi_6$	100%	100%	100%
II	1000-500-4	79.27%	77.73%	76.64%
II	1000-200-4	89.00%	88.91%	88.64%
III	1000-600-400-200-4	96.73%	96.18%	95.91%
III	1000-750-500-250-4	97.82%	97.17%	97.36%
IV	1000-516-227-49-4	100%	100%	100%

表 4 在 5 维特征下的诊断正确率

Tab.4 Classification accuracy with 5-dimensional features

方法	网络结构 (特征)	空载	1.5KW 负载	随机负载
I	$A_1A_2A_6\phi_1\phi_6$	100%	100%	100%
II	1000-500-5	97.73%	90.36%	97.00%
II	1000-200-5	94.82%	94.27%	94.91%
III	1000-600-400-200-5	97.91%	96.73%	97.27%
III	1000-750-500-250-5	99.82%	99.73%	99.55%
IV	1000-516-227-49-5	100%	100%	100%

另外, 诊断时间也是衡量分类器性能的一个重要指标, 本文以空载条件为例, 利用各种方法提取 5 维特征, 对各种方法所耗费的特征提取时间 (T_1) 和 SVM 分类时间 (T_2) 进行了统计, 具体结果如

表 5 所示。其中, T_1 、 T_2 均是针对 1100 个测试样本所耗费的总时间; T_a 表示单个样本所耗费的总时间, 且 $T_a=(T_1+T_2)/1100$ 。此处, 对方法 I 而言, T_1 主要包括 FFT 分析和处理时间; 对其他方法而言, T_1 主要指神经网络的处理时间。

表 5 四种方法的耗费时间(s)

Tab.5 Time for several methods (s)

方法	网络结构 (特征)	T_1	T_2	T_a
I	$A_1A_2A_6\phi_1\phi_6$	0.1317	251.4185	0.2287
II	1000-500-5	0.1178	251.9502	0.2292
III	1000-750-500-250-5	0.2794	252.6598	0.2299
IV	1000-516-227-49-5	0.2558	257.2766	0.2341

从表 2-表 4 的仿真结果可看出, 随着特征维数的增加(从 3 维到 5 维), 有几种分类器(例如方法 II、方法 III)的诊断率呈上升趋势, 这说明增加特征可提高诊断正确率, 但增加到一定的程度, 诊断率不再变化(例如方法 IV)。方法 I 取得了好的诊断效果, 这说明了专家领域知识确实是有效的; 方法 II 是利用浅层网络结构所提取的故障特征, 从数据来看, 此方法的效果要比方法 III 差, 说明深度网络在数据挖掘方面比浅层网络更有优势; 方法 III 是随机选取堆栈自动编码器结构所提取的故障特征, 性能要稍逊 GRA-SAE 方法, 这说明, SAE 可以利用 GRA 方法指导得到一个较好的网络结构。另外, 从表 5 可以看出, 四种方法所耗费的特征提取及诊断时间比较接近。这是因为几种方法采用的特征提取网络和分类器规模比较接近, 而且这些网络一旦训练固定之后, 其结构也固定下来, 因此, 处理的时间也基本上是固定的。

3 物理实验验证

3.1 实验平台说明及数据采集

由于实验条件所限, 由一台民用的三级式发电机作为验证平台进行实验验证。虽然实验的发电机与航空发电机有差别, 但不太影响算法的原理性验证。实验平台如下图 6 所示, 由四个部分组成: 原动机(由一台 11kW 电动机模拟, 电动机则由一台 15kW 的西门子变频器控制转速)、7.5kW 的三级式发电机(输出三相交流电压 230V/50Hz, 额度转速 1500 rpm)、可调式阻性负载、数据采集装置等。为方便设置旋转整流器二极管开路故障, 将原本在转子上的旋转整流器通过电刷和滑环引出固定在机

身上,并在每个二极管所在支路都串联上了断路器进行故障模拟。




图6 旋转整流器故障实验平台

Fig.6 Fault experiment platform of rotating rectifier




图7 空载条件下5种典型故障模式励磁电流波形图

Fig.7 Excitation generator field current wave of 5 typical fault modes in no-load situation

在实际实验中,考虑了无故障、单管故障和双管故障共 22 类故障模式。与仿真实验相同,这里也在空载、1.5kW 负载和 3kW 负载等 3 种条件下进行了实验,然后将交流励磁机励磁电流经数据采集卡连接至计算机进行数据采集,采样率设为 10KHz。每种故障模式采集 100 个样本,其中,随机选 50 个样本作为训练,剩下的 50 个样本作为测试用。样本的选择和分配与仿真实验完全一致。

空载条件下,五种故障模式的交流励磁机励磁电流波形如图 7 所示。与仿真实验不同的是,发电机在连续运行中,需要考虑采样起始点的问题,根据文献[4],主发电机输出相电压与交流励磁机励磁电流的均方根值有一定的比例关系,因此本文选取主发电机的相电压 U_A 作为参考信号来确定采样起

始点,从而对交流励磁机励磁电流进行截取(每个样本有 1000 个数据点)。

3.2 特征提取及诊断

在物理实验中,也采用四种方法进行对比。方法 I 为专家领域知识得到的 1、2、6 次等几种谐波成分。方法 II 利用浅层神经网络提取故障特征。方法 III 为随机选取堆栈自动编码器结构所提取的故障特征。方法 IV 为 GRA-SAE 方法,神经元激活函数设为“sigmoid”函数,每一个自动编码器的迭代次数设为 20 次,灰色关联度系数 ξ 仍然设为 0.05,同样利用随机负载条件下的故障样本对 GRA-SAE 进行训练,得到一组通用网络结构,其余几种负载条件(空载、1.5KW 负载)同样是利用该网络结构进行特征提取。在实际实验中,方法 II、方法 III 和方法 IV 中输入至神经网络中进行故障特征提取的原始样本均需进行均值为 0、方差为 1 的归一化进行预处理。

最后,仍然用 SVM 实施故障诊断,分类器具体参数设置与仿真实验完全相同。三种特征的结果分别如表 6、表 7 和表 8 所示。同样在空载条件下(以 5 维特征提取和评估为例),对各种方法所耗费的 T_1 、 T_2 、 T_a 等进行统计,结果如表 9 所示。

表 6 在 3 维特征下的诊断正确率

Tab.6 Classification accuracy with 3-dimensional features

方法	网络结构(特征)	空载	1.5KW 负载	随机负载
I	$A_1A_2A_6$	94.82%	95.09%	95.91%
II	1000-500-3	67.91%	62.36%	54.00%
II	1000-200-3	45.45%	40.91%	43.09%
III	1000-600-400-200-3	73.27%	79.26%	74.91%
III	1000-750-500-250-3	72.45%	70.36%	71.82%
IV	1000-125-8-5-3	95.45%	95.45%	97.00%

表 7 在 4 维特征下的诊断正确率

Tab.7 Classification accuracy with 4-dimensional features

方法	网络结构(特征)	空载	1.5KW 负载	随机负载
I	$A_1A_2A_6\phi_6$	99.91%	100%	97.82%
II	1000-500-4	72.19%	70.36%	57.91%
II	1000-200-4	61.45%	57.27%	62.09%
III	1000-600-400-200-4	84.09%	83.64%	83.91%
III	1000-750-500-250-4	87.73%	83.45%	85.45%
IV	1000-125-8-5-4	100%	100%	100%

表 8 在 5 维特征下的诊断正确率

Tab.8 Classification accuracy with 5-dimensional features

方法	网络结构 (特征)	空载	1.5KW 负载	随机负载
I	$A_1A_2A_6\phi_1\phi_6$	100%	100%	99.67%
II	1000-500-5	73.82%	73.27%	79.18%
II	1000-200-5	80.82%	80.91%	81.09%
III	1000-600-400-200-5	87.27%	85.09%	85.09%
III	1000-750-500-250-5	91.27%	92.45%	90.36%
IV	1000-125-8-5-5	100%	100%	100%

表 9 四种方法特征提取及诊断耗费时间(s)

Tab.9 Time for several methods (s)

方法	网络结构 (特征)	T_1	T_2	T_a
I	$A_1A_2A_6\phi_1\phi_6$	0.1425	251.3052	0.2286
II	1000-500-5	0.1192	250.6141	0.2279
III	1000-750-500-250-5	0.3169	256.3966	0.2334
IV	1000-125-8-5-5	0.1684	255.8921	0.2328

从表 6-表 8 的物理实验结果来看, 结论与仿真实验结果较为一致。在物理实验中, 在两种负载条件下, 方法 I 取得了很好的诊断效果, 这说明了专家领域知识的重要性和有效性; 方法 II 与方法 III 相比, 浅层神经网络挖掘数据信息的能力不如深度神经网络; 方法 III 在两种分类器下的诊断正确率仍然要低于方法 IV, 这说明 GRA-SAE 方法适合发电机旋转整流器的故障特征提取。此外, 从表 9 的几种分类器特征提取时间和诊断时间可以看出, 仿真和实验所需的时间基本吻合, 这是因为仿真和实验所需的特征提取网络和分类器网络结构比较一致, 因而所消耗的时间应该也相差不大。

4 结论

本文提出了一种基于 GRA-SAE 的故障特征自适应提取方法, 并将其用于发电机旋转整流器二极管故障诊断和定位, 取得了很好的诊断效果。文中的例子说明:

(1) 基于 SAE 的特征提取技术是有效的, 可以用于发电机旋转整流器故障诊断应用中。

(2) SAE 的结构有很多, 对应的网络性能也不同。本文提出的 GRA-SAE 是一种很好的故障特征提取方法, 在仿真和实验中均取得了较好的效果。

参考文献

- [1] J.A. Rosero, J.A. Ortega, E. Aldabas, et al. Moving towards a more electric aircraft[J]. IEEE Aerospace and Electric Systems Magazine, 2007, 22(3): 3-9.
- [2] J. Banks, T. Batzel, R. Keolian, et al. Power System

Prognostics for the U.S. Army OH-58D Helicopter[C]. IEEE Aerospace Conference, Big Sky, MT, USA, March 5-12, 2011, pp: 1-15.

- [3] M. Salah, K. Bacha, A. Chaari, et al. Brushless Three-Phase Synchronous Generator under Rotating Diode Failure Conditions[J]. IEEE Transactions on Energy Conversion, 2014, 29(3): 594-601.
- [4] T.D. Batzel, D.C. Swanson. Prognostic Health Management of Aircraft Power Generator[J]. IEEE Transactions on Aerospace and Electronic Systems, 2009, 45(2): 473-483.
- [5] 张超, 夏立. 交流无刷发电机故障诊断研究综述[J]. 湖南工业大学学报, 2007, 21(5): 103-106.
C. Zhang, L. Xia. A review of fault diagnosis in alternating-current brushless generator[J]. Journal of Hunan University of Technology, 2007, 21(5): 103-106.
- [6] J.Y. Liu, K. Gao, P.F. Liu. Design and application for fault monitoring circuit of rotating rectifier in aviation brushless AC generator[C]. Proceedings of 2014 IEEE Chinese Guidance, Navigation and Control Conference, Yantai, China, August 8-10, 2014, 1235-1239.
- [7] M. Salah, K. Bacha, A. Chaari. Detection of Brushless Exciter Rotating Diodes Failures by Spectral Analysis of Main Output Voltage[C]. International Conference on Electrical Engineering and Software Applications, Hammamet, Tunisia, March 21-23, 2013, 6 pp.
- [8] 张超, 夏立. 基于谐波分析的旋转整流器故障检测[J]. 电机与控制应用, 2008, 35(11): 51-54.
C. Zhang, L. Xia. Fault Detection of Rotary Rectifier Based on Harmonic Analysis[J]. Motor Control and Application, 2008, 35(11): 51-54.
- [9] M.G. McArdle, D.J. Morrow. Noninvasive Detection of Brushless Exciter Rotating Diode Failure[J]. IEEE Transactions on Energy Conversion, 2004, 19(2): 378-383.
- [10] 张敬, 李颖晖, 朱喜华, 等. 三级式发电机旋转整流器故障特征提取[J]. 微电机, 2011, 44(7): 92-96.
J. Zhang, Y.H. Li, X.H. Zhu, et al. Feature extraction of rotating rectifier in three-stage generator[J]. Micromotors, 2011, 44(7): 92-96.
- [11] 刘勇智, 刘聪. 基于 EMD 和 LS-SVM 的旋转整流器故障诊断方法研究[J]. 微电机, 2012, 45(4): 21-24.
Y.Z. Liu, C. Liu. Fault diagnosis of rotating rectifier based on EMD and LS-SVM[J]. Micromotors, 2012, 45(4): 21-24.
- [12] 任磊, 韦微, 龚春英, 等. 电力电子电路功率器件故障特征参数提取技术综述[J]. 中国电机工程学报, 2015, 35(12): 3089-3101.

- Ren Lei, Wei Zheng, Gong Chunying, et al. Fault Feature Extraction Techniques for Power Devices in Power Electronic Converters: A Review[J]. Proceeding of the CSEE, 2015, 35(12): 3089-3101 (in Chinese).
- [13] 王瑾, 严仰光. 旋转整流器式无刷交、直流发电机谐波电枢反应研究[J]. 南京航空航天大学学报, 2000, 32(3): 257-262.
- J. Wang, Y.G. Yan. Research on harmonic armature reaction of brushless ac and dc generator[J]. Journal of Nanjing University of Aeronautics and Astronautics, 2000, 32(3): 257-262.
- [14] Z.P. Feng, M. Liang, F.L. Chu. Recent Advances in Time-Frequency Analysis Methods for Machinery Fault Diagnosis : A Review with Application Examples[J]. Mechanical Systems and Signal Processing, 2013, 38(1): 165-205.
- [15] Y.G. Lei, J. Lin, Z.J. He, et al. A Review on Empirical Mode Decomposition in Fault Diagnosis of Rotating Machinery[J]. Mechanical Systems and Signal Processing, 2013, 35(1-2): 108-126.
- [16] 崔江, 王强, 龚春英. 结合小波与 Concordia 变换的逆变器功率管故障诊断技术研究[J]. 中国电机工程学报, 2015, 35(12): 3110-3116.
- Cui Jiang, Wang Qiang, Gong Chunying. Inverter Power Switch Fault Diagnosis Technique Research Based on Wavelet and Concordia Transform[J]. Proceeding of the CSEE, 2015, 35(12): 3110-3116(in Chinese).
- [17] G. Hinton, S. Osindero, M. Welling, et al. Unsupervised Discovery of Nonlinear Structure Using Contrastive Backpropagation[J]. Science, 2006, 30(4): 725-732.
- [18] Yann LeCun, Youshua Bengio, Geoffrey Hinton. Deep Learning[J]. Nature, 2015, 521: 436-444.
- [19] 孙志军, 薛磊, 许阳明. 深度学习研究综述[J]. 计算机应用研究, 2012, 29(8): 2806-2810.
- Z.J. Sun, L. Xue, Y.M. Xu. A Research Review of Deep Learning[J]. Application research of computer, 2012, 29(8): 2806-2810.
- [20] Y.X. Luo, Y. Wan. A Novel Efficient Method for Training Sparse Auto-Encoders[C]. 6th International Congress on Image and Signal Processing, Hangzhou, China, December 16-18, 2013, 2:1019-1023.
- [21] Hu C, Bai X, Qi L, et al. Vehicle Color Recognition With Spatial Pyramid Deep Learning[J]. IEEE Transactions on Intelligent Transportation Systems, 2015, 16(5): 2925-2934.
- [22] K. Cho, A. Courville, Y. Bengio. Describing Multimedia Content Using Attention-Based Encoder-Decoder Networks[J]. IEEE Transactions on Multimedia, 2015, 17(11): 1875-1886.
- [23] Y. Bengio, A. Courville, P. Vincent. Representation Learning: A Review and New Perspectives[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2013, 35(8): 1798-1828.
- [24] J.B. Tan, W.N. Lu, J.F. Tan, et al. Fault Diagnosis Method Study in Roller Bearing Based on Wavelet Transform and Stacked Auto-encoder[C]. The 27th Chinese Control and Decision Conference, 2015, 4608-4613.
- [25] H. Larochelle, Y. Bengio, J. Louradoer, et al. Exploring Strategies for Training Deep Neural Networks[J]. Journal of Machine Learning Research, 2009, 1: 1-40.
- [26] J. Zou, Z. Yu, H. Zong, et al. Grey relational analysis for query expansion[J]. Communications in Computer & Information Science, 2013, 400: 386-393.
- [27] 崔江, 叶纪青, 陈未, 等. 一种基于改进 M-ary 支持向量机的功率变换器故障分类技术[J]. 中国电机工程学报, 2016, 36(22): 6231-6237.
- Cui Jiang, Ye Jiqing, Chen Wei, et al. Fault Classification of Power Converters Based on M-ary Support Vector Machine Method[J]. Proceeding of the CSEE, 2016, 36(22): 6231-6237 (in Chinese).
- [28] 秦海鸿, 严仰光. 多电飞机的电气系统[M]. 北京航空航天大学出版社, 2015: 80-81.
- [29] A. Widodo, B.S. Yang. Support Vector Machine in Machine Condition Monitoring and Fault Diagnosis[J]. Mechanical Systems and Signal Processing, 2007, 21(6): 2560-2574.
- [30] J. Cui, Y.R. Wang. A Novel Approach of Analog Circuit Fault Diagnosis Using Support Vector Machines Classifier[J]. Measurement, 2011, 44(1): 281-289.



崔江

收稿日期：2016-00-00。

作者简介：

崔江(1977)，男，博士，副教授，主要研究方向为电子电路故障诊断与测试、健康管理等，cuijiang@nuaa.edu.cn；

(责任编辑 李婧妍)

中国知网