

# 基于油中气体分析的变压器故障诊断 深度信念网络方法

代杰杰<sup>1</sup>, 宋辉<sup>1</sup>, 杨祎<sup>2</sup>, 陈玉峰<sup>2</sup>, 盛戈皞<sup>1</sup>, 江秀臣<sup>1</sup>

(1. 上海交通大学电气工程系, 上海市闵行区 200240;

2. 国网山东省电力公司电力科学研究院, 山东省济南市 250002)

## Dissolved Gas Analysis of Insulating Oil for Power Transformer Fault Diagnosis With ReLU-DBN

DAI Jiejie<sup>1</sup>, SONG Hui<sup>1</sup>, YANG Yi<sup>2</sup>, CHEN Yufeng<sup>2</sup>, SHENG Gehao<sup>1</sup>, JIANG Xiuchen<sup>1</sup>

(1. Department of Electrical Engineering, Shanghai Jiao Tong University, Minhang District, Shanghai 200240, China;

2. Electric Power Research Institute of Shandong Power Supply Company of State Grid, Jinan 250002, Shandong Province, China)

**ABSTRACT:** Dissolved gas analysis (DGA) of insulating oil can provide an important basis for transformer fault diagnosis. To improve the diagnosis accuracy, this paper studies a transformer fault diagnosis method based on rectified linear units deep belief networks (ReLU-DBN). By analyzing the relationship between the gases dissolved in transformer oil and fault types, the Non-code ratios of the gases are determined as the characterizing parameter of ReLU-DBN model. ReLU-DBN adopts multi-layer and multi-dimension mapping to extract more detailed differences of fault types. In this process, the parameters of diagnosis model are pre-trained, and adjusted by back propagation algorithm with the labels of the samples. The performances of the ReLU-DBN diagnosis model are analyzed by different characterizing parameters, different training dataset and sample dataset. Besides, the influence of discharge and overheating multiple-fault on the diagnosis model is studied. The diagnosis effect of the model with Non-code ratios as characterizing parameter is better than those of the model with IEC ratios, Rogers ratios and Dornenburg ratios. Compared with the results derived from support vector machine (SVM) and back propagation neural network (BPNN), the proposed ReLU-DBN method significantly improves the accuracy for power transformer fault diagnosis. The diagnosis effect of the model considers multiple-fault is better than those of the model without multiple-fault. With the increase of sample dataset, the diagnostic accuracy is improved.

**KEY WORDS:** transformer; dissolved gas analysis; deep belief networks; Non-code ratios; fault diagnosis

基金资助项目: 国家自然科学基金项目(51477100); 国家 863 高技术基金项目(2015AA050204); 国家电网公司科技项目。

Project supported by National Natural Science Foundation of China (NSFC) (51477100), The National High Technology Research and Development of China(863 Programme)(2015AA050204), Science and Technology Program of State Grid Corporation of China.

**摘要:** 油中溶解气体分析可为变压器故障诊断提供重要依据。为提高变压器故障诊断精度, 本文研究了基于修正线性单元改进的深度信念网络(rectified linear units deep belief networks, ReLU-DBN)变压器故障诊断方法。通过分析油中溶解气体与故障类型的联系, 建立以油色谱特征气体无编码比值为特征参量的 ReLU-DBN 诊断模型。ReLU-DBN 通过多维多层映射提取出故障类型更细致明显的特征区别, 通过反向调优达到诊断模型参数最优化。通过识别实验分析了不同特征参量、不同训练集及样本集大小下 ReLU-DBN 诊断模型效果, 研究了放电兼过热复合型故障对诊断模型的影响, 并与支持向量机、反向传播神经网络方法进行了对比。实验结果表明基于无编码比值的模型诊断效果优于 IEC 比值、Rogers 比值、Dornenburg 比值为特征参量的模型, 且 ReLU-DBN 较支持向量机和反向传播神经网络方法相比诊断准确率有较大提高。区分复合型故障的模型诊断效果优于未区分复合型故障的模型。随样本数据增多, 模型诊断精度得到较大提升。

**关键词:** 变压器; 油中气体分析; 深度信念网络; 无编码比值; 故障诊断

**DOI:** 10.13335/j.1000-3673.pst.2017.1027

## 0 引言

电力变压器是电力系统的关键设备之一, 其运行状态关乎电网能否可靠供电。变压器在运行使用过程中, 由于老化、电、热故障等原因会产生少量气体溶解于绝缘油中, 油中气体的各种成分含量及不同组分间的比例关系与变压器运行状况密切相关。

正常运行状态下的变压器, 因绝缘油和固体绝

缘的老化裂解等会分解出极少量气体，主要为氢气  $H_2$ ，甲烷  $CH_4$ 、乙烷  $C_2H_6$ 、乙烯  $C_2H_4$ 、乙炔  $C_2H_2$ 、一氧化碳  $CO$ 、二氧化碳  $CO_2$ <sup>[1]</sup>。当变压器内部发生故障或异常时，这些气体中的某些组分含量会迅速增加。例如绝缘油过热时， $CH_4$  和  $C_2H_4$  为主要增大的气体成分，且表现出较强相关性；高能放电时  $H_2$  和  $C_2H_2$  含量升高，且表现出较强相关性。因此，通过油中溶解气体分析(dissolved gas analysis, DGA)，可为变压器故障诊断提供重要依据<sup>[2]</sup>。

以 DGA 特征气体为基础形成的三比值法、Rogers 比值法、Dornenburg 比值法、大卫三角形法等操作简单，在实际应用中发挥了重要作用，但存在编码不完备、界限过于绝对等问题<sup>[2-3]</sup>。随着智能算法及机器学习方法的发展，神经网络、支持向量机、模糊集理论、贝叶斯网络、分类回归树、主成分分析等逐渐应用于电力变压器故障诊断方面<sup>[3-8]</sup>，并取得一定成果，但也存在一些问题。例如神经网络有较强的学习能力但易陷入局部最优，在处理大样本数据时收敛速度慢；支持向量机在处理小样本数据时性能突出，但其本质上为二分类器，在处理变压器故障诊断这种多分类问题时效率较低；模糊集方法不需要建立精确模型便可快速给出诊断结果，但其学习能力有限；贝叶斯网络在使用时需要较多的条件属性，不利于现场应用。因学习能力、处理效率、特征提取等方面的不足，上述方法在推广应用时仍有一定的局限性。随着电力大数据的发展及变压器故障缺陷案例的增加，变压器故障模式因型号、电压等级、故障部位、故障能量密度、运行状态等不同所呈现的多样性对故障诊断提出了更高要求。

加拿大学者 Geoffrey Hinton 在 2006 年提出了深度信念网络(deep belief networks, DBN)<sup>[9-10]</sup>，研究表明深度学习模型得到的特征数据对原数据有更本质的代表性，更有利于分类和识别问题。对于深度神经网络很难训练达到最优的问题，可以采用逐层训练方法解决。深度学习方法在特征识别、数据降维、分类预测等方面性能突出<sup>[11-13]</sup>，文献[11]将深度信念网络应用于电力变压器故障分类建模，测试结果表明深度学习方法具有较强的从样本中提取特征的能力和容错特性。

在电力大数据背景下，变压器缺陷故障数据及监测数据增加对深度学习故障诊断模型效率及准确率带来了新的挑战。本文将修正线性单元替代传统激活函数对深度信念网络进行改进。以变压器缺陷案例数据及变压器在线监测正常运行数据为基

础，选用油色谱特征气体无编码比值作为特征参量，构建修正线性单元激活的深度信念(rectified linear units deep belief networks, ReLU-DBN)诊断模型。同时分析了不同特征参量、不同训练集及样本集大小下 ReLU-DBN 诊断模型效果，研究了放电兼过热复合型故障对诊断模型的影响。通过算例分析表明，所提方法较大程度上提高了变压器故障诊断准确率。

## 1 ReLU 深度信念网络

深度信念网络是由多层受限玻尔兹曼机(restricted boltzmann machine, RBM)组成的一种生成模型<sup>[14]</sup>。

### 1.1 受限玻尔兹曼机

RBM 由可视层  $v$  和隐藏层  $h$  组成， $v$  用于输入训练数据， $h$  用作为特征检测器<sup>[15]</sup>。RBM 是一种基于能量的模型，对一组给定状态  $(v, h)$ ，其联合组态能量定义如下：

$$E_{\theta}(v, h) = -\sum_{i=1}^{n_v} a_i v_i - \sum_{j=1}^{n_h} b_j h_j - \sum_{i=1}^{n_v} \sum_{j=1}^{n_h} h_j w_{j,i} v_i \quad (1)$$

式中： $v_i$  为可视层显元状态， $h_j$  为隐藏层隐元状态， $a_i$  和  $b_j$  分别为显元  $i$  和隐元  $j$  的偏置， $w_{j,i}$  为显元  $i$  和隐元  $j$  之间的连接权重， $\theta = \{w_{j,i}, a_i, b_j\}$  为模型参数。

基于能量函数，状态  $(v, h)$  的联合概率分布为

$$P_{\theta}(v, h) = \frac{1}{Z_{\theta}} e^{-E_{\theta}(v, h)} \quad (2)$$

式中： $Z_{\theta} = \sum_{v, h} e^{-E_{\theta}(v, h)}$  为归一化因子，也被称为配分函数。

由于显元及隐元的状态和激活条件独立。第  $j$  个隐元和第  $i$  个显元的激活概率分别为

$$P(h_j = 1 | v) = \sigma(b_j + \sum_{i=1}^{n_v} w_{j,i} v_i) \quad (3)$$

$$P(v_i = 1 | h) = \sigma(a_i + \sum_{j=1}^{n_h} w_{i,j} h_j) \quad (4)$$

式中， $\sigma(\cdot)$  表示激活函数。常见的激活函数为 sigmoid 函数和 tanh 函数，表达式分别见(5)、(6)。

$$\sigma(z) = \frac{1}{1 + e^{-z}} \quad (5)$$

$$\sigma(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}} \quad (6)$$

上述激活函数存在导数及饱和值缩放特性，一旦进行递推式多层反向传播时，梯度误差会不断

衰减,使得网络学习效率降低。本文选用修正线性单元(rectified linear units, **ReLU**函数<sup>[16]</sup>代替传统神经网络的激活函数,如式(7)所示。

$$\sigma(z) = \max(0, z) \quad (7)$$

ReLU 函数梯度为 1,且只有一端饱和,梯度可很好地在反向传播中流动,深层结构收敛性能好,从而提高整个网络的训练速度。

因为归一化因子  $Z_\theta$  的存在,联合概率分布  $P$  求解较为复杂。Hinton 提出的对比散度(contrastive divergence, **CD**算法<sup>[17]</sup>,可对 RBM 快速训练学习。

## 1.2 深度信念网络

经典的 DBN 应用结构是由若干层 RBM 和分类输出层组成的一种深层神经网络,结构如下图所示。




图 1 DBN 应用结构

Fig.1 The typical DBN application structure

DBN 网络采用 CD 算法非监督贪婪逐层预训练模型得到权重。由于每一层 RBM 网络都是独立进行训练,只能保证该层的权重对该层特征向量映射达到最优,并不能保证整个 DBN 网络特征提取和映射达到最优。因此采用梯度下降算法将网络输出与标准数值标签之间的误差自顶向下反向传播至每一层 RBM,微调整个 DBN 模型,实现模型参数最优化。

## 2 基于 ReLU-DBN 的变压器故障诊断模型

### 2.1 特征参量选取

由于从工程现场获取的 DGA 数据,各特征气体的浓度分散性较大,同一故障类型的气体含量波动范围较广,对变压器故障诊断的准确性有一定影响。因此,IEC 推荐使用 DGA 比值对变压器故障进行诊断识别。而常用的 IEC 比值( $\text{CH}_4/\text{H}_2$ ,  $\text{C}_2\text{H}_2/\text{C}_2\text{H}_4$ ,  $\text{C}_2\text{H}_4/\text{C}_2\text{H}_6$ )、Rogers 比值( $\text{CH}_4/\text{H}_2$ ,

$\text{C}_2\text{H}_2/\text{C}_2\text{H}_4$ ,  $\text{C}_2\text{H}_4/\text{C}_2\text{H}_6$ ,  $\text{C}_2\text{H}_6/\text{CH}_4$ )及 Dornenburg 比值( $\text{CH}_4/\text{H}_2$ ,  $\text{C}_2\text{H}_2/\text{C}_2\text{H}_4$ ,  $\text{C}_2\text{H}_2/\text{CH}_4$ ,  $\text{C}_2\text{H}_6/\text{C}_2\text{H}_2$ )等<sup>[1]</sup>因特征量个数有限,不利于变压器故障模式差异化特征提取。

国内外电力工作者通过大量的变压器模拟实验,总结出了过热、放电分解的气体具有如下规律<sup>[18]</sup>:

(1)油中过热低于  $600^\circ\text{C}$  时,产生的主要气体是  $\text{CH}_4$ ,其次是  $\text{C}_2\text{H}_4$ 、 $\text{C}_2\text{H}_6$  和少量  $\text{H}_2$ 。

(2)油中电弧放电时,产生的气体以  $\text{H}_2$  和  $\text{C}_2\text{H}_2$  为主,有少量  $\text{CH}_4$  和  $\text{C}_2\text{H}_4$ 。在纸板和油中电弧放电时产生的 CO 是纯油中的 10 多倍。

(3)在局部放电中无  $\text{C}_2\text{H}_2$ ,且  $\text{CH}_4$  较多。

(4)火花放电产生的气体近似于电弧放电。

利用上述性质,可用某些特征气体的含量和它们之间的比值来鉴别变压器中存在的不同类型的故障。文献[18]提出了 9 种不同组合形式的气体比率值,将这些计算结果按变压器实际故障分类统计,从中找出故障性质相关的量,用与故障性质相关的气体比率来确定故障类型,形成了变压器故障的无编码比值诊断法。无编码比值包括以下气体浓度比值:  $\text{CH}_4/\text{H}_2$ ,  $\text{C}_2\text{H}_4/\text{C}_2\text{H}_2$ ,  $\text{C}_2\text{H}_4/\text{C}_2\text{H}_6$ ,  $\text{C}_2\text{H}_2/(\text{C}_1+\text{C}_2)$ ,  $\text{H}_2/(\text{H}_2+\text{C}_1+\text{C}_2)$ ,  $\text{C}_2\text{H}_4/(\text{C}_1+\text{C}_2)$ ,  $\text{CH}_4/(\text{C}_1+\text{C}_2)$ ,  $\text{C}_2\text{H}_6/(\text{C}_1+\text{C}_2)$ ,  $(\text{CH}_4+\text{C}_2\text{H}_4)/(\text{C}_1+\text{C}_2)$ 。其中,  $\text{C}_1$  为  $\text{CH}_4$  所代表的一阶碳氢化合物,  $\text{C}_2$  为  $\text{C}_2\text{H}_6$ 、 $\text{C}_2\text{H}_4$ 、 $\text{C}_2\text{H}_2$  所代表的二阶碳氢化合物。

本文将无编码比值作为诊断模型的特征参量,与常用比值法相比包含更多的特征信息,样本数据特征间差异化信息可得到更充分的表示。

### 2.2 特征参量选取

依据 IEC 60599 标准,故障模式分为低温过热、中温过热、高温过热、局部放电、低能放电和高能放电 6 种。通过对变压器故障案例搜集整理发现,长期的放电故障引起变压器绝缘油温上升,引发设备过热故障,使得油色谱数据中放电和过热故障特征兼有,对此类数据如不加以区分,势必会对故障类型的诊断产生一定的影响。参考《变压器油中溶解气体分析和判断导则》,补充低能放电兼过热、高能放电兼过热两种复合故障类型<sup>[19]</sup>。综合正常运行状态数据,本文对变压器故障标签编码如下: 1--正常, 2--低温过热, 3--中温过热, 4--高温过热, 5--局部放电, 6--低能放电, 7--高能放电, 8--低能放电兼过热, 9--高能放电兼过热。针对非线性多分类问题,采用 Softmax 分类器对诊断结果进行输出。

### 2.3 样本数据分布



本文使用的 DGA 数据来自：1) 变压器在线监测数据；2) 变压器离线实验数据；3) 变压器历史故障数据集；4) 出版物。前三项中数据由国家电网公司提供，变压器电压等级为 35kV~750kV，其中历史故障数据集中变压器遍布全国 28 省，变压器投运时间自 1989 年起。最后一项包括 IEC TC 10 数据库和已发表论文中确定故障类型的 DGA 数据[4,8,20,21]。由上述 DGA 数据组成变压器故障样本库，共 4642 例典型故障信息。其中：正常数据 688 例，低温过热 599 例，中温过热 511 例，高温过热 722 例，局部放电 564 例，低能放电 599 例，高能放电 576 例，低能放电兼过热 132 例，高能放电兼过热 251 例。将样本数据随机划分为训练集和测试集，训练集和测试集中各类型样本个数如表 1 所示。

表 1 样本数据具体分布

Table 1 Distribution of the samples

模式类型	样本数据	训练样本	测试样本
正常	688	553	135
低温过热	599	480	119
中温过热	511	405	106
高温过热	722	562	160
局部放电	564	454	110
低能放电	599	486	113
高能放电	576	473	103
低能放电兼过热	132	100	32
高能放电兼过热	251	201	50
总计	4642	3714	928

## 2.4 诊断模型应用步骤及架构

初始化连接权重为服从正态分布  $N(0,0.01)$  的随机数，偏置项为 0。设定权重学习率、偏置项学习率为 0.1，权重衰减项为 0.0008。为改善反向传播算法的收敛速度与算法不稳定性之间的矛盾，初始动量项设为 0.5，在重构误差处于平稳增加状态时动量项设为 0.9<sup>[22]</sup>。经过实验发现，网络结构层数与诊断准确率的关系如图 2 所示。当网络层数从 1 层增加至 4 层，预测正确率大幅提升，由 4 层增加至 8 层，准确率提升效果微弱。综合模型诊断效果及运算效率，本文确定网络结构为 4 层。输入为无编码 9 种比值，输出为 9 种故障类型，网络结构规模为 9-20-20-10-9。

本文分别采用 ReLU 与传统 sigmoid、tanh 函数分别对 DBN 网络进行了训练，其收敛性对比如图 3 所示。




图 2 网络结构层数与诊断准确率的关系

Fig.2 The relationship between network layers and the diagnosis average accuracy

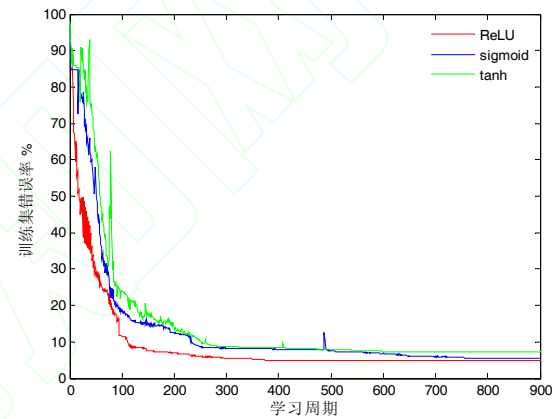


图 3 收敛性能对比

Fig.3 Comparison of convergence performance

由图 3 可见，训练初期分类误差较大，三类激活函数反向传播梯度大，错误率均大幅降低。随着错误率下降，sigmoid 函数和 tanh 梯度误差衰减，收敛性能降低。sigmoid 激活网络经过 809 个学习周期，训练集诊断错误率稳定在 4.79%。tanh 激活网络经过 611 个学习周期，训练集诊断错误率稳定在 7.26%。ReLU 函数在错误率较低的情况下，反向传播梯度不受影响，达到稳定错误率 3.62% 仅用 417 个学习周期。相比传统 sigmoid 和 tanh 网络结构，ReLU 函数激活的 DBN 具有较高的训练学习速率。依据图 3，本文设定学习周期为 500。

## 2.5 模型参数设定

基于深度信念网络的变压器故障诊断模型如图 4 所示。具体应用步骤如下：

- 1) 选取无编码比值作为模型的特征参量；
- 2) 按比例将样本数据划分为训练集和测试集；
- 3) 采用 CD 算法对 ReLU-DBN 预训练，通过反

向传播算法和随机梯度下降法利用故障标签对网络参数微调,实现模型参数最优化;

4)利用训练参数对测试集数据进行诊断测试;

5)依据新增样本数据及故障诊断准确率,对模型重新训练,实现参数更新。

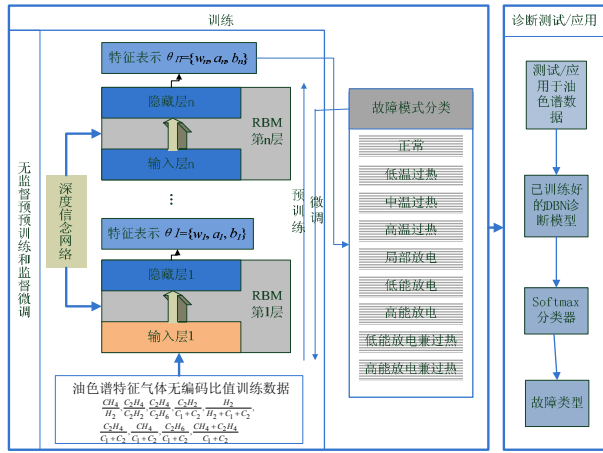


图4 基于 ReLU-DBN 的变压器故障诊断模型  
Fig.4 Transformer fault diagnosis model based on ReLU-DBN

### 3 算例分析

#### 3.1 不同特征参量对比

按表1中样本数据分布将无编码比值作为输入特征参量,对 ReLU-DBN 模型进行测试。为验证本文所提方法,将 IEC 三比值、Rogers 比值及 Dornenburg 比值作为 ReLU-DBN 特征参量分别进行计算。同时,将上述四种不同特征参量分别在 SVM 和 BPNN 模型上进行诊断识别。其中 SVM 模型选用径向基核函数(radial basis function, RBF),通过交叉验证得最优惩罚因子为 0.1, RBF 核参数为  $10^4$ 。BPNN 结构为输入层、隐藏层、输出层,各层神经元个数分别为 9、20、9,模型中学习率为 0.01,学习周期为 1000。结果如表 2 所示。

表 2 不同特征参量的诊断准确率(%)  
Table 2 Diagnosis accuracy of different characterizing parameters (in percentage)

方法/特征	IEC 比值		Rogers 比值		Dornenburg 比值		无编码 比值	
	训	测	训	测	训	测	训	测
参量	练	试	练	试	练	试	练	试
比值法	76.2	75.6	81.8	80.4	57.8	56.3	86.7	85.2
SVM	84.2	84.5	88.7	87.5	70.2	67.5	93.0	92.3
BPNN	80.7	79.8	85.3	83.9	63.1	61.5	92.1	91.4
ReLU-DBN	86.0	84.9	91.8	92.3	73.9	73.5	96.4	95.9

由表 2 可知,诊断准确率按比值法、BPNN、

SVM、ReLU-DBN 依次提升。此外,训练和测试准确率按输入向量为 Dornenburg 比值、IEC 比值、Rogers 比值、无编码比值依次上升。其中,以无编码比值为输入特征向量的 ReLU-DBN 拥有最佳诊断效果,训练和测试准确率分别为 96.4%和 95.9%。与无编码比值法、无编码比值为输入的 SVM 和 BPNN 相比,训练准确率分别提升了 9.7%, 3.4% 和 4.3%,测试准确率分别提升了 10.7%, 3.6%和 4.5%。与输入向量为 IEC 比值、Rogers 比值和 Dornenburg 比值的 ReLU-DBN 相比,训练准确率分别提升了 10.4%, 4.6%和 22.5%,测试准确率分别提升了 11.0%, 3.6%和 22.4%。

将训练集中随机选取的 100 例样本与测试集中随机选取的 100 例样本互换,以无编码比值为输入向量对模型进行训练测试,重复 10 次。SVM、BPNN 及 DBN 模型训练平均准确率为 93.0%, 92.0%, 96.5%,测试平均准确率为 92.4%, 91.2%, 95.9%。DBN 模型保持较高准确率,有较强诊断稳定性。

在模型训练效率方面,各模型训练时间如下图所示。其中,特征参量为无编码比值的模型在训练阶段耗时最长,SVM、BPNN 和 DBN 的训练时间分别为 313 秒、343 秒和 301 秒。无编码比值包含较多输入信息,在故障特征提取学习时信息量更大,训练效率低。DBN 虽然网络结构比 SVM 和 BPNN 复杂,但采用 CD 算法逐层预训练,对参数分布有较好的预估计,并且 ReLU 激活函数反向传播时梯度无消散,模型收敛速度快,训练时间较短。

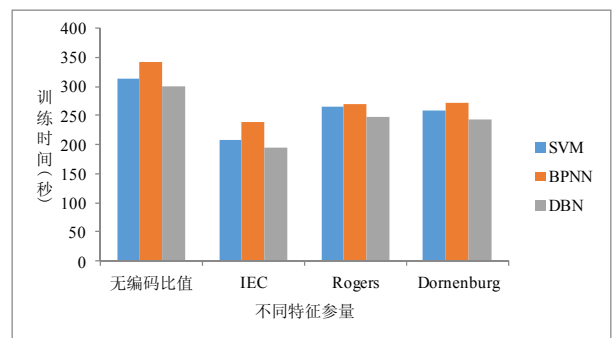


图 5 模型训练时效性

Fig.5 Comparison of training efficiency

无编码比值与其三种比值法相比包含更多隐藏的故障特征信息,通过深度信念网络的自主学习能力,可以有效提高变压器故障诊断模型的差异化特征提取性能。

#### 3.2 不同样本集对比

为进一步验证诊断模型的稳定性,将表 1 中样本数据逐步减小为 4000, 3000, 2000, 1000, 500,

按 8:2 的比例将样本库划分为训练集和测试集，得到如表 3 所示的结果。

表 3 不同样本集的诊断准确率  
Table 3 Transformer fault diagnosis accuracy on the different sample sets (in percentage)

样本集	SVM		BPNN		ReLU-DBN	
	训练	测试	训练	测试	训练	测试
500	72.3	69.0	64.6	62.5	89.0	80.5
1000	78.0	77.6	73.8	71.1	92.6	87.8
2000	87.3	86.8	86.0	85.1	95.3	92.0
3000	90.7	89.5	89.1	88.4	95.5	93.8
4000	92.8	92.1	91.7	90.5	96.2	95.4

按表 1 中数据分布，保持测试集规模为 928 不变，以无编码比值为输入参量分别对规模为 464、928、1856、2784、3714 的训练集进行特征学习。为验证训练数据规模对特征提取的影响，本文参考文献[23]中所提的 SMOTEBoost 技术对样本数据进行补充，样本规模大至 6496，按上述测试集和训练集比例递增关系，训练集可至 4640 和 5568。考三种算法的测试集诊断效果，如表 4 所示。

表 4 不同训练集的诊断准确率(%)  
Table 4Transformer fault diagnosis case on the different training sample sets (in percentage)

训练集	SVM		BPNN		ReLU-DBN	
	训练	测试	训练	测试	训练	测试
464	74.0	72.6	68.3	64.9	91.2	86.4
928	84.1	80.8	73.5	72.4	92.0	89.0
1856	88.0	87.8	86.6	85.2	93.4	92.0
2784	92.2	91.3	91.0	90.4	94.6	93.3
3714	93.0	92.3	92.1	91.4	96.4	95.9
4640	93.7	93.5	93.0	92.7	97.5	97.1
5568	94.3	94.0	93.8	93.6	98.4	98.1

由表 3、4 可知，变压器故障诊断准确率与模型训练样本中所包含的特征信息密切相关，随着训练集的增大，诊断模型从训练数据中可提取的特征信息多，诊断准确率也高。变压器故障模式因型号、电压等级、运行状态等不同所呈现的多样性，被大样本间所覆盖，深度网络结构可更全面的提取出样本间中更深层更全面的特征。与 SVM、BPNN 相比，随着样本集的完善，ReLU-DBN 模型可以取得更好的分类效果。

3.3 复合型故障影响

若不对复合故障加以区分，此时变压器状态模式为正常、低温过热、中温过热、高温过热、局部

放电、低能放电和高能放电 7 种。将表 1 中低能放电兼过热和高能放电兼过热样本作为无标签数据，同其 7 种类型数据混合以无编码比值为输入特征向量，诊断结果如表 5 所示。

表 5 复合故障对诊断模型的影响效果(诊断准确率%)  
Table 5Diagnosis accuracy of seven types label data with the mixed dataset (in percentage)

故障模式	SVM		BPNN		ReLU-DBN	
	训练	测试	训练	测试	训练	测试
1	93.8	91.5	92.0	91.3	95.1	93.3
2	85.7	85.3	84.7	84.0	86.8	86.7
3	85.7	85.8	85.9	85.8	87.4	86.7
4	87.1	86.6	86.5	85.9	92.7	91.3
5	88.8	88.6	87.4	86.6	92.1	91.2
6	84.2	83.2	84.6	84.2	89.0	87.3
7	87.9	87.5	85.2	84.7	88.5	87.6
总体	87.8	86.9	86.6	86.1	90.2	89.2

因为无标签数据放电和过热特征兼有，所以在特征学习过程中，容易模糊故障类型间分类信息。由表 5 可知，若不对放电兼过热复合故障进行区分，SVM、BPNN 和 ReLU-DBN 的诊断精度将大幅降低，与 BPNN 和 SVM 相比，虽然 ReLU-DBN 依然拥有最佳识别效果，但训练和测试精度仅为 90.2% 和 89.2%。其中，低、中温过热和低能放电之间的误判率较高，低、中、高温过热类型与高能放电之间误判率较高。复合故障对正常类型诊断精度影响较小，其放电和过热故障因特征重叠，诊断精度大幅降低。因此，区分复合型故障的模型相比于未区分复合型故障的模型更符合于实际工程应用。

4 结论

针对电力变压器故障多样性导致诊断精度低的问题，本文提出了基于无编码比值的故障诊断 ReLU-DBN 方法。结论如下：

- 1) 相比 SVM、BPNN 算法，ReLU-DBN 方法在无编码比值、IEC 值、Rogers 比值、Dornenburg 比值作为特征参量的诊断模型中均得到更好的识别效果。其中无编码比值为特征参量的模型相比其三种特征参量的模型识别准确率更高。
- 2) ReLU-DBN 通过深层学习过程，逐层提取故障数据所隐含的相关特征信息，细致表征故障数据与故障类型的内在联系。将复合型故障与单一故障区分输出的模型相比未区分输出的模型总体识别准确率更高。
- 3) 深度网络结构自动提取样本间的特征信息，提高了模型的鲁棒性和泛化能力。



多样性特征,诊断模型参数随着样本集的一 大而完善,本文所提模型为电力设备状态大数据的发展应用提供了一种 。下一步将 合变压器故障及缺陷的类型、 重程度及其置信度,进一步完善基于深度学习的智能诊断模型。结合不 工况、电网运行状态、家 缺陷和 因 对设备状态变化的影响,构建基于大数据样本的多维度设备故障诊断模型。

## 参考文献

- [1] 一, 平 三比值 关联度分析的变压器故障诊断法[J] 高电压技术, 2002, 28(10): 16-17  
LIU Yi, NI Yuanping. A transformer faults diagnosis method based on the grey correlation theory[J]. High Voltage Engineering, 2002, 28(10): 16-17.
- [2] IEC-60599 Mineral oil-impregnated electrical equipment in service guide to the interpretation of dissolved and free gases analysis[S]. International Electrotechnical Commission, 2007.
- [3] 强, 特放, 采用自组 RBF 网络算法的变压器故障诊断[J] 高电压技术, 2012, 38(6): 1368-1375  
FU Qiang, CHEN Tefang, ZHU Jiaojiao. Transformer fault diagnosis using self-adaptive RBF neural network algorithm[J]. High Voltage Engineering, 2012, 38(6): 1368-1375.
- [4] 利, 金 组合核相关向量机在电力变压器故障诊断中的应用研究[J] 中国电机工程学 , 2013, 33(22): 68-74  
ZHU Yongli, YIN Jinliang. Study on application of multi-kernel learning relevance vector machines in fault diagnosis of power transformers[J]. Proceedings of the CSEE, 2013, 33(22): 68-74.
- [5] , 基于模糊 类和完全二叉树支持向量机的变压器故障诊断[J] 电工技术学 , 2016, 31(4): 64-70  
LI Ying, SHU Naiqiu. Transformer Fault diagnosis based on fuzzy clustering and complete binary tree support vector machine[J]. Transactions of China Electrotechnical Society, 2016, 31(4): 64-70.
- [6] 强, 律方成, 和明 基于 集理论和贝叶斯网络的电力变压器故障诊断方法[J] 中国电机工程学 , 2006, 26(8): 137-141  
WANG Yongqiang, LV Fangcheng, LI Heming. Synthetic fault diagnosis method of power transformer based on rough set theory and Bayesian network[J]. Proceedings of the CSEE, 2006, 26(8): 137-141.
- [7] 新波, 文 子, , 等 采用 传算法优化 分类回归树组合算法的变压器故障诊断[J] 高电压技术, 2016, 42(5): 1617-1623  
HUANG Xinbo, LI Wenjunzi, SONG Tong, et al. Application of bagging-CART algorithm optimized by genetic algorithm in transformer fault diagnosis[J]. High Voltage Engineering, 2016, 42(5): 1617-1623.
- [8] 波, 卫 , , 等 PCA 和 KICA 特征提取的变压器故障诊断模型[J] 高电压技术, 2014, 40(2): 557-563  
TANG Yongbo, GUI Weihua, PENG Tao, et al. Transformer fault diagnosis model based on PCA and KICA feature extraction[J]. High Voltage Engineering, 2014, 40(2): 557-563.
- [9] Hinton G, Simon O, Yee-Whye T. A fast learning algorithm for deep belief nets[J]. Neural Computation, 2006, 18(7):1527-1554.
- [10] Hinton G, Salakhutdinov R.R. Reducing the dimensionality of data with neural networks[J]. Science, 2006, 313(5786):504-507.
- [11] , 利, 初 , 等 基于深度信念网络的电力变压器故障分类建模[J] 电力系统保 与 , 2016, 44(1): 71-76  
SHI Xin, ZHU Yongli, SA Churila, et al. Power transformer fault classifying model based on deep belief network[J]. Power System Protection and Control, 2016, 44(1): 71-76.
- [12] , , 为 , 等 一种基于受限玻尔兹曼机的特征提取算法[J] 器 表学 , 2016, 37(2): 256-262  
FENG Yong, XIONG Qingyu, SHI Weiren, et al. Speaker feature extraction algorithm based on restricted Boltzmann[J]. Chinese Journal of Scientific Instrument, 2016, 37(2): 256-262.
- [13] Bengio Y. Learning deep architectures for AI[J]. Foundations and Trends in Machine Learning, 2009, 2(1):1-127.
- [14] Smolensky P. Information processing in dynamical systems: Foundations of harmony theory[M]. Cambridge, MA: MIT Press, 1986.
- [15] Salakhutdinov R.R, Hinton G. An efficient learning procedure for deep Boltzmann machines[J]. Neural Computation, 2012, 24(8): 1967-2006.
- [16] Zeiler M.D, Ranzato M, Monga R, et al. On rectified linear units for speech processing[C]. Proceedings of IEEE International Conference on Acoustics, Speech and Signal Processing. Vancouver, Canada, 2013.
- [17] Hinton G. Training products of experts by minimizing contrastive divergence[J]. Neural Computation, 2002, 14(8):1771-1800.
- [18] 新, , , 等 电气设备油中气体在线监测与故障诊断技术[M] : 科学出版 , 2003: 31-56  
SUNCaixin, CHENWeigen, LI Jian, et al. Gas Online Monitoring and Fault Diagnosis Technology in Electrical Equipment[M]. Beijing: Science Press, 2003: 31-56.
- [19] DL/T 722-2014 变压器油中溶解气体分析和判断导则[S] : 国家能 局, 2014  
DL/T 722-2014 Guide to the Analysis and the Diagnosis of Gases Dissolved in Transformer Oil[S]. Beijing, China: National Energy Administration, 2014.
- [20] 平, 新, , 等 诊断电力变压器故障的一种 色关联度分析模式及方法[J] 中国电机工程学 , 2001, 21(10): 106-109  
ZHENG Haiping, SUN Caixin, LI Jian, et al. A model and method of degree of grey incidence analysis on transformer fault diagnosis[J]. Proceedings of the CSEE, 2001, 21(10): 106-109.
- [21] , , 立 , 等 基于改进型主成分分析的变压器 性故障诊断[J] 电力自动化设备, 2015, 35(6): 149-153, 165  
YANG Tingfang, ZHANG Hang, HUANG Libin, et al. In-cipient fault diagnosis based on improved principal component analysis for power transformer[J]. Electric Power Automation Equipment, 2015, 35(6): 149-153, 165.
- [22] Hinton G : A practical guide to training restricted boltzmannmachines[EB/OL]. Toronto, Canada: Department of Computer Science, University of Toronto, 2010[2010-08-02].http://www.cs.toronto.edu/~hinton/.
- [23] Cui Y, Ma H, TapanS. Improvement of power transformer insulation diagnosis using oil characteristics data preprocessed by SMOTEBoosttechnique[J]. IEEE transactions on Dielectrics and Electrical Insulation, 2014, 21(5):2363-2373.



代杰杰

收稿日期: 2017-05-31。

作者简介:

代杰杰(1986), , 通 作者, 研究生, 研究方向为智能输变电设备故障诊断、预测, E-mail: secess@163.com;

峰(1974), , , 研究方向为智能输变电技术, E-mail: shenghe@sju.edu.cn。

( 责任编辑马晓华 )

