

基于深度学习的航空发动机故障融合诊断

车畅畅¹, 王华伟¹, 倪晓梅¹, 洪骥宇¹

(1.南京航空航天大学 民航学院, 南京 2111061)

摘 要: 通过对航空发动机故障诊断, 能够正确判断各部件工作状态, 快速确定维修方案, 保证飞行安全。在结合深度信念网络和决策融合理论的基础上, 提出了基于深度学习的航空发动机故障融合诊断模型。该模型通过分析发动机的大量性能参数, 首先利用深度学习算法提取出性能参数中的隐藏特征得出故障分类置信度; 然后对多次故障分类结果进行决策融合, 从而得出更准确的诊断结果。将普惠 JT9D-74R 发动机故障系数用于数据仿真, 通过实例验证本文提出算法的有效性; 算例计算结果表明: 多次实验结果经数据融合提高了可信度, 该模型具有较高的故障分类诊断准确性和抗干扰能力。

关 键 词: 深度学习; 故障诊断; 决策融合; 抗干扰能力; 航空发动机

中图分类号: V263.6; TK418

文献标识码: A

文章编号: 1001-5965 (XXXX) XX-XXXX-XX

航空发动机结构复杂, 数学模型严重非线性, 多故障类型之间监控数据变化相似程度高, 同时测量误差容易对气路故障诊断造成干扰, 从而影响故障诊断结果的准确性和可靠性。目前航空发动机故障诊断的研究主要有^[1]基于模型的故障诊断 (如卡尔曼滤波器模型)、基于信号和数据处理的故障诊断 (如神经网络、支持向量机等智能算法)、基于知识的故障诊断 (如D-S证据理论、故障树理论、蒙特卡罗方法)。薛薇^[2]针对航空发动机传感器特征, 设计出对应的滤波器来进行故障诊断, 提出传感器和执行机构信息融合的诊断方案; 俞刚^[3]先将航空发动机异常监测参数输入到最小二乘支持向量机模型中, 得出故障分类结果; 再用卡尔曼滤波器估计故障参数, 从而完成故障综合诊断; 廖洪一^[4]使用费舍尔判别分析法和云模型理论, 将从子空间中提取出的特征输入到极限学习机模型中来诊断航空发动机故障, 进一步确定相应的故障类型; 赵世荣^[5]针对航空发动机气路部件故障, 融合神经网络算法和模糊集合论, 建立故障诊断模型, 估计与判断出故障状态; 徐启华^[6]建立了基于层次支持向量机的快速多分类算法模型, 研究了大数据样本条件下的航空发动机多类故障诊断问题; 孙伟超^[7]融合粗糙集和证据诊断理论, 提出了用于解决航空

电子装备多源故障诊断信息冲突问题的故障诊断方法; 于劲松^[8]建立了贝叶斯网络模型的量化评价指标, 为故障诊断系统的性能评价提供依据; Allen H. Tai^[9]使用了隐马尔科夫模型监测在过程控制中的机械故障, 该模型能够对可辨别以及不可辨别的单元进行分析; M.J. Gomez^[10]使用小波变换与径向基人工神经网络架构结合的模型从振动信号入手检测转轴裂缝, 对机械参数和缺陷条件进行故障识别, 并调节模型参数对成功率进行优化; Bajric R^[11]提出了一种基于离散小波变换和时间同步平均的故障诊断新方法, 用于高速轴齿轮剥落故障诊断和跟踪, 提高了变速箱故障诊断能力; Simani S^[12]从模型结构、参数辨识方法、残差生成技术、故障诊断策略出发, 建立了基于模糊识别的故障诊断模型, 用于复杂系统动态故障诊断。

从上述研究可以发现, 使用单一模型进行故障诊断时结果抗干扰性较差; 在使用多种模型结合进行故障诊断又存在建模复杂, 输出结果不直观等问题, 当研究对象的故障特征发生变换时, 就会严重影响故障诊断准确度。基于上述问题, 本文在结合深度学习方法和决策融合理论的基础上, 提出了基于深度学习的航空发动机故障融合诊断方法, 把航空发动机的性能参数和故障类型样本输入到深度

收稿日期: 2017-04-05; 录用日期: ; 网络出版时间: 2017-09-01 18:08:14

网络出版地址: <http://kns.cnki.net/kcms/detail/11.2625.V.20170901.1808.005.html>

基金项目: 国家自然科学基金资助项目 (71401073); 国家自然科学基金和中国民航局联合资助项目 (U1233115)

作者简介: 车畅畅 (1994-), 男, 河南驻马店人, 硕士研究生, 821116775@qq.com

*通讯作者: 王华伟, 教授, wang hw66@163.com

引用格式:

信念网络模型中,提取出样本特征,从而输出故障分类数据,然后把输出数据带入到**决策融合算法**模型中进行决策融合,得出航空发动机故障融合诊断结果。该方法能够在结合两种模型优势的基础上,模型结构简单,不仅有效提高故障诊断准确度,而且能够得出更加直观的故障诊断结果,同时有一定抗干扰性。通过数据仿真实验,验证出该方法的有效性。

1 航空发动机故障诊断

航空发动机故障诊断能够在检测出系统故障时,分离故障部件、判断故障种类、评估故障严重程度,从而在第一时间展开维修工作,减少经济损失。在发动机试验故障诊断中,可利用的状态信息有:发动机振动、气动热力等过程参数、滑油参数以及试验操纵控制信息等。由于航空发动机结构复杂性,单纯依靠单一信息进行故障诊断的准确度不高,多元状态监测信息从不同角度实现了对故障的深层次认识,能够提高故障诊断的准确度。本文采用基于深度学习的故障融合诊断方法对发动机主要参数^[13]如:低压转子转速N1、高压转子转速N2、排气口燃气温度EGT、燃油量消耗量FF建立模型,然后进行故障融合诊断。

2 深度学习与决策融合算法

2.1 深度学习算法理论

深度学习是相对于浅层学习而言的,浅层学习包可以BP神经网络、支持向量机、最大熵方法等。这些模型结构只含有一层隐层或者没有隐层,理论分析难度大,同时训练方法依赖于经验和技巧,得出的样本特征也较为浅显。相对于浅层学习,深度学习模型是多隐层的人工神经网络,通过无监督学习实现网络模型的逐层学习,具有良好的特征提取和学习能力,在样本分类方面有独特的优势。深度学习算法的主要包括深度信念网络、卷积神经网络、循环神经网络等。深度信念网络模型较为灵活,与其他方法的兼容性较好,因此本文采用深度信念网络模型用于故障分类,并将分类结果输入决策融合模型得出故障融合诊断结果。

深度信念网络(DBN)由多个限制玻尔兹曼机^[14](restricted boltzmann machine, RBM)层组成,一个典型的RBM结构如图1所示。该结构包括三个部分:显层 v 、隐层 h 、偏置层。其中显层作为输入层,隐层作为输出层,偏置层用来控制隐层和显层节点的激活,层内单元间相互独立。




图1 RBM结构图

Fig.1 Structure diagram of RBM

设显层向量为 v ,隐层向量为 h ,权值向量为 w ;对显层偏置为 a ,隐层偏置为 b 。对隐层和显层各单元参数定义如下:

$$v = (v_1, v_2, \dots, v_i, \dots, v_m), (i, m \in Z^+);$$

$$h = (h_1, h_2, \dots, h_j, \dots, h_n), (j, n \in Z^+);$$

$$w = (w_{ij}), (i \in [1, m], j \in [1, n]);$$

$$a = (a_1, a_2, \dots, a_i, \dots, a_m);$$

$$b = (b_1, b_2, \dots, b_j, \dots, b_n)$$

2.1.1 建立深度信念网络模型

深度信念网络模型需要引入能量函数,首先用能量函数推导出可视层和隐藏层的条件概率;然后求解偏置层,得出可视层和隐藏层被激活的概率;最后求解能量函数,对模型参数进行更新。

1) 引入能量函数

网络的稳态对应能量函数最低值状态,针对RBM模型而言,输入 v 向量和隐含层输出向量 h 之间的能量函数值为:

$$E(v, h) = -\sum_{i=1}^m a_i v_i - \sum_{j=1}^n b_j h_j - \sum_{j=1}^n \sum_{i=1}^m v_i h_j w_{ij} \quad (1)$$

2) 求隐层和显层的条件概率分布

v 和 h 的联合概率为:

$$P(v, h) = \frac{1}{Z} e^{-E(v, h)} \quad (2)$$

其中 Z 是归一化因子, $Z = \sum_{v, h} e^{-E(v, h)}$ 。关于 v 和 h 的概率分布函数为:

$$P(v) = \sum_h P(v, h) = \sum_h \frac{1}{Z} e^{-E(v, h)} \quad (3)$$

$$P(h) = \sum_v P(v, h) = \sum_v \frac{1}{Z} e^{-E(v, h)} \quad (4)$$

$$P(v|h) = \frac{P(v, h)}{P(h)} = \frac{e^{-E(v, h)}}{\sum_v e^{-E(v, h)}} \quad (5)$$

$$P(h|v) = \frac{P(v, h)}{P(v)} = \frac{e^{-E(v, h)}}{\sum_h e^{-E(v, h)}} \quad (6)$$

3) 偏置层求解

通过隐层和显层的条件概率和能量函数可得隐层和显层个节点被激活（取值为1）的概率，从而对偏置层求解：

$$P(h_j=1|v) = \frac{P(h_j=1, v)}{P(h_j=1, v) + P(h_j=0, v)}$$

$$= \text{sigm}\left(\sum_{i=1}^m a_i + w_{ij}v_i\right) \quad (7)$$

$$P(v_i=1|h) = \frac{P(v_i=1, h)}{P(v_i=1, h) + P(v_i=0, h)}$$

$$= \text{sigm}\left(\sum_{j=1}^n b_j + w_{ij}h_j\right) \quad (8)$$

其中 $\text{sigm}(x) = \frac{1}{1+e^{-x}}$ 。

4) 能量函数求解

引入自由能量函数 $f(v) = -\ln \sum_h e^{-E(v, h)}$ ，则有：

$$P(v) = \frac{e^{-f(v)}}{\sum_v e^{-f(v)}} \quad (9)$$

从上面能量函数的抽象介绍中可以看出，如果要使系统（这里即指DBN网络）达到稳定，则应该是系统的能量值最小。由上面的公式可知，要使能量 $E(x)$ 最小，应该使 $F(x)$ 最小，也就是要使 $P(x)$ 最大。因此此时的损失函数可以看做是 $-P(x)$ 。且求导时需要是加上负号的。设 $\theta = \{a, b, w\}$ ，对 $P(v; \theta)$ 求偏导取负可得：

$$-\frac{\partial \ln P(v; \theta)}{\partial \theta} = \frac{\partial f(v; \theta)}{\partial \theta} = \sum_v P(v; \theta) \frac{\partial f(v; \theta)}{\partial \theta} \quad (10)$$

将 $E(v, h)$ 的公式带入可得：

$$-\frac{\partial \ln P(v)}{w_{ij}} = -\sum_h \left[P(h|v) \left(\frac{\partial E(v, h)}{\partial w_{ij}} \right) - \sum_{v, h} P(v, h) \left(\frac{\partial E(v, h)}{\partial w_{ij}} \right) \right]$$

$$= -\left[\sum_v P(v) (P(h_j=0|v) + P(h_j=1|v)v_i h_j - \sum_v P(v) (P(h_j=0|v) + P(h_j=1|v)v_i h_j)) \right]$$

$$= -P(h_j=1|v)v_i + \sum_v P(v) P(h_j=1|v)v_i \quad (11)$$

同理可得 $P(v; \theta)$ 的偏导展开有：

$$-\frac{\partial \ln P(v)}{\partial a_i} = -\sum_v P(v) P(h_j=1|v) + P(h_j=1|v) \quad (12)$$

$$-\frac{\partial \ln P(v)}{\partial b_j} = -\sum_v P(v) v_i + v_i \quad (13)$$

从偏导结果可以看出左边的减数是输入样本数据的自由能量函数期望值， v 状态已知。右边的被减数是模型产生样本数据的自由能量函数期望值， v 状态未知。

2.1.2 训练深度信念网络模型

1) 深度信念网络训练流程

深度信念网络由多层 RBM 组成，是一种无监督学习模型，有一定的“黑箱性”。在实际应用过程中为了方便理解，更加直观得出分类结果，需要利用已知特征的样本对模型反向修正，相当于上述的 RBM 结构从隐层推导出显层，使故障样本的性能参数与故障类型想匹配，提高故障分类置信度。本文采用如今比较成熟的有监督算法 BP 神经网络来对 DBN 网络反向调节参数。如图 2 可以看出 DBN 网络的训练过程，首先输入样本的状态参数到多层 RBM 中，逐层更新参数；然后把 RBM 训练结果和样本特征输入到 BP 神经网络中反向调节完成对模型的参数优化。




图2 DBN训练流程图

Fig.2 Flow chart of DBN training

2) RBM训练过程

RBM 的训练就是为了通过反复迭代得出深度信念网络的隐藏特征。根据上述公式 11-13 可以得出参数 θ 的更新流程如下图 3 所示，公式中 k 为训练次数， ε 为学习率。

① 参数初始化。初始化参数 w 、 a 、 b 、 ε ，允许重构误差 err 、最大训练次数 $epoch$ ， k 初值赋为 1。把原始的数据 v 输入到网络；

② 参数更新。更新 w 、 a 、 b ，计算输出 $h.1$ ，然后又反推 $v.1$ ，继续计算 $h.2$ ，…… $h.k$ ；

$$w = w + \varepsilon \left(\begin{matrix} P(h_j^{(k)} = 1 | v^{(k)}) (v^{(k)})^T \\ -P(h_j^{(k+1)} = 1 | v^{(k+1)}) (v^{(k+1)})^T \end{matrix} \right) \quad (1)$$

4)

$$a = a + \varepsilon (v^{(k)} - v^{(k+1)}) \quad (15)$$

$$b = b + \varepsilon (P(h_j^{(k)} = 1 | v^{(k)}) - P(h_j^{(k+1)} = 1 | v^{(k+1)})) \quad (16)$$

③ 结果检验。判定循环次数和误差是否符合要求，当最后反推出的 $v.k$ 和 v 比较其重构误差 $err = \|v.k - v\|^2$ ，当重构误差足够小时，将这个时候的 $h.k$ 带入下一层RBM继续训练。如果不符合则将 k 赋值为 $k+1$ 然后重复进行步骤2。

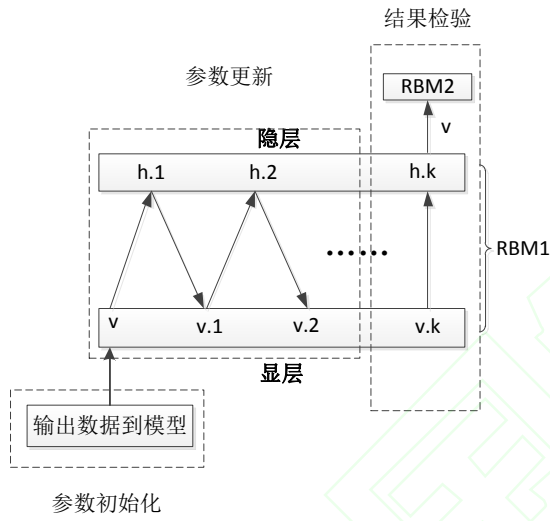


图3 RBM训练过程

Fig.3 RBM training process

2.2 决策融合算法

决策融合算法以D-S证据理论^[16]为基础，假设共有 m 个故障，其集合为 $\{A_1, A_2, A_3, \dots, A_m\}$ ， n 次诊断结果 $\{B_1, B_2, B_3, \dots, B_n\}$ 对应的函数为 $\{F_1, F_2, F_3, \dots, F_n\}$ ，结果 $F_i(A_k)$ 和 $F_j(A_k)$ 的相似度函数定义为 $S_{ij}(A_k)$ ，其公式如下：

$$S_{ij}(A_k) = 1 - \frac{|F_i(A_k) - F_j(A_k)|}{\max(F_i(A_k), F_j(A_k))} \quad (17)$$

式中： $i \neq j (i, j = 1, 2, \dots, n)$ ， $k = 1, 2, 3, \dots, m$ 。

可以看出两个结果之间相似度相差越小，相似度值越大。当两个结果的相似度完全相同时，相似度为最高值 1。定义结果 $B_i(A_k)$ 的支持度为 $P(A_k)$ 和信任度 $C(A_k)$ 如下式：

$$P_i(A_k) = \prod_{\substack{j=1 \\ i \neq j}}^n S_{ij}(A_k) \quad (18)$$

$$C(A_k) = \frac{P_i(A_k)}{\sum_{j=1}^n P_j(A_k)} \quad (19)$$

求出经 n 个结果数据融合后得出的信任度，然后取 $\max(C(A_1), C(A_2), \dots, C(A_k))$ 作为最终结果。

3 基于深度学习的航空发动机故障融合诊断模型

基于深度学习的航空发动机故障融合模型结合了深度信念网络模型和决策融合模型。先通过深度信念网络模型提取故障样本的性能参数特征，再对故障分类结果进行决策融合。具体模型运算步骤如图4所示：

1) 采集数据，构建训练样本矩阵、标签矩阵和测试矩阵。样本矩阵为 $m \times n$ ，其中 m 为故障数， n 是状态参数个数。设置网络层数和节点个数，其中节点数最大值为 $2\sqrt{mn} + n$ ，初始状态参数设为极小值；

2) 把训练样本输入深度信念网络中，从高层到底层学习DBN中的所有RBM，得出权值 w 和各参数；

3) 把训练得到的参数输入到BP神经网络中进行反向优化训练，得到最终的深度信念网络模型；

4) 输入测试样本得出故障置信度；

5) 重复步骤4进行多次实验，把得出的故障分类置信度结果输入到决策融合模型中；

6) 根据决策融合结果得出故障融合诊断结果；

7) 分析故障融合诊断结果，并统计正确率。

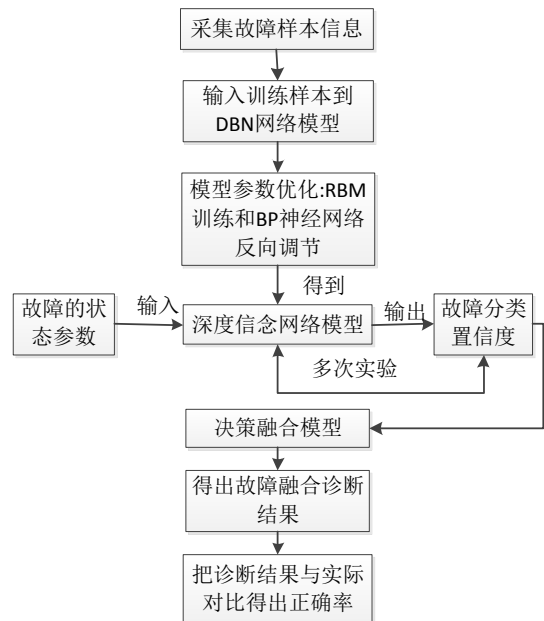


图4 基于深度学习的航空发动机故障融合诊断模型
Fig.4 Fault fusion diagnosis model for aeroengine based on
deep learning

用表1的发动机故障表^[17]作为原始样本进行仿真拓展，公式^[14]如下：

$$x = x_0 + k\sigma * rand \quad (20)$$

其中： x_0 为原始样本， k 为噪音控制因子用来模拟噪音受到环境干扰的情况。 σ 样本标准差， $rand$ 函数用来生成服从正太分布的随机数。

表 1 JT9D 发动机故障表

Tab.1 Engine failure table of JT9D

序号	发动机故障类型	性能参数变化			
		$\Delta EGT(^{\circ}C)$	$\Delta FF(\%)$	$\Delta N1(\%)$	$\Delta N2(\%)$
F01	风扇效率+1%	-1	-0.25	-0.25	-0.05
F02	风扇流量+1%	4.5	0.8	-0.85	0.05
F03	低压压气机效率+1%	-2	-0.15	0.1	-0.15
F04	低压压气机流量+1%	-2	-0.4	-2	-0.05
F05	高压压气机效率+1%	-7	-0.85	-0.1	0.1
F06	高压压气机流量+1%	-0.05	-0.1	0	-0.25
F07	高压涡轮效率+1%	-0.85	-1.05	-0.1	0.2
F08	低压涡轮效率+1%	-4.5	0	0.45	0
F09	3.0+3.5 放气活门开度-20%	-11.2	-2.4	-0.04	-0.24
F10	第一级涡轮导向叶片面积+1%	2.5	0.35	0.05	-0.15

4.2 建立故障诊断模型

首先建立4维样本矩阵，每维代表各个性能参数。根据仿真建立1000个有样本故障状态标签的训练样本，每种故障类型100个，其中故障因子设置为0.1-0.5每隔0.1仿真20个样本。另外建立1000个无标签的训练样本，参数设置与有标签样本相同。然后构建层数分别为2-4的共7个四DBN网络，代入所有训练样本求出样本的总重构误差可得如表2所示，可以看出网络结构为[4, 6, 8, 10]的DBN网络，重构误差最小，说明该网络结构能够更加准确的挖掘出性能参数中的隐藏特征。因此，我们选取该网络结构做进一步的反向调节优化。

网络结构为[4, 6, 8, 10]的 DBN 网络重构误差见图 5。可以看出在多次重构后，重构误差逐步下降到较小值。

表 2 DBN 网络结构与重构误差

Tab.2 DBN network structure and reconstruction error table

DBN 网络结构	重构误差
[4, 6, 10]	0.083
[4, 8, 10]	0.047
[4, 6, 8, 10]	0.076
[4, 8, 12, 10]	0.037
[4, 8, 9, 10]	0.028
[4, 8, 9, 12, 10]	0.049
[4, 6, 8, 12, 10]	0.065




图5 重构误差图

Fig.5 Graph of Reconstruction error




图6 BP 误差图

Fig.6 Graph of BP error

然后对带标签样本进行反向调节,可以得出 BP 误差曲线如下图 6 所示, BP 误差反映出状态参数的隐藏特征与故障类型的匹配程度,其误差值为所有训练样本的特征值与故障类型的标准差总和。由于 RBM 训练过程为无监督训练,所以提取出的样本特征不能直接与故障类型相对应。从图 6 可以看出刚开始训练时 BP 误差很大,在 2500 次左右样本误差已经大幅度下降,在运算 30000 次后最终 BP 误差仅为 0.41,已满足要求。

4.3 故障融合诊断结果

截取故障 F05 的 5 次实验结果,其置信度见表 3,其中 $9\text{E-}08$ 代表 9×10^{-8} 。从表中可以看出每次诊断得出的置信度都有一定偏差,对于 F05 的置信度 1 为 0.278,同时 F09 的置信度为 0.716,发生了明显的分类错误。对比故障 F05 和 F09 的状态参数可以看出由于范围较为接近,在故障仿真中的数据特征较为模糊,因此容易在单次故障诊断结果出错。为了消除个别实验结果对诊断结果的影响,需要决策融合再进行更准确的诊断。同时应当对那些特征不明显的样本,应再仿真出一些类似样本,添加到深度信念网络的训练集中,从而对深度信念网络的参数进行进一步优化。

表 3 故障分类置信度

Tab.3 Confidence level of fault classification

故障类型	置信度 1	置信度 2	置信度 3	置信度 4	置信度 5
F01	9E-08	1.08E-06	6.01E-07	2.35E-06	4.90E-05
F02	2.41E-07	7.09E-07	5.39E-07	3.77E-07	6.06E-07
F03	0.005163	0.002603	0.003046	0.001395	6.57E-05
F04	6.30E-05	0.000235	0.000181	0.000115	0.00025
F05	0.277828	0.796908	0.643634	0.946859	0.998639
F06	1.16E-05	2.05E-06	3.78E-06	3.17E-07	1.91E-09
F07	0.001014	0.000727	0.001078	0.000188	1.18E-05
F08	1.10E-05	4.65E-05	2.30E-05	8.12E-05	0.000431
F09	0.715909	0.199476	0.352033	0.051358	0.000554
F10	4.66E-7	4.68E-7	4.34E-7	1.40E-7	3.39E-8

为了消除运算结果偏差对最终故障诊断结果所造成的影响, 进一步提高诊断正确率, 把表中数据带入到决策融合算法中可得到最终结果见表 4。从表中可以看出经过决策融合, 故障在所属 F5 的置信度极高, 达到了故障分类要求。

通过上述实验, 选择网络结构为[4, 6, 8, 10]的深度信念网络模型和决策融合模型组合成故障融合诊断模型。仿真出 1000 个有故障状态标签的测试样本, 每种故障类型 100 个, 为检验模型抗干扰性, 故障因子设置为 0.1~1 每隔 0.1 仿真 10 个样本。把测试样本带入到故障融合诊断模型中, 把得出故障融合诊断结果与故障状态标签对比可以得出故障融合诊断正确率。

下面将测试样本带入到基于深度学习的故障融合诊断模型与智能算法模型、BP 神经网络和单独深度信念网络模型进行对比, 并统计正确率。从

表 5 中的实验结果可以看出本文所采用的深度信念网络与决策融合模型正确率为 99.58%, 比无决策融合模型略高, 同时 BP 神经网络模型在多故障诊断中效果较差。说明通过决策融合有效的提高了模型抗干扰型, 有更高的故障诊断正确率。

表 5 故障诊断正确率对比表

Tab. 5 Accuracy comparison table of fault diagnosis

模型类型	正确率
深度信念网络与决策融合模型	99.58%
深度信念网络模型	95.30%
BP 神经网络模型	82.13%

表 4 故障诊断结果表

Tab. 4 Results table of fault diagnosis

	F1	F2	F3	F4	F5	F6	F7	F8	F9	F10
C(F)	3.9E-05	7.6E-07	7.16E-05	0.38E-3	0.998	4.32E-09	3.25E-05	0.161E-3	0.129	4.14E-08
诊断结果	0	0	0	0	1	0	0	0	0	0

5 结论

1) 该故障融合诊断模型与传统智能算法相比有更高的故障诊断正确率, 例如对 JT9D 发动机进行故障诊断的正确率达到 99.58%。

2) 故障融合诊断模型中的深度学习方法方法能够充分发掘大样本特征, 对多故障进行分析, 提取故障样本隐含特征。

3) 该故障融合诊断模型结构简单, 输入输出清晰直观。先把故障样本的状态参数作为输入, 输出各个故障分类置信度; 然后再用决策融合方法把多次故障分类结果相融合得出最终诊断结果。

4) 该模型使用决策融合方法消除了深度信念网络故障分类结果中的偶然误差, 有较好的抗干扰能力。

为了使本模型的故障诊断结果更精确、速度更快, 仍需要优化相关参数和模型结构。

参考文献 (References)

[1] 黄强, 王建, 张桂刚. 一种航空发动机传感器故障诊断方法[J]. 传感技术学报, 2014, 27(10): 1315-1320.

HUANG Q, WANG J, ZHANG G G. A Kind of Approach for Aero-Engine Sensor Fault Diagnosis [J]. Chinese Journal of Sensors and Actuators, 2014, 27(10): 1315-1320.

[2] 薛薇, 王涛. 基于一组卡尔曼滤波器信息融合的故障诊断 [J]. 计算机测量与控制, 2015, 23(7): 2285-2287.

XUE W, WANG T. Application of a Bank of Kalman Filters for Aircraft Engine Sensor/Actuator Fault Diagnosis [J]. Computer Measurement and Control, 2015, 23(7): 2285-2287.

[3] 俞刚, 黄金泉. 基于支持向量机和卡尔曼滤波器的航空发动机故障诊断研究[J]. 航空发动机, 2012, 38(1): 47-50.

YU G, HUANG J G. Aeroengine Fault Diagnosis Based on Support Vector Machine and Kalman Filter[J]. Aero-Engine, 2012, 38(1): 47-50.

[4] 廖洪一. 基于极限学习机的航空发动机故障诊断研究[D]. 四川: 中国民用航空飞行学院, 2012.

LIAO H Y. Research on Aero-engine Fault Diagnosis Based on Extreme Learning Machine[D]. Sichuan: Civil Aviation Flight University of China, 2012.

[5] 赵世荣, 黄向华. 应用神经网络信息融合诊断航空发动机故障 [J]. 航空动力学报, 2008, 23(1): 164-168.

ZHAO S R, HUANG X H. Fault diagnosis for aeroengine gas path components based on neural network multisensor data fusion [J]. Journal of Aerospace Power, 2008, 23(1): 1-6.

[6] 徐启华, 师军, 耿帅. 应用快速多分类 SVM 的航空发动机故障诊断方法[J]. 推进技术, 2012, 33(6): 961-967.

- XU Q H, SHUAI J, GENG S. Aero-Engine Fault Diagnosis by a New Fast Multi-Class Support Vector Algorithm[J]. Journal of Propulsion Technology, 2012, 33(6): 961-967.
- [7] 孙伟超, 李文海, 李文峰. 融合粗糙集与 D-S 证据理论的航空装备故障诊断[J]. 北京航空航天大学学报, 2015, 41(10): 1902-1909.
- SUN W C, LI W H, LI W F. Avionic devices fault diagnosis based on fusion method of rough set and D-S theory[J]. Journal of Beijing University of Aeronautics and Astronautics, 2015, 41(10): 1902-1909.
- [8] 于劲松, 沈琳, 唐获音. 基于贝叶斯网络的故障诊断系统性能评价[J]. 北京航空航天大学学报, 2016, 42(1): 35-40.
- YU J S, SHEN L, TANG D Y. Performance evaluation of fault diagnosis system based on Bayesian network[J]. Journal of Beijing University of Aeronautics and Astronautics, 2016, 42(1): 35-40.
- [9] Tai A H, Ching W K, Chan L Y. Detection of machine failure: Hidden Markov Model approach[J]. Computers & Industrial Engineering, 2009, 57(2): 608-619.
- [10] Gómez M J, Castejón C, García-Prada J C. Automatic condition monitoring system for crack detection in rotating machinery[J]. Reliability Engineering & System Safety, 2016, 152: 239-247.
- [11] Bajric R, Zuber N, Skrimpas G A, et al. Feature Extraction Using Discrete Wavelet Transform for Gear Fault Diagnosis of Wind Turbine Gearbox[J]. Shock & Vibration, 2016, 2016(1): 1-10.
- [12] Simani S. Residual generator fuzzy identification for automotive diesel engine fault diagnosis[J]. International Journal of Applied Mathematics & Computer Science, 2013, 23(23): 419-438.
- [13] 周利敏, 闫国华, 瞿红春. 一种云环境下的发动机健康管理系统及其应用[J]. 计算机测量与控制, 2014, 22(12): 3926-3928.
- ZHOU L M, YAN C H, ZHAI H C. Engine Health Management System in Cloud and Its Applications [J]. Computer Measurement and Control, 2014, 22(12): 3926-3928.
- [14] 单外平. 基于深度信念网络的变速器故障分类识别研究[D]. 广州: 华南理工大学, 2015.
- SHAN W P. Classification and Recognition of Transmission Fault Based on Deep Belief Network[D]. Guangzhou: South China University of Technology, 2015.
- [15] 刘伟峰, 杨爱兰. 基于 BIC 准则和 Gibbs 采样的有限混合模型无监督学习算法[J]. 电子学报, 2011, 39(S1): 134-139.
- LIU W F, YANG A L. Unsupervised Learning for Finite Mixture Models Based on BIC Criterion and Gibbs Sampling[J]. Acta Electronica Sinica, 2011, 39(S1): 134-139.
- [16] 李文立, 郭凯红. D-S 证据理论合成规则及冲突问题[J]. 系统工程理论与实践, 2010, 30(8): 1422-1432.
- LI W L, GUO K H. Combination rules of D-S evidence theory and conflict problem[J]. Systems Engineering Theory and Practice, 2010, 30(8): 1422-1432.
- [17] 张光明. 航空发动机气路故障诊断技术研究[D]. 沈阳航空工业学院, 2010.
- ZHANG G M. Research on Gas Path Fault Diagnosis for Aero-engine[D]. Shen Yang Institute of Aeronautical Engineering, 2010.

作者简介:

车畅畅 男, 硕士研究生。主要研究方向: 可靠性、维修性及维修工程。

王华伟 女, 博士, 教授, 博士生导师。主要研究方向: 民航安全工程、民航维修工程、可靠性工程。

Fault fusion diagnosis of aircraft engine based on deep learning

CHE Changchang¹, Wang Huawei¹, NI Xiaomei¹, HONG Jiyu¹

(1. School of Civil Aviation, Nanjing University of Aeronautics and Astronautics, Nanjing 210016, China)

Abstract: Through the fault diagnosis of aero-engine, the working status of each component can be correctly judged, and the maintenance program can be determined quickly to ensure the safety of flight. Based on the combination of deep belief network and decision fusion theory, fault fusion diagnosis of aircraft engine based on deep learning was proposed. This model through analyze a large number of engine parameters, start with getting fault classification confidence via hidden features in engine performance parameters extracted by deep learning algorithm, then the results were fused to get more accurate results. The JT9D-74R engine failure coefficient was simulated as data to prove the validity of the method. The results of an example show that: the reliability of the data has been improved by fault fusion diagnosis of several experimental results, the model has high accuracy and anti-interference ability.

Key words: deep learning; fault diagnosis; decision fusion

Received: 2017-04-05; Accepted: ; Published online:

URL:

Foundation item: National Natural Science Foundation of China (71401073); Supported by the National Natural Science Foundation of China and the China Civil Aviation Administration (U1233115)

*Corresponding author WANG Huawei. Tel.: 15062211551 E-mail: wang hw66@163.com